

DE LA GRILLE ET DU POINT

Le dessinateur de Dürer transfère, point par point à travers une grille tendue, la forme d'un luth vers une surface plane : un algorithme spatial fait ce même geste méthodique, transposé au calcul plutôt qu'au trait de plume.




FIG. IX. ALBRECHT DÜRER, « LE DESSINATEUR DU LUTH », 1525

Un catalogue très fourni d'algorithmes d'analyse spatiale : interpolation, indexation, géométrie computationnelle, analyse de réseau, détection de motifs — mécanique, complexité et cas d'usage, en trois parcours de niveau.

SOMMAIRE

1. STRUCTURES D'INDEXATION SPATIALE : GRILLE, QUADTREE, K-D TREE

2. TRIANGULATION DE DELAUNAY ET POLYGONES DE VORONOÏ/THIESSEN

3. LE TIN, UN RÉSEAU IRRÉGULIER DE TRIANGLES POUR UN MNT

4. INTERPOLATION SPATIALE APPROFONDIE : IDW, SPLINE, ET KRIGEAGE

5. PLUS COURT CHEMIN, AU-DELÀ DE DIJKSTRA ET A*

6. CLUSTERING SPATIAL BASÉ SUR LA DENSITÉ : DBSCAN

7. GÉNÉRALISATION CARTOGRAPHIQUE AUTOMATISÉE

8. OPÉRATIONS GÉOMÉTRIQUES ROBUSTES

Sur la gravure d'Albrecht Dürer qui prête son décor à cette salle, deux hommes transfèrent la forme d'un luth vers une surface plane, point par point, à travers une grille tendue entre eux et l'objet : un protocole reproductible, pas un coup d'œil d'artiste. C'est exactement ce que fait un algorithme spatial — une suite d'étapes précises, les mêmes à

chaque exécution, qui transforme des coordonnées en une forme, une distance, une estimation ou un chemin. Les modules Le Compas, Les Statistiques et La Base ont déjà mis en situation plusieurs de ces algorithmes (Moran, MAUP, krigeage, Dijkstra/A*, AHP, LISA, Gi*, KDE, régression spatiale, index GiST) : cette salle ne les répète pas, elle les prolonge dans une autre direction. Elle se lit comme un catalogue — volontairement dense, pensé pour qu'on y revienne consulter un algorithme précis plutôt que pour une seule lecture continue du début à la fin. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : TOBLER, MORAN, KRIGEAGE, DIJKSTRA/A*, AHP

Le Compas pose les bases théoriques et les tout premiers algorithmes d'analyse spatiale — cette salle les prolonge sans les répéter.

SUPÉRIEUR

1. STRUCTURES D'INDEXATION SPATIALE : GRILLE, QUADTREE, K-D TREE

Chercher « tous les points à moins de 500 m de cet endroit » ou « le plus proche voisin de ce point » en comparant un par un à chacun des n points d'un jeu de données coûte, dans le pire des cas, autant de comparaisons qu'il y a de points : une recherche naïve en $O(n)$. Sur quelques centaines de points, cela reste instantané ; sur plusieurs millions, cela devient rapidement impraticable si la même recherche doit être répétée de nombreuses fois. Une structure d'indexation spatiale prétraite les données une fois pour toutes afin que chaque recherche ultérieure élimine d'emblée l'immense majorité des candidats impossibles.

GRILLE RÉGULIÈRE

- Découpe l'espace en cellules de taille fixe, indépendamment de la densité réelle des points
- Construction très simple : chaque point est rangé dans sa cellule selon ses coordonnées
- Recherche efficace ($O(1)$ en moyenne) si les points sont répartis de façon à peu près homogène
- Dégénère si les points sont très inégalement répartis : certaines cellules débordent, d'autres restent vides

QUADTREE

- Subdivise récursivement une région en quatre quadrants égaux dès qu'elle contient plus d'un nombre fixé de points
- S'adapte automatiquement à la densité : les zones denses sont finement subdivisées, les zones vides restent en une seule grande cellule
- Recherche en $O(\log n)$ en moyenne pour un arbre à peu près équilibré
- Cas dégénéré : des points alignés ou très regroupés peuvent produire un arbre déséquilibré, proche d'un $O(n)$ dans le pire cas

K-D TREE

- Arbre binaire qui divise l'espace en alternant les axes (x, puis y, puis x...) à la valeur médiane de l'axe courant
- Construction en $O(n \log n)$ (recherche de médiane à chaque niveau)
- Recherche du plus proche voisin en $O(\log n)$ en moyenne, en élaguant les branches trop éloignées pour contenir un meilleur candidat
- Particulièrement efficace pour des données ponctuelles en faible dimension (2D, 3D) ; ses performances se dégradent en haute dimension

MÉTHODE	RECHERCHE (CAS MOYEN)	RECHERCHE (PIRE CAS)	ADAP
Recherche naïve (aucun index)	$O(n)$	$O(n)$	Un jeu de données isolé
Grille régulière	$O(1)$	$O(n)$	Points denses près d'un homme
Quadtree	$O(\log n)$	$O(n)$	Points denses irréguliers (zones et zones)
k-d tree	$O(\log n)$	$O(n)$	Recherche plus voisine faible dimension




PLANCHE XVII. LE PRINCIPE COMMUN AU QUADTREE ET AU K-D TREE : SUBDIVISER RÉCURSIVEMENT L'ESPACE POUR ÉLIMINER D'UN COUP LES RÉGIONS QUI NE PEUVENT CONTENIR AUCUN CANDIDAT PERTINENT, AVANT DE TESTER LES RARES POINTS RESTANTS UN PAR UN.

REMARQUE

ET POUR DES GÉOMÉTRIES ÉTENDUES, PAS SEULEMENT DES POINTS ? LE R-TREE

Grille, quadtree et k-d tree indexent naturellement des points. Pour des géométries étendues (lignes, polygones), le R-tree (Guttman, 1984) regroupe les géométries proches dans des rectangles englobants (bounding box) eux-mêmes imbriqués hiérarchiquement : une recherche élimine d'abord les branches dont le rectangle englobant ne peut pas concerner la requête, avant de tester la géométrie exacte des rares candidats restants — le même principe de pruning que le quadtree, appliqué à des rectangles plutôt qu'à des points. C'est exactement la structure que l'index GiST de PostGIS implémente concrètement en base de données.

ATTENTION

LE MAUVAIS INDEX POUR LE MAUVAIS TYPE DE REQUÊTE

Un k-d tree, très efficace pour un plus proche voisin ponctuel, gère mal des géométries étendues qui se chevauchent (deux polygones peuvent avoir des centres très éloignés tout en se recoupant). Une grille régulière, très simple, devient contre-productive sur des données extrêmement regroupées (une seule cellule contiendrait alors presque tous les points, annulant tout l'intérêt de l'index). Choisir un index adapté au type de géométrie (point vs polygone) et à la distribution réelle des données (homogène vs très regroupée) n'est jamais un détail secondaire.

VOIR AUSSI : ALLER PLUS LOIN : L'INDEX GIST CONCRÈTEMENT, EN POSTGIS

Le module La Base détaille comment ce principe de rectangles englobants imbriqués est implémenté concrètement dans une vraie base de données spatiale, avec EXPLAIN ANALYZE pour vérifier qu'il est bien utilisé.

SUPÉRIEUR

2. TRIANGULATION DE DELAUNAY ET POLYGONES DE VORONOÏ/THIESSEN

Deux constructions géométriques, duales l'une de l'autre, répondent chacune à une question différente sur un même nuage de points : comment les relier en triangles de la

façon la plus « équilibrée » possible (Delaunay), et quelle portion du territoire est la plus proche de chaque point (Voronoi/Thiessen).

BRIQUE — DELAUNAY ET VORONOI : DEUX CONSTRUCTIONS DUALES

CONDITION DE DELAUNAY (CRITÈRE DU CERCLE CIRCONSCRIT)

Un triangle appartient à la triangulation de Delaunay $\Leftrightarrow$ aucun autre point du nuage ne se trouve à l'intérieur de son cercle circonscrit

Parmi toutes les façons possibles de relier un nuage de points en triangles, la triangulation de Delaunay (1934) est celle qui maximise le plus petit angle de chaque triangle, évitant les triangles très allongés et aplatis — une propriété directement utile pour interpoler ensuite à l'intérieur de chaque triangle (section 3, TIN).

Le diagramme de Voronoi (ou polygones de Thiessen) associe à chaque point du nuage la région de l'espace plus proche de lui que de tout autre point — exactement le découpage en « marches d'escalier » rencontré en piste Lycée avec l'interpolation par plus proche voisin, mais construit ici comme un objet géométrique à part entière plutôt que comme un simple effet de bord d'une interpolation.

REMARQUE

LA DUALITÉ ENTRE DELAUNAY ET VORONOI

Les deux constructions se déduisent directement l'une de l'autre : chaque sommet du diagramme de Voronoi est le centre du cercle circonscrit d'un triangle de Delaunay, et chaque arête de Voronoi est portée par la médiatrice de l'arête de Delaunay correspondante (perpendiculaire au milieu du segment qui relie les deux points voisins). Construire l'une des deux structures donne immédiatement l'autre, sans recalcul indépendant.

CONSTRUCTION	RÉPOND À...	APPLICATION TYPIQUE
Triangulation de Delaunay	Comment relier ces points en triangles les plus "réguliers" possible ?	Base d'un TIN (section 3), maillage pour une interpolation ou une simulation
Diagramme de Voronoï / Thiessen	Quelle portion du territoire est la plus proche de chaque point ?	Zone de desserte/chalandise (la pharmacie la plus proche d'une adresse), interpolation par plus proche voisin formalisée

ATTENTION

NE PAS CONFONDRE LES DEUX

Une erreur fréquente consiste à demander « la triangulation de Delaunay » quand on veut en réalité des zones de desserte (Voronoi), ou l'inverse. Un repère simple : Delaunay relie des points par des lignes (des triangles) ; Voronoï découpe l'espace en zones (des polygones). Les deux se déduisent l'un de l'autre, mais ne répondent pas à la même question.

SUPÉRIEUR

3. LE TIN, UN RÉSEAU IRRÉGULIER DE TRIANGLES POUR UN MNT

Un modèle numérique de terrain (MNT) peut être représenté de deux façons : une grille régulière de pixels d'altitude (un raster classique, module Fondements), ou un TIN (Triangulated Irregular Network), un maillage de triangles de Delaunay construits directement sur les points de mesure d'altitude, où qu'ils se trouvent.

INTERPOLATION À L'INTÉRIEUR D'UN TRIANGLE DU TIN

$$z(x, y) = \lambda_1 z_1 + \lambda_2 z_2 + \lambda_3 z_3, \text{ avec } \lambda_1 + \lambda_2 + \lambda_3 = 1$$

z_1, z_2, z_3 = altitudes connues aux trois sommets du triangle qui contient le point (x, y) ;
 $\lambda_1, \lambda_2, \lambda_3$ = coordonnées barycentriques du point dans ce triangle. Cette interpolation revient à ajuster un plan exact passant par les trois sommets : à l'intérieur d'un même triangle, la pente reste strictement constante.

TIN (TRIANGLES DE DELAUNAY)

- Densité de sommets variable : plus fine où le terrain change vite (une crête, une rupture de pente), plus lâche sur un plateau régulier
- Restitue fidèlement les lignes de rupture (crêtes, talwegs) si elles sont fournies comme contraintes de la triangulation
- Stockage proportionnel au nombre de points de mesure réels, pas à une résolution fixée arbitrairement

GRILLE RÉGULIÈRE (RASTER DEM)

- Résolution fixe partout, qu'il y ait ou non un vrai besoin de détail local
- Plus simple à manipuler (algèbre raster directe, module Le Compas), format quasi universel
- Peut sur-échantillonner les zones plates (gaspillage de stockage) ou sous-échantillonner les zones accidentées (perte de détail)

SUPÉRIEUR

4. INTERPOLATION SPATIALE APPROFONDIE : IDW, SPLINE, ET KRIGEAGE

La piste Lycée a introduit l'IDW de façon intuitive. Un paramètre, laissé implicite plus haut, contrôle en réalité tout le comportement de la méthode : l'exposant de pondération.

IDW GÉNÉRALISÉE, AVEC EXPOSANT DE PONDÉRATION P

$$Z(P) = [\sum_i z_i / d_i^p] / [\sum_i 1 / d_i^p]$$

p contrôle à quel point l'influence d'un point décroît vite avec la distance. p = 1 : décroissance douce, chaque point connu garde une influence significative même loin de P. p = 2 (le choix le plus courant, celui de la piste Lycée) : décroissance plus marquée. p élevé (p = 4, 5...) : la méthode se rapproche du plus proche voisin pur, les points un peu plus lointains devenant presque négligeables. Le choix de p n'est jamais neutre et doit être justifié, pas laissé à la valeur par défaut du logiciel.

L'interpolation par spline ajuste, au lieu d'une simple moyenne pondérée, une fonction mathématique lisse (typiquement une somme de fonctions polynomiales par morceaux)

qui passe exactement par chaque valeur connue tout en minimisant sa courbure globale — un peu comme une règle flexible qu'on plierait pour toucher chaque point de mesure sans faire d'angle brusque. Le résultat est une surface visuellement plus lisse qu'une IDW (sans les motifs concentriques caractéristiques de l'IDW autour de chaque point de mesure isolé), mais qui peut produire des valeurs légèrement supérieures ou inférieures aux valeurs mesurées entre deux points très contrastés (un dépassement, ou overshoot), un comportement que l'IDW, bornée par construction entre le minimum et le maximum des valeurs connues, ne produit jamais.

IDW

- Moyenne pondérée par la distance, jamais au-delà du min/max des valeurs connues
- Motifs concentriques ("œil de bœuf") autour de chaque point isolé
- Simple à paramétrer (un seul exposant p), aucune hypothèse statistique sur le phénomène

SPLINE

- Surface lisse, sans motifs concentriques
- Peut dépasser localement le min/max des valeurs mesurées (overshoot) entre deux valeurs très contrastées
- Adaptée à un phénomène qu'on sait varier progressivement (une surface topographique, par exemple)

KRIGEAGE (MODULE LE COMPAS)

- Pondération dérivée statistiquement d'un variogramme ajusté sur les données, pas d'une convention arbitraire (p ou une formule spline)
- Fournit en prime une carte d'incertitude (variance de krigeage)
- Plus exigeant à mettre en œuvre (nécessite un échantillon suffisant pour ajuster un variogramme fiable)

REMARQUE

TROIS MÉTHODES, UNE HIÉRARCHIE DE RIGUEUR CROISSANTE

IDW, spline et krigeage répondent à la même question (estimer une valeur continue à partir d'un échantillon de points), mais avec un degré de rigueur statistique croissant : IDW pondère selon une convention géométrique arbitraire, la spline selon une contrainte purement mathématique de lissage, le krigeage selon la structure spatiale réellement mesurée du phénomène (le variogramme). Aucune des trois n'est "la meilleure" dans l'absolu : IDW convient à un besoin rapide et simple, la spline à un phénomène qu'on sait lisse par nature, le krigeage dès qu'une estimation de l'incertitude est nécessaire en plus de l'estimation elle-même.

VOIR AUSSI : REVOIR : LE KRIGEAGE ET LE VARIOGRAMME EN DÉTAIL

Le Compas détaille la construction du variogramme (portée, palier, pépité) et ce que le krigeage ajoute par rapport à une simple pondération par la distance.

SUPÉRIEUR

5. PLUS COURT CHEMIN, AU-DELÀ DE DIJKSTRA ET A*

Le Compas a déjà présenté Dijkstra (calcul du plus court chemin depuis une source unique, avec des poids positifs) et A* (Dijkstra guidé par une heuristique). Deux situations que ces deux algorithmes ne couvrent pas directement : des poids d'arêtes négatifs, et le besoin du plus court chemin entre toutes les paires de nœuds à la fois plutôt que depuis une seule source.

BELLMAN-FORD : RELAXATION RÉPÉTÉE DE TOUTES LES ARÊTES

Pour chaque arête (u, v, w) , répéter $|V| - 1$ fois : si $\text{dist}[u] + w < \text{dist}[v]$, alors $\text{dist}[v] \leftarrow \text{dist}[u] + w$

Complexité $O(V \cdot E)$ (V = nombre de nœuds, E = nombre d'arêtes), plus lent que Dijkstra en $O((V+E) \log V)$, mais Bellman-Ford (1958) fonctionne même avec des poids d'arêtes négatifs, ce que Dijkstra ne garantit pas (un poids négatif peut faire manquer le vrai plus court chemin à Dijkstra). Une passe supplémentaire après les $|V| - 1$ répétitions permet même de détecter un cycle de poids total négatif (un chemin qu'on pourrait raccourcir indéfiniment en tournant en boucle), une situation que Dijkstra ne détecte pas du tout.

FLOYD-WARSHALL : TOUS LES PLUS COURTS CHEMINS, ENTRE TOUTES LES PAIRES

$\text{dist}[i][j] \leftarrow \min(\text{dist}[i][j], \text{dist}[i][k] + \text{dist}[k][j])$ pour chaque nœud intermédiaire k

Complexité $O(V^3)$, indépendante du nombre d'arêtes. Contrairement à Dijkstra (une seule source à la fois) ou Bellman-Ford, Floyd-Warshall (1962) calcule en une seule passe le plus court chemin entre chaque paire de nœuds du graphe, en autorisant progressivement chaque nœud k comme intermédiaire possible. Économique quand on a réellement besoin de toutes les paires (une matrice complète de distances entre toutes les communes d'un réseau, par exemple) ; inutilement coûteux si on ne cherche qu'un seul chemin source-destination.

ALGORITHME	RÉPOND À...	COMPLEXITÉ	POIDS NÉGATIFS ?
Dijkstra (module Le Compas)	Plus court chemin depuis une source unique	$O((V+E) \log V)$	Non
A* (module Le Compas)	Idem, guidé par une heuristique vers la destination	Dépend de l'heuristique, souvent bien inférieur à Dijkstra en pratique	Non
Bellman-Ford	Plus court chemin depuis une source unique, poids négatifs autorisés	$O(V \cdot E)$	Oui (détecte aussi les cycles négatifs)
Floyd-Warshall	Plus court chemin entre toutes les paires de nœuds à la fois	$O(V^3)$	Oui (pas de cycle négatif)

EXEMPLE

POURQUOI DES POIDS NÉGATIFS, EN GÉOMATIQUE ?

Un poids d'arête négatif paraît étrange pour une distance physique (jamais négative), mais apparaît naturellement dès que le poids représente autre chose : un gain net plutôt qu'un coût pur (un dénivelé négatif qui "rembourse" de l'énergie en descente dans un modèle de coût énergétique d'un trajet), ou un différentiel économique entre deux itinéraires logistiques concurrents. Bellman-Ford reste alors le seul des algorithmes de cette page directement utilisable sans transformation préalable du graphe.

VOIR AUSSI : REVOIR : DIJKSTRA ET A* EN DÉTAIL

Le Compas détaille le fonctionnement de Dijkstra et l'apport de l'heuristique d'A*, les deux algorithmes de plus court chemin les plus utilisés en pratique (itinéraires routiers).

SUPÉRIEUR

6. CLUSTERING SPATIAL BASÉ SUR LA DENSITÉ : DBSCAN

Regrouper des points en clusters (des grappes) selon leur seule position géographique est un problème distinct de tout ce qui précède : on ne cherche plus une valeur (interpolation) ni un chemin (réseau), mais une partition du nuage de points en groupes denses, séparés par des zones plus clairsemées. DBSCAN (Density-Based Spatial Clustering of Applications with Noise, Ester et al., 1996) est l'algorithme de référence pour cette tâche.

BRIQUE – DBSCAN : REGROUPER PAR DENSITÉ, AVEC DÉTECTION DE BRUIT

- ϵ (eps) : le rayon de voisinage autour de chaque point
- minPts : le nombre minimal de points (le point lui-même inclus) qui doivent se trouver dans ce voisinage pour qu'un point soit considéré comme "dense"
- Point cœur (core point) : un point dont le voisinage à distance ϵ contient au moins minPts points
- Point de bordure (border point) : un point qui n'est pas lui-même un point cœur, mais qui se trouve dans le voisinage d'un point cœur
- Bruit (noise) : un point qui n'est ni un point cœur, ni dans le voisinage d'aucun point cœur — DBSCAN ne force jamais un point isolé à rejoindre un cluster

Un cluster DBSCAN est l'ensemble de tous les points cœurs connectés de proche en proche (chacun dans le voisinage d'au moins un autre point cœur du même groupe), auquel s'ajoutent leurs points de bordure. Le nombre de clusters n'est jamais fixé à l'avance : il émerge directement de la structure de densité des données, contrairement à un algorithme qui demanderait de préciser k clusters en entrée.

COMPLEXITÉ DE DBSCAN

$O(n \log n)$ avec un index spatial (section 1) pour chaque requête de voisinage ; $O(n^2)$ sans index

Chaque point doit interroger son voisinage à distance ϵ : avec un quadtree ou un k -d tree, cette requête coûte $O(\log n)$ en moyenne, soit $O(n \log n)$ au total sur n points ; sans index, chaque requête de voisinage compare naïvement à tous les autres points, soit $O(n^2)$ — l'illustration directe de pourquoi les structures d'indexation de la section 1 comptent en pratique, pas seulement en théorie.

EXEMPLE

EXEMPLE : EPS = 1,5 KM, MINPTS = 3

Un semis de départs de feu de forêt : cinq points serrés dans un rayon de 800 m les uns des autres (chacun a au moins deux autres points dans son voisinage à 1,5 km → tous points cœurs, un seul cluster) ; un sixième point isolé à 4 km du groupe le plus proche (aucun point dans son voisinage à 1,5 km → classé bruit, pas rattaché de force au cluster). DBSCAN produit ainsi un seul cluster dense plus un point de bruit, sans qu'on ait eu à décider à l'avance qu'il fallait chercher exactement un groupe.

DBSCAN (CLUSTERING SPATIAL PAR DENSITÉ)

- Le nombre de clusters émerge des données, jamais fixé à l'avance
- Détecte explicitement le bruit (points isolés, non rattachés à un cluster)
- Peut trouver des clusters de forme quelconque, pas seulement des groupes ronds/compacts

K-MEANS (MODULE DU HASARD ET DE LA PREUVE)

- Le nombre de clusters k doit être choisi à l'avance par l'opérateur
- Force chaque point dans un cluster, aucune notion de bruit
- Suppose implicitement des clusters à peu près ronds/compacts autour d'un centre

GI* DE GETIS-ORD (MODULE LES STATISTIQUES)

- Teste un point chaud/froid sur une variable mesurée (une valeur par zone), pas un simple regroupement géométrique de points
- Répond à une question statistique de significativité (Z-score), pas à une partition de l'espace en clusters
- S'applique typiquement sur des zones déjà découpées, DBSCAN s'applique directement sur un semis de points bruts

ATTENTION

CHOISIR EPS ET MINPTS N'EST JAMAIS ANODIN

Un eps trop petit fragmente un vrai cluster en plusieurs petits morceaux artificiels (voire classe presque tout en bruit) ; un eps trop grand fusionne deux clusters réellement distincts en un seul. Une méthode courante consiste à tracer, pour chaque point, la distance à son k -ième plus proche voisin ($k = \text{minPts}$), triée par ordre croissant : le "coude" de cette courbe donne une estimation raisonnable d'eps. Un minPts trop petit (2 ou 3) rend l'algorithme très sensible au bruit ; une règle empirique courante est de partir de $\text{minPts} \geq \text{dimension de l'espace} + 1$, et souvent $\text{minPts} = 2 \times \text{dimension}$ en pratique.

SUPÉRIEUR

7. GÉNÉRALISATION CARTOGRAPHIQUE AUTOMATISÉE

La piste Lycée a présenté Douglas-Peucker intuitivement. Deux précisions techniques, et un second algorithme qui répond au même problème par un critère différent.

COMPLEXITÉ DE DOUGLAS-PEUCKER

$O(n \log n)$ en moyenne ; $O(n^2)$ dans le pire cas

Le cas moyen suppose que le point le plus éloigné du segment courant divise la ligne en deux moitiés à peu près équilibrées à chaque récursion (comme un tri rapide bien équilibré) ; le pire cas survient quand ce point est systématiquement proche d'une extrémité, ce qui ne divise presque pas le problème à chaque étape.

Visvalingam-Whyatt (1993) simplifie une ligne selon un critère différent de la distance perpendiculaire de Douglas-Peucker : l'aire du triangle formé par chaque point et ses deux voisins immédiats.

1. Pour chaque point intermédiaire de la ligne, calculer l'aire du triangle qu'il forme avec ses deux voisins immédiats
2. Retirer le point dont le triangle a la plus petite aire — c'est le point qui, localement, contribue le moins à la forme de la ligne
3. Recalculer l'aire des triangles des deux nouveaux voisins du point supprimé (leur voisinage a changé)
4. Répéter jusqu'à atteindre le nombre de points visé, ou jusqu'à ce que la plus petite aire restante dépasse un seuil fixé

AIRE DU TRIANGLE FORMÉ PAR TROIS POINTS (FORMULE DU DÉTERMINANT)

$$\text{Aire} = \frac{1}{2} \cdot |x_1(y_2 - y_3) + x_2(y_3 - y_1) + x_3(y_1 - y_2)|$$

Avec une file de priorité (tas), retirer à chaque étape le point d'aire minimale coûte $O(\log n)$, pour un total en $O(n \log n)$ sur toute la ligne — la même complexité moyenne que Douglas-Peucker, mais un critère de suppression différent.

DOUGLAS-PEUCKER

- Critère : distance perpendiculaire au segment courant
- Garde fidèlement les grands écarts de trajectoire, même isolés

- Peut laisser des micro-détails côte à côte si aucun ne dépasse seul la tolérance, produisant un résultat parfois anguleux

VISVALINGAM-WHYATT

- Critère : aire du triangle local (une notion d'"importance visuelle" du point)
- Résultat généralement perçu comme visuellement plus naturel, la ligne simplifiée "ressemble" davantage à l'originale de loin
- Traite la ligne de façon plus globale et progressive (un point à la fois, du moins important au plus important), plutôt que par découpes récursives indépendantes

REMARQUE

LEQUEL CHOISIR ?

Douglas-Peucker reste le plus répandu (implémenté nativement dans presque tous les SIG, dont QGIS) et suffit dans l'immense majorité des cas. Visvalingam-Whyatt est préféré quand le rendu visuel final compte particulièrement (cartographie soignée à plusieurs échelles, généralisation progressive d'un même jeu de données pour un web-mapping multi-niveaux de zoom), car son critère d'aire produit statistiquement moins d'artefacts anguleux visibles à l'œil.

SUPÉRIEUR

8. OPÉRATIONS GÉOMÉTRIQUES ROBUSTES

Tous les algorithmes de cette page supposent des géométries "propres" : polygones sans auto-intersection, coordonnées parfaitement exactes. En pratique, une donnée réelle contient souvent des géométries invalides, et les ordinateurs ne calculent jamais avec une précision infinie — deux sources d'erreurs classiques en géométrie computationnelle.

PROBLÈME	CAUSE TYPIQUE	REMÈDE COURANT
Polygone auto-intersectant	Erreur de numérisation, fusion mal contrôlée de deux couches	ST_MakeValid (PostGIS) ou l'astuce buffer(0), qui reconstruit une géométrie valide équivalente
Sommets dupliqués ou quasi confondus	Export/import répété entre logiciels, arrondi de coordonnées	Un seuil de tolérance (snapping) qui fusionne les sommets plus proches qu'une distance donnée
Test d'orientation instable près de trois points presque alignés	Calcul en précision flottante standard (les fameuses erreurs d'arrondi du binaire)	Prédicats géométriques robustes (arithmétique exacte ou adaptative), implémentés dans les bibliothèques de référence comme GEOS

ATTENTION

TROIS POINTS PRESQUE ALIGNÉS : UN PIÈGE CLASSIQUE

Le test d'orientation (le point C est-il à gauche, à droite, ou exactement sur la droite formée par A et B ?), utilisé en interne par la plupart des algorithmes de cette page (convex hull, Delaunay, ray casting), repose sur le signe d'un déterminant. Quand trois points sont presque, mais pas exactement, alignés, l'arrondi en virgule flottante standard peut inverser ce signe par rapport au résultat mathématiquement exact — un bug rare, difficile à reproduire, mais réel dans toute implémentation naïve. Les bibliothèques de géométrie computationnelle de référence (GEOS, JTS, CGAL) utilisent des prédicats robustes spécifiquement conçus pour éviter ce piège, plutôt qu'une simple comparaison de flottants.

EXEMPLE

UNE GÉOMÉTRIE INVALIDE PROPAGE L'ERREUR EN SILENCE

Calculer une intersection, une union ou un buffer sur un polygone auto-intersectant peut, selon la bibliothèque utilisée, produire un résultat silencieusement faux (une surface incorrecte, un polygone à trou inattendu) plutôt qu'une erreur explicite. Vérifier la validité géométrique d'une couche avant tout traitement lourd (ST_IsValid en PostGIS, l'outil "Vérifier la validité" de QGIS) est un réflexe aussi important que vérifier le CRS d'un projet (module Le Compas), pour une raison symétrique : une erreur silencieuse est toujours plus coûteuse à détecter après coup qu'avant.

DEVOIR À RENDRE : EXERCICE NOTÉ

CLASSER DES POINTS PAR DBSCAN, À LA MAIN

Dix capteurs de qualité de l'air sont installés aux coordonnées suivantes (en km) : P1(0, 0), P2(0.5, 0.3), P3(1, 0), P4(0.3, 1), P5(6, 6), P6(6.5, 6.2), P7(6.2, 6.8), P8(7, 6), P9(3, 3), P10(0.8, 0.8). Avec $\text{eps} = 1,5$ km et $\text{minPts} = 3$: (1) pour chaque point, détermine s'il s'agit d'un point cœur, d'un point de bordure ou de bruit (une estimation visuelle des distances, sans calcul exact au mètre près, est acceptée). (2) Déduis-en le nombre de clusters trouvés et leur composition. (3) Explique en une phrase pourquoi P9 est traité différemment par DBSCAN et par un algorithme comme le k-means, où k aurait été fixé à 2 au départ.

- Les points cœurs, de bordure et de bruit sont correctement distingués selon eps et minPts donnés
- Le nombre de clusters trouvés est cohérent avec la classification établie à l'étape 1
- La différence de traitement de P9 (point isolé) entre DBSCAN (bruit possible) et k-means (toujours rattaché à un cluster) est correctement expliquée

- Bilan — à retenir : grille régulière, quadtree et k-d tree accélèrent une recherche spatiale de $O(n)$ naïf à $O(\log n)$ en moyenne, chacun adapté à un type de distribution de données différent (R-tree pour des géométries étendues, cross-link GiST/PostGIS) ; Delaunay et Voronoï sont duaux (triangles vs zones de proximité) ; un TIN interpole exactement par plan à l'intérieur de chaque triangle, contrairement à une grille régulière ; l'exposant p de l>IDW contrôle la localité de l'estimation, la spline lisse au prix d'un possible dépassement, le krigeage reste le seul des trois à fonder sa pondération sur une structure spatiale mesurée ; Bellman-Ford gère les poids négatifs, Floyd-Warshall calcule toutes les paires en $O(V^3)$; DBSCAN regroupe par densité sans fixer k à l'avance et détecte le bruit, contrairement au k-means ou au G_i^* ; Douglas-Peucker (distance) et Visvalingam-Whyatt (aire) simplifient une ligne selon deux critères différents ; une géométrie invalide ou un cas limite en précision flottante peut fausser silencieusement un résultat géométrique.

VOIR AUSSI : CONTINUER : LISA, G_i^* ET KDE

Les Statistiques prolonge cette page sur le terrain spécifiquement statistique — significativité, autocorrélation locale — plutôt que purement géométrique/algorithme.

VOIR AUSSI : PRATIQUER : INDEXATION ET SIMPLIFICATION SOUS QGIS

L'Atelier applique concrètement la création d'un index spatial et la simplification d'une couche vectorielle sur un vrai jeu de données.

