

DE LA GRILLE ET DU POINT

Le dessinateur de Dürer transfère, point par point à travers une grille tendue, la forme d'un luth vers une surface plane : un algorithme spatial fait ce même geste méthodique, transposé au calcul plutôt qu'au trait de plume.




FIG. IX. ALBRECHT DÜRER, « LE DESSINATEUR DU LUTH », 1525

Un catalogue très fourni d'algorithmes d'analyse spatiale : interpolation, indexation, géométrie computationnelle, analyse de réseau, détection de motifs — mécanique, complexité et cas d'usage, en trois parcours de niveau.

SOMMAIRE

1. ANALYSE DE MOTIFS PONCTUELS : CLARK-EVANS, RIPLEY K, ENVELOPPES DE SIMULATION

2. CLUSTERING SPATIAL AVANCÉ : OPTICS, ET LA RÉGIONALISATION (SKATER, AZP)

3. ANALYSE DE RÉSEAU AVANCÉE : TSP, VRP, CENTRALITÉ

4. COMPLEXITÉ ALGORITHMIQUE APPLIQUÉE : POURQUOI LE CHOIX DÉPEND DE LA TAILLE RÉELLE DES DONNÉES

5. PASSAGE À L'ÉCHELLE : QUAND N DEVIENT TRÈS GRAND

6. DÉTECTION DE MOTIFS DE CO-LOCALISATION SPATIALE

Sur la gravure d'Albrecht Dürer qui prête son décor à cette salle, deux hommes transfèrent la forme d'un luth vers une surface plane, point par point, à travers une grille tendue entre eux et l'objet : un protocole reproductible, pas un coup d'œil d'artiste. C'est exactement ce que fait un algorithme spatial — une suite d'étapes précises, les mêmes à chaque exécution, qui transforme des coordonnées en une forme, une distance, une estimation ou un chemin. Les modules Le Compas, Les Statistiques et La Base ont déjà mis en situation plusieurs de ces algorithmes (Moran, MAUP, krigeage, Dijkstra/A*, AHP, LISA, Gi*, KDE, régression spatiale, index GiST) : cette salle ne les répète pas, elle les prolonge dans une autre direction. Elle se lit comme un catalogue — volontairement dense, pensé pour qu'on y revienne consulter un algorithme précis plutôt que pour une

seule lecture continue du début à la fin. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : TOBLER, MORAN, KRIGEAGE, DIJKSTRA/A*, AHP

Le Compas pose les bases théoriques et les tout premiers algorithmes d'analyse spatiale — cette salle les prolonge sans les répéter.

APPROFONDISSEMENT

1. ANALYSE DE MOTIFS PONCTUELS : CLARK-EVANS, RIPLEY K, ENVELOPPES DE SIMULATION

Avant de chercher où une structure spatiale se manifeste (LISA, G_i^* , module Les Statistiques) ou de simplement estimer une densité (KDE, même module), une question plus fondamentale se pose sur un semis de points brut : ce semis est-il statistiquement distinguable d'une répartition complètement aléatoire (CSR, Complete Spatial Randomness — un processus de Poisson spatial homogène), ou révèle-t-il un vrai regroupement (aggrégation) ou au contraire une répulsion (régularité) ?

INDICE DU PLUS PROCHE VOISIN DE CLARK-EVANS

$$R = \bar{r}_A / \bar{r}_E, \text{ avec } \bar{r}_E = 1 / (2\sqrt{n/A})$$

$\bar{r}_A$ = distance moyenne observée au plus proche voisin, calculée sur les n points réels. $\bar{r}_E$ = distance moyenne théorique attendue sous CSR, pour une densité n/A (A = aire de la zone d'étude). $R = 1$: semis statistiquement indiscernable d'un processus aléatoire. $R < 1$: agrégation (les points sont, en moyenne, plus proches de leur plus proche voisin que sous l'hypothèse aléatoire). $R > 1$: régularité/dispersion ($R = 2,1491$ au maximum théorique, atteint pour une grille hexagonale parfaite, la répartition la plus régulière possible).

EXEMPLE

EXEMPLE CHIFFRÉ

Sur une zone d'étude de 100 km^2 ($A = 100$), 5 points d'ignition de feux de forêt affichent une distance moyenne observée au plus proche voisin $\bar{r}_A = 1,2 \text{ km}$. Densité $n/A = 5/100 = 0,05 \text{ point/km}^2$. $\bar{r}_E = 1 / (2\sqrt{0,05}) = 1 / (2 \times 0,2236) \approx 2,236 \text{ km}$. $R = 1,2 / 2,236 \approx 0,54$. R nettement inférieur à 1 : les départs de feu sont significativement plus regroupés dans l'espace que ce qu'un hasard pur produirait — cohérent avec des foyers de départ liés à des facteurs communs (axes routiers, lignes électriques), pas dispersés au hasard sur tout le territoire. Un test statistique (écart-type théorique sous CSR $\approx 0,26136/\sqrt{(n \times n/A)}$) permet de vérifier si cet écart à $R = 1$ est significatif plutôt que dû au hasard d'échantillonnage sur seulement 5 points.

L'indice de Clark-Evans (1954) résume tout un semis de points en un seul chiffre, à une seule échelle de distance implicite (celle du plus proche voisin). La fonction K de Ripley, déjà présentée en détail dans le module Les Statistiques, généralise cette même question à une infinité de distances h simultanément — un semis peut être regroupé à petite échelle tout en restant proche du hasard à grande échelle, une nuance qu'un seul indice comme R ne peut jamais révéler à lui seul.

🔗 RAPPEL

RAPPEL : LA FONCTION K DE RIPLEY EST DÉJÀ DÉTAILLÉE AILLEURS

Formule complète, exemple chiffré et correction de bord de la fonction K de Ripley : voir le module Les Statistiques, piste Master/Recherche. Cette page ne la répète pas ; elle ajoute ci-dessous ce que Les Statistiques ne détaille pas — comment tester rigoureusement la significativité de $K(h)$ (ou de R ci-dessus) par simulation, plutôt que par une seule formule de test asymptotique.

TEST DE SIGNIFICATIVITÉ PAR ENVELOPPE DE SIMULATION MONTE CARLO

Enveloppe = [min, max] (ou percentiles 2,5 %/97,5 %) de la statistique calculée sur N semis simulés sous CSR

Principe : générer un grand nombre N de semis de points artificiels (typiquement 99 ou 999 simulations), chacun respectant strictement l'hypothèse CSR (n points tirés uniformément au hasard dans la même zone d'étude A), puis calculer la statistique d'intérêt (Clark-Evans R , ou $K(h)$ pour chaque distance h) sur chacun de ces semis simulés. L'ensemble des valeurs simulées borne une enveloppe de confiance : si la statistique observée sur les vraies données sort de cette enveloppe (typiquement au-delà de la plus extrême des 99 simulations, un seuil $p \approx 0,01$), l'écart à CSR est considéré statistiquement significatif — sans jamais supposer de forme théorique particulière pour la distribution de la statistique sous l'hypothèse nulle, contrairement à un test reposant sur une formule d'écart-type asymptotique.

REMARQUE

POURQUOI SIMULER PLUTÔT QUE CALCULER UNE FORMULE ?

La formule de test asymptotique de Clark-Evans (basée sur un écart-type théorique) suppose un grand nombre de points et une zone d'étude simple (souvent rectangulaire). Sur un petit échantillon, une zone d'étude de forme irrégulière (un massif forestier aux contours sinueux, pas un rectangle), ou une statistique plus complexe comme $K(h)$ à de multiples distances simultanément, la simulation Monte Carlo reste valide dans tous les cas : elle respecte exactement la vraie forme de la zone d'étude et le vrai nombre de points, sans aucune approximation mathématique supplémentaire à justifier.

À TOI DE VOIR

À TOI DE VOIR

Un collègue calcule un indice de Clark-Evans $R = 0,85$ sur un semis de 12 points et conclut directement à une agrégation significative, sans test de significativité. Pourquoi cette conclusion est-elle prématurée avec un échantillon aussi petit, et en quoi une enveloppe de simulation Monte Carlo répondrait-elle mieux à la question que R seul ?

APPROFONDISSEMENT

2. CLUSTERING SPATIAL AVANCÉ : OPTICS, ET LA RÉGIONALISATION (SKATER, AZP)

DBSCAN (piste Licence/BUT) suppose une densité de cluster à peu près homogène, fixée par un seul couple (ϵ , minPts) pour tout le jeu de données. OPTICS (Ordering Points To Identify the Clustering Structure, Ankerst et al., 1999) généralise DBSCAN pour gérer des clusters de densités variables au sein d'un même semis de points, sans avoir à choisir un seul ϵ global a priori.

- Distance de cœur (core-distance) d'un point p : la distance à son minPts-ième plus proche voisin — la valeur d' ϵ minimale qui ferait de p un point cœur
- Distance d'accessibilité (reachability-distance) d'un point p depuis un point o : $\max(\text{core-distance}(o), \text{distance}(p, o))$ — combien il faudrait au minimum agrandir le rayon de densité pour atteindre p depuis o
- OPTICS ordonne tous les points selon un parcours qui reste toujours le plus proche possible de la structure dense courante, et produit un graphique d'accessibilité (reachability plot) : les "vallées" de ce graphique correspondent aux clusters, leur profondeur relative à leur densité respective
- Extraire des clusters à différents seuils de densité revient alors à couper ce graphique à différentes hauteurs, sans avoir à relancer tout l'algorithme pour chaque seuil testé — un avantage direct sur DBSCAN, qu'il faudrait relancer entièrement pour chaque nouvel ϵ

COMPLEXITÉ D'OPTICS

$O(n \log n)$ avec un index spatial (section 1, piste Licence/BUT), la même complexité que DBSCAN

OPTICS coûte le même ordre de grandeur que DBSCAN à exécuter, pour un résultat bien plus riche (une hiérarchie de densités explorable a posteriori plutôt qu'une seule partition figée) — le compromis est presque uniquement dans la complexité de mise en œuvre et d'interprétation du reachability plot, pas dans le temps de calcul.

Un problème différent, souvent confondu avec le clustering spatial, est la régionalisation : constituer des régions qui soient à la fois statistiquement homogènes (comme un cluster classique) ET spatialement contiguës (chaque région forme un seul bloc connexe sur la carte, jamais des fragments disjoints). DBSCAN ou OPTICS, appliqués tels quels sur des données mêlant position et attribut, ne garantissent jamais cette contiguïté.

SKATER (SPATIAL 'K'LUSTER ANALYSIS BY TREE EDGE REMOVAL, ASSUNÇÃO ET AL., 2006)

- Construit d'abord un graphe de contiguïté entre zones voisines, pondéré par leur dissemblance d'attributs
- Calcule l'arbre couvrant de poids minimal (MST) de ce graphe
- Retire itérativement, dans cet arbre, l'arête dont la suppression réduit le plus l'hétérogénéité interne des sous-arbres obtenus
- S'arrête au nombre de régions k souhaité — chaque sous-arbre restant est une région, contiguë par construction (c'est un sous-arbre connexe)

AZP (AUTOMATIC ZONING PROCEDURE, OPENSHAW, 1977)

- Part d'un découpage initial en k régions déjà contiguës (un point de départ, pas une reconstruction depuis zéro)
- Recherche locale : déplace une unité spatiale d'une région vers une région adjacente si ce déplacement réduit l'hétérogénéité interne totale, sous contrainte de préserver la contiguïté des deux régions concernées
- Répète jusqu'à ne plus trouver de déplacement qui améliore le résultat (un optimum local, pas nécessairement global)
- Peut être relancé avec des points de départ différents, ou selon une variante recuit simulé, pour tenter d'échapper à un optimum local médiocre

ATTENTION

LA RÉGIONALISATION N'EST PAS UN SIMPLE CLUSTERING APPLIQUÉ À DES ZONES

Appliquer un k-means ou un DBSCAN directement sur des attributs de zones (sans tenir compte de leur contiguïté géographique) peut très bien regrouper deux communes aux caractéristiques socio-économiques proches mais situées aux deux extrémités opposées du territoire — un résultat statistiquement valide, mais inutilisable pour découper un territoire en bassins d'emploi ou en secteurs d'intervention, qui doivent rester des blocs continus sur la carte. SKATER et AZP imposent explicitement cette contrainte de contiguïté, absente par construction d'un clustering classique.

VOIR AUSSI : VOIR AUSSI : AUTOCORRÉLATION SPATIALE ET MAUP

Le Compas rappelle que le découpage d'un territoire n'est jamais neutre pour une statistique de zone (MAUP) — la régionalisation (SKATER/AZP) construit ce découpage rigoureusement plutôt que de le subir.

APPROFONDISSEMENT

3. ANALYSE DE RÉSEAU AVANCÉE : TSP, VRP, CENTRALITÉ

Au-delà du plus court chemin entre deux points (Dijkstra, A*, Bellman-Ford, Floyd-Warshall), l'analyse de réseau couvre des problèmes d'optimisation combinatoire plus vastes — visiter plusieurs points dans le meilleur ordre possible, répartir des tournées entre plusieurs véhicules — et des mesures qui ne cherchent plus un chemin mais l'importance relative de chaque nœud dans l'ensemble du réseau.

LE PROBLÈME DU VOYAGEUR DE COMMERCE (TSP)

Trouver le cycle de coût total minimal qui visite chacun des n nœuds exactement une fois

Le TSP est NP-difficile : aucun algorithme connu ne le résout en temps polynomial dans le cas général. La méthode exacte de Held-Karp (programmation dynamique) le résout en $O(n^2 \cdot 2^n)$, praticable seulement jusqu'à une vingtaine, une trentaine de nœuds. Au-delà, on recourt à des heuristiques : le plus proche voisin (choisir à chaque étape le nœud non visité le plus proche, rapide mais souvent loin de l'optimal), le 2-opt (recherche locale qui élimine les croisements d'itinéraire en échangeant deux arêtes), ou l'algorithme de Christofides, une approximation garantie à 1,5 fois l'optimal pour un TSP métrique (les distances respectent l'inégalité triangulaire), fondée sur un arbre couvrant minimal complété par un couplage parfait de poids minimal sur les nœuds de degré impair.

Le problème de tournées de véhicules (VRP, Vehicle Routing Problem) généralise le TSP à plusieurs véhicules partant d'un même dépôt, chacun avec une capacité limitée (un nombre de colis, un volume) à répartir entre plusieurs clients. Une heuristique classique, l'algorithme des économies (Clarke-Wright, 1964), part d'une tournée séparée pour chaque client puis fusionne progressivement les tournées qui réduisent le plus la distance totale parcourue, tout en respectant la capacité de chaque véhicule.

CENTRALITÉ D'INTERMÉDIARITÉ (BETWEENNESS) ET DE PROXIMITÉ (CLOSENESS)

$$C_B(v) = \sum_{s \neq v \neq t} \sigma_{st}(v) / \sigma_{st} ; C_C(v) = (n - 1) / \sum_u d(v, u)$$

$C_B(v)$ (Freeman, 1977) : pour chaque paire de nœuds (s, t) autres que v , σ_{st} = nombre total de plus courts chemins entre s et t , $\sigma_{st}(v)$ = combien de ces chemins passent par v . Un nœud à forte centralité d'intermédiarité est un "pont" critique du réseau : sa disparition (un pont fermé, un carrefour saturé) allonge fortement de nombreux trajets. $C_C(v)$: l'inverse de la distance moyenne de v à tous les autres nœuds (n = nombre total de nœuds) — un nœud à forte centralité de proximité atteint rapidement le reste du réseau, un bon candidat pour l'implantation d'un équipement central (caserne de pompiers, entrepôt logistique).

MESURE/ALGORITHME	RÉPOND À...	APPLICATION TYPIQUE
TSP (heuristiques)	Dans quel ordre visiter n points pour minimiser la distance totale ?	Tournée de relevé de compteurs, circuit touristique optimisé
VRP (Clarke-Wright)	Comment répartir n clients entre plusieurs véhicules à capacité limitée ?	Planification de tournées de livraison depuis un ou plusieurs dépôts
Centralité d'intermédiarité	Quels nœuds concentrent le plus de trajets qui les traversent ?	Identifier les carrefours critiques d'un réseau routier, les nœuds à protéger en priorité
Centralité de proximité	Quel nœud atteint le reste du réseau le plus rapidement en moyenne ?	Localisation optimale d'un équipement d'urgence (caserne, hôpital)

EXEMPLE

TSP ET VRP NE SONT PAS DIJKSTRA À PLUS GRANDE ÉCHELLE

Dijkstra répond à "quel est le plus court chemin entre A et B", un problème résolu exactement et rapidement même sur un immense réseau. Demander en plus "dans quel ordre visiter dix points précis avant de revenir au dépôt" change radicalement la nature du problème : ce n'est plus un plus court chemin sur un graphe fixe, mais un choix parmi un nombre de permutations qui explose de façon factorielle avec le nombre de points à visiter — exactement pourquoi le TSP est NP-difficile alors que le plus court chemin entre deux points ne l'est pas.

APPROFONDISSEMENT

4. COMPLEXITÉ ALGORITHMIQUE APPLIQUÉE : POURQUOI LE CHOIX DÉPEND DE LA TAILLE RÉELLE DES DONNÉES

Cette page a mentionné une classe de complexité pour presque chaque algorithme présenté. Les rassembler dans un seul tableau rend visible ce qui distingue un algorithme utilisable à toute échelle d'un algorithme réservé à de petits jeux de données.

ALGORITHME	COMPLEXITÉ TYPIQUE	PRATICABLE JUSQU'À...
Recherche naïve de plus proche voisin	$O(n)$	Quelques dizaines de milliers de points, si peu de requêtes répétées
Quadtree / k-d tree (recherche)	$O(\log n)$ moyen	Plusieurs millions de points
Enveloppe convexe (Graham scan)	$O(n \log n)$	Très grands volumes, contrainte surtout par la mémoire
Triangulation de Delaunay	$O(n \log n)$	Plusieurs millions de points (implémentations optimisées)
Douglas-Peucker / Visvalingam-Whyatt	$O(n \log n)$ moyen, $O(n^2)$ pire cas	Une ligne de plusieurs dizaines de milliers de sommets
DBSCAN / OPTICS (avec index)	$O(n \log n)$	Plusieurs millions de points
Dijkstra (tas binaire)	$O((V+E) \log V)$	Un réseau routier national entier
Bellman-Ford	$O(V \cdot E)$	Un réseau de taille moyenne (poids négatifs)
Floyd-Warshall (toutes les paires)	$O(V^3)$	Quelques milliers de nœuds seulement, au-delà : trop lent
TSP exact (Held-Karp)	$O(n^2 \cdot 2^n)$	Une vingtaine à une trentaine de nœuds, pas plus
TSP heuristique (2-opt, Christofides)	Polynomial	Des milliers de nœuds, sans garantie d'optimalité stricte

REMARQUE

UN $O(N^2)$ N'EST PAS TOUJOURS UN MAUVAIS CHOIX

Sur 200 points, un algorithme en $O(n^2)$ (40 000 opérations) et un algorithme en $O(n \log n)$ (environ 1 500 opérations) sont tous deux quasi instantanés pour un ordinateur moderne : la différence ne se voit pas. Sur 2 millions de points, le même écart devient vertigineux : $O(n^2)$ donnerait 4 000 milliards d'opérations (des heures, voire des jours), $O(n \log n)$ en donnerait environ 42 millions (une fraction de seconde). Choisir un algorithme plus complexe à implémenter pour sa complexité asymptotique meilleure n'a de sens qu'à partir d'une taille de données où cet écart devient réellement sensible — une décision d'ingénierie, pas un réflexe systématique à appliquer sans réfléchir à l'échelle réelle du problème.

À TOI DE VOIR

À TOI DE VOIR

Calculer toutes les distances entre toutes les paires de 500 communes d'un département avec Floyd-Warshall ($O(V^3) \approx 125$ millions d'opérations) reste praticable. Faire de même pour les 35 000 communes de France ($O(V^3) \approx 42\,900$ milliards d'opérations) ne l'est plus. Quelle alternative proposerais-tu pour obtenir malgré tout, de façon praticable, la distance de chaque commune aux communes qui l'intéressent réellement (ses k plus proches voisines, par exemple), sans jamais calculer la matrice complète des $35\,000 \times 35\,000$ distances ?

APPROFONDISSEMENT

5. PASSAGE À L'ÉCHELLE : QUAND N DEVIENT TRÈS GRAND

Au-delà de quelques dizaines de millions de géométries, même les structures d'indexation les plus efficaces (section 1) atteignent leurs limites pratiques : la structure elle-même ne tient plus entièrement en mémoire vive, et certains algorithmes (Delaunay exact, TSP même heuristique sur des millions de nœuds) deviennent trop lents même avec la meilleure complexité asymptotique disponible.

- Simplification en flux (streaming) : traiter une ligne ou un polygone sommet par sommet, dans l'ordre du fichier, sans jamais charger la géométrie entière en mémoire — une variante de Douglas-Peucker adaptée au flux existe, au prix d'un résultat parfois légèrement moins optimal qu'une version qui voit la ligne entière d'un coup
- Parallélisation : répartir un traitement spatial (une jointure, une simplification en masse) sur plusieurs cœurs ou plusieurs machines, chacune traitant une portion géographique distincte du jeu de données — l'approche des moteurs de traitement spatial distribué comme Apache Sedona (ex-GeoSpark), construits au-dessus d'un moteur de calcul distribué généraliste
- Indexation hors mémoire (out-of-core) : un R-tree ou un quadtree peut être organisé et stocké directement sur disque, structuré en blocs de taille fixe (souvent la taille d'une page disque), pour rester interrogeable sans jamais devoir tenir intégralement en RAM — le même principe qu'un index de base de données classique (module La Base), appliqué à une géométrie plutôt qu'à un identifiant numérique
- Partitionnement spatial (tuilage) : découper le territoire en dalles ou en tuiles traitées indépendamment, souvent la première étape avant toute parallélisation ou tout traitement hors mémoire




PLANCHE XVII. À TRÈS GRANDE ÉCHELLE, LE MÊME PRINCIPE DE RECTANGLES ENGLOBANTS IMBRIQUÉS S'ORGANISE DIRECTEMENT SUR DISQUE PLUTÔT QU'EN MÉMOIRE VIVE : CHAQUE NŒUD DE L'ARBRE CORRESPOND À UN BLOC LU À LA DEMANDE, PAS À L'ENSEMBLE DE LA STRUCTURE CHARGÉE D'UN COUP.

ATTENTION

LES LIMITES PRATIQUES NE SONT PAS SEULEMENT UNE QUESTION DE MÉMOIRE

Un TSP exact (Held-Karp) reste mathématiquement défini pour n'importe quel nombre de nœuds, mais devient concrètement incalculable bien avant qu'un problème de mémoire ne se pose (dès quelques dizaines de nœuds, la complexité $O(n^2 \cdot 2^n)$ explose). À l'inverse, une recherche de plus proche voisin indexée reste en théorie parfaitement soutenable jusqu'à des milliards de points ; c'est alors la mémoire disponible, pas la complexité de l'algorithme, qui devient la vraie contrainte. Diagnostiquer laquelle des deux limites (complexité algorithmique intrinsèque, ou ressources matérielles disponibles) est réellement en cause conditionne complètement la solution à apporter.

APPROFONDISSEMENT

6. DÉTECTION DE MOTIFS DE CO-LOCALISATION SPATIALE

Au-delà d'une corrélation globale entre deux variables continues (module Du Hasard et de la Preuve) ou d'une autocorrélation d'une seule variable (Moran, module Le Compas), une question différente se pose souvent sur des données catégorielles géolocalisées : quelles catégories d'entités ont tendance à apparaître ensemble dans l'espace, plus souvent que ne le voudrait le hasard ? La détection de motifs de co-localisation spatiale (spatial co-location pattern mining, Shekhar & Huang, 2001) répond précisément à cette question.

INDICE DE PARTICIPATION D'UN MOTIF DE CO-LOCALISATION

$$PR(C, f_i) = |\text{instances de } f_i \text{ participant à } C| / |\text{instances totales de } f_i| ; PI(C) = \min_i PR(C, f_i)$$

Pour un motif $C = \{f_1, f_2\}$ (par exemple "distributeur automatique" et "commerce de restauration rapide"), $PR(C, f_i)$ mesure la proportion des instances de la catégorie f_i qui se trouvent effectivement à proximité d'au moins une instance de l'autre catégorie du motif. L'indice de participation global $PI(C)$, le minimum des PR sur toutes les catégories du motif, résume la force du motif dans son ensemble : un motif n'est considéré comme "prévalent" que si $PI(C)$ dépasse un seuil minimal fixé à l'avance, garantissant que les deux catégories se co-localisent réellement dans les deux sens, pas seulement dans un seul.

EXEMPLE

EXEMPLE CONCRET

Sur un jeu de données de commerces urbains, 80 distributeurs automatiques sur 100 se trouvent à moins de 50 m d'un commerce de restauration rapide ($PR = 0,80$), et 60 commerces de restauration rapide sur 150 se trouvent à moins de 50 m d'un distributeur ($PR = 0,40$). $PI(\{\text{distributeur, restauration rapide}\}) = \min(0,80, 0,40) = 0,40$. Ce motif de co-localisation n'est ni purement symétrique (les distributeurs "cherchent" davantage la proximité des commerces de restauration que l'inverse), ni négligeable — une nuance que ni une simple carte de densité superposée, ni un indice de corrélation global entre deux variables continues, ne mettrait en évidence de cette façon.

REMARQUE

UNE QUESTION DIFFÉRENTE DE LISA OU DE GI^*

LISA et GI^* (module Les Statistiques) travaillent sur une variable mesurée continue (un taux, un indice) répartie sur des zones. La co-localisation travaille directement sur des catégories d'entités ponctuelles distinctes (deux types de commerces, une espèce végétale et un type de sol) : ce n'est pas la même donnée en entrée (catégorielle et ponctuelle, plutôt que continue et zonale), et donc jamais un cas particulier de LISA/ GI^* , même si l'intuition sous-jacente — la proximité spatiale porte de l'information — reste, une fois de plus, celle de Tobler.

DEVOIR À RENDRE : EXERCICE NOTÉ

CALCULER UNE CENTRALITÉ D'INTERMÉDIARITÉ À LA MAIN

Un petit réseau routier relie cinq bourgs par les tronçons suivants, avec leur temps de trajet en minutes : A–B (4), B–C (3), C–D (2), D–E (5), B–D (6), A–E (10). (1) Détermine le plus court chemin (en temps total) entre chacune des six paires de bourgs qui n'impliquent pas B directement comme extrémité (A–C, A–D, A–E, C–D, C–E, D–E), en indiquant si ce chemin passe par B. (2) À partir de ce décompte, calcule la centralité d'intermédiarité de B au sens de Freeman (la part des plus courts chemins, parmi ces six paires, qui passent effectivement par B). (3) Un service technique dispose d'un budget limité pour renforcer un seul tronçon du réseau contre les coupures. Le résultat de la question 2 justifie-t-il de prioriser un tronçon connecté à B plutôt qu'un autre ? Justifie.

- Les six plus courts chemins sont correctement calculés (temps total minimal, en tenant compte de tous les tronçons disponibles, pas seulement du chemin direct)
- La centralité d'intermédiarité de B est calculée comme la proportion correcte de plus courts chemins passant par B parmi les six paires considérées
- La recommandation finale relie explicitement une centralité d'intermédiarité élevée au risque de fragilisation du réseau en cas de coupure de ce nœud

- Bilan — à retenir : Clark-Evans résume un semis de points en un seul indice R à l'échelle du plus proche voisin, la fonction K de Ripley (module Les Statistiques) généralise à toutes les échelles à la fois ; une enveloppe de simulation Monte Carlo teste la significativité de ces deux statistiques sans hypothèse de forme théorique ; OPTICS généralise DBSCAN à des densités variables via un reachability plot ; SKATER et AZP résolvent un problème différent du clustering — la régionalisation sous contrainte de contiguïté spatiale ; le TSP est NP-difficile (heuristiques : plus proche voisin, 2-opt, Christofides), le VRP le généralise à plusieurs véhicules, la centralité d'intermédiarité identifie les nœuds critiques d'un réseau, la centralité de proximité les nœuds les mieux placés en moyenne ; le choix d'un algorithme dépend de la taille réelle n des données, pas seulement de sa complexité asymptotique dans l'absolu ; au-delà de plusieurs dizaines de millions de géométries, le streaming, la parallélisation et l'indexation hors mémoire prennent le relais des structures classiques ; la co-localisation détecte quelles catégories d'entités s'associent spatialement, une question distincte de l'autocorrélation d'une seule variable continue.

VOIR AUSSI : CONTINUER : PASSAGE À L'ÉCHELLE D'UNE BASE SPATIALE

La Base détaille le partitionnement et la parallélisation côté base de données (EXPLAIN ANALYZE, partitionnement, PostGIS Raster) — le pendant applicatif du passage à l'échelle présenté ici de façon

algorithmique.

VOIR AUSSI : VOIR AUSSI : LISA, GI* ET RÉGRESSION SPATIALE

Les Statistiques prolonge cette page sur le terrain de la significativité statistique locale — un terrain complémentaire, pas redondant, de la détection de motifs présentée ici.