

DU HASARD ET DE LA PREUVE

Les Tricheurs du Caravage lisent et manipulent le hasard aux cartes ; l'analyse statistique fait, avec rigueur plutôt qu'avec tromperie, ce que ces joueurs pressentaient déjà : le hasard obéit à des lois qu'on peut mesurer.



FIG. VIII. LE CARAVAGE, « LES TRICHEURS »,
VERS 1594

Statistique descriptive et inférentielle, tests d'hypothèse, corrélation et régression, analyse multivariée, apprentissage statistique : un très grand nombre de méthodes, en trois parcours de niveau.

SOMMAIRE

1. ÉCHANTILLONNAGE ET ESTIMATION : POPULATION, ÉCHANTILLON, ERREUR STANDARD, INTERVALLE DE CONFIANCE

2. TESTS D'HYPOTHÈSE : H_0/H_1 , SEUIL α , P-VALUE, ERREURS DE TYPE I ET II, PUISSANCE

3. TEST DE STUDENT (T-TEST) : COMPARER DEUX MOYENNES

4. LE TEST DU χ^2 (KHI-DEUX)

5. ANOVA (ANALYSE DE VARIANCE À UN FACTEUR)

6. CORRÉLATION ET RÉGRESSION LINÉAIRE SIMPLE

7. RÉGRESSION LINÉAIRE MULTIPLE

8. RÉGRESSION LOGISTIQUE : PRÉDIRE UNE VARIABLE BINAIRE

Dans Les Tricheurs du Caravage, un jeune joueur de cartes crédule affronte deux complices : l'un lit son jeu par-dessus son épaule, l'autre lui signale du bout des doigts, dans son dos, les cartes à jouer. Le tableau pose une question qui a une histoire précise en mathématiques : une série de pertes répétées relève-t-elle du hasard, ou d'un biais caché ?

C'est exactement le problème que le chevalier de Méré soumit à Blaise Pascal en 1654 à propos d'une partie de dés interrompue avant son terme (le « problème des partis ») — la correspondance que Pascal échangea alors avec Pierre de Fermat pour le résoudre est reconnue comme l'acte de naissance du calcul des probabilités. Ce module part de cette même question — un résultat observé est-il dû au hasard, à une vraie régularité, ou à un biais de mesure ou d'échantillonnage — pour construire la boîte à outils statistique générale qui soutient tout le reste du site : les indicateurs spatiaux du module Les Statistiques, la matrice de confusion et le kappa d'une classification satellite (module L'Intelligence), les scripts d'analyse du module R. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

SUPÉRIEUR

1. ÉCHANTILLONNAGE ET ESTIMATION : POPULATION, ÉCHANTILLON, ERREUR STANDARD, INTERVALLE DE CONFIANCE

On appelle population l'ensemble complet des individus (ou des mesures) qui intéressent une étude — toutes les parcelles agricoles d'un département, par exemple — et échantillon un sous-ensemble effectivement mesuré, en général parce que mesurer toute la population est impossible ou trop coûteux. Un estimateur (comme la moyenne d'échantillon $\bar{x}$) approche un paramètre de population inconnu (la vraie moyenne μ) ; deux échantillons différents tirés de la même population donnent presque toujours deux estimations légèrement différentes — c'est cette variabilité d'échantillonnage que l'erreur standard mesure.

ERREUR STANDARD DE LA MOYENNE

$$SE = s / \sqrt{n}$$

s est l'écart-type observé dans l'échantillon, n sa taille. L'erreur standard diminue quand n augmente (un échantillon plus grand donne une moyenne plus stable), mais seulement en $1/\sqrt{n}$: quadrupler n ne fait que diviser SE par deux, pas par quatre.

INTERVALLE DE CONFIANCE À 95 % POUR UNE MOYENNE

$$IC_{95\%} = \bar{x} \pm t(0,025 ; n-1) \cdot SE$$

$t(0,025 ; n-1)$ est la valeur critique de la loi de Student à $n-1$ degrés de liberté (environ 1,96 quand n est grand, où la loi de Student se confond avec la loi normale). L'intervalle obtenu ne signifie pas « il y a 95 % de chances que μ soit dans cet intervalle » — μ est une constante fixe, pas une variable aléatoire — mais que la méthode utilisée produit, sur un grand nombre d'échantillons répétés, un intervalle qui contient effectivement la vraie moyenne 95 % du temps.

ATTENTION

UN ÉCHANTILLON BIAISÉ RESTE BIAISÉ, MÊME TRÈS GRAND

Interroger 10 000 personnes en ligne un jour de semaine à midi ne représente pas la population générale, aussi grand que soit l'échantillon : augmenter n réduit l'erreur d'échantillonnage (le bruit aléatoire), mais ne corrige jamais un biais de sélection (une erreur systématique dans la façon dont l'échantillon a été constitué). Un échantillon de 200 personnes correctement tiré au hasard dans toute la population vaut mieux, pour l'inférence, qu'un échantillon de 10 000 personnes biaisé.

SUPÉRIEUR

2. TESTS D'HYPOTHÈSE : H_0/H_1 , SEUIL α , P-VALUE, ERREURS DE TYPE I ET II, PUISSANCE

Un test d'hypothèse arbitre entre deux affirmations concurrentes à partir de données observées : l'hypothèse nulle H_0 (en général « pas d'effet », « pas de différence », « pas de lien ») et l'hypothèse alternative H_1 , celle qu'on cherche en général à mettre en évidence. Le test ne « prouve » jamais H_1 au sens mathématique strict : il évalue seulement si les données observées sont compatibles avec H_0 , ou suffisamment improbables sous H_0 pour la rejeter.

- Seuil de significativité α : probabilité qu'on accepte, avant même de voir les données, de se tromper en rejetant H_0 alors qu'elle est vraie — classiquement fixé à 0,05 (5 %) par convention, pas par nécessité mathématique
- p-value : probabilité d'observer un résultat au moins aussi extrême que celui obtenu, si H_0 était réellement vraie — plus elle est petite, plus le résultat observé serait surpre-

nant sous H_0

- Règle de décision : si $p\text{-value} < \alpha$, on rejette H_0 (résultat dit « statistiquement significatif ») ; sinon, on ne rejette pas H_0 , ce qui n'équivaut jamais à l'avoir démontrée vraie

	H_0 RÉELLEMENT VRAIE	H_0 RÉELLEMENT FAUSSE
On rejette H_0	Erreur de type I (probabilité α) — faux positif	Décision correcte (probabilité = puissance, $1 - \beta$)
On ne rejette pas H_0	Décision correcte (probabilité $1 - \alpha$)	Erreur de type II (probabilité β) — faux négatif

ATTENTION

UNE P-VALUE NON SIGNIFICATIVE NE PROUVE PAS L'ABSENCE D'EFFET

« $p = 0,21$, non significatif » signifie seulement que les données ne permettent pas de rejeter H_0 avec l'échantillon dont on dispose — pas que H_0 est vraie, et pas que l'effet recherché n'existe pas. Un effet réel mais petit, ou un échantillon trop petit, produisent exactement le même résultat qu'une vraie absence d'effet : c'est précisément ce que mesure la puissance du test.

REMARQUE

LA PUISSANCE D'UN TEST ($1 - \beta$)

La puissance est la probabilité de détecter un effet réel quand il existe réellement — donc d'éviter une erreur de type II. Elle augmente avec la taille de l'échantillon n , avec la taille de l'effet réel (un grand écart est plus facile à détecter qu'un petit), et diminue si on choisit un seuil α plus strict (0,01 plutôt que 0,05). Un test mené sur un échantillon trop petit est sous-puissant : même un effet réel a de bonnes chances d'y passer inaperçu.

SUPÉRIEUR

3. TEST DE STUDENT (T-TEST) : COMPARER DEUX MOYENNES

Le test de Student compare la moyenne d'une variable numérique entre deux groupes, pour juger si l'écart observé est suffisamment grand pour ne pas s'expliquer par le seul hasard d'échantillonnage.

ÉCHANTILLONS APPARIÉS (TEST APPARIÉ)

- Les deux mesures portent sur les mêmes individus (avant/après un traitement) ou sur des paires liées
- On travaille sur la série des différences $d_i = x_{1i} - x_{2i}$, ramenée à un test sur une seule moyenne
- Plus puissant qu'un test indépendant à effectif égal, car il élimine la variabilité propre à chaque individu

ÉCHANTILLONS INDÉPENDANTS

- Les deux groupes rassemblent des individus différents, sans lien entre une observation d'un groupe et une de l'autre
- Nécessite de comparer aussi la variabilité de chaque groupe, pas seulement leurs moyennes
- Le test suppose classiquement des variances comparables entre les deux groupes (à vérifier, par exemple par un test de Levene)

T-TEST APPARIÉ

$$t = \bar{d} / (s_d / \sqrt{n})$$

$\bar{d}$ est la moyenne des différences individuelles, s_d leur écart-type, n le nombre de paires. Le résultat suit une loi de Student à $n-1$ degrés de liberté sous H_0 (moyenne des différences nulle).

T-TEST INDÉPENDANT (VARIANCES SUPPOSÉES ÉGALES)

$$t = (\bar{x}_1 - \bar{x}_2) / [sp \cdot \sqrt{(1/n_1 + 1/n_2)}] \text{ avec } sp^2 = [(n_1-1)s_1^2 + (n_2-1)s_2^2] / (n_1+n_2-2)$$

sp^2 (variance combinée, « pooled ») met en commun la variabilité des deux groupes. Le résultat suit une loi de Student à n_1+n_2-2 degrés de liberté sous H_0 ($\mu_1 = \mu_2$). Quand les variances des deux groupes sont trop différentes, on utilise à la place la correction de Welch, qui ajuste les degrés de liberté sans supposer des variances égales.

- Conditions d'application : variable numérique à peu près normalement distribuée dans chaque groupe (ou effectif assez grand pour que ce ne soit plus critique), observations indépendantes entre elles, et — pour la version classique — variances comparables entre groupes
- Avec des données trop éloignées d'une distribution normale et un petit échantillon, un test non paramétrique (comme le test de Mann-Whitney pour deux groupes indépendants) remplace le t-test sans supposer de forme de distribution particulière

SUPÉRIEUR

4. LE TEST DU χ^2 (KHI-DEUX)

Le t-test compare des moyennes de variables numériques ; le test du χ^2 compare, lui, des variables qualitatives (catégorielles), à partir de leurs effectifs observés.

TEST D'INDÉPENDANCE DU χ^2

- Teste si deux variables qualitatives sont liées (ex. occupation du sol $\times$ commune) à partir d'un tableau croisé
- H_0 : les deux variables sont indépendantes

TEST D'AJUSTEMENT DU χ^2

- Teste si une seule variable qualitative suit une distribution théorique attendue (ex. répartition attendue des classes d'occupation du sol dans une région)
- H_0 : la distribution observée correspond à la distribution théorique

STATISTIQUE DU χ^2

$$\chi^2 = \sum_i (O_i - E_i)^2 / E_i$$

O_i = effectif observé dans la case i , E_i = effectif théorique attendu sous H_0 dans cette même case (pour un test d'indépendance, E_i se calcule à partir des totaux de ligne et de colonne du tableau croisé). Plus les effectifs observés s'écartent des effectifs attendus, plus χ^2 est grand. Le nombre de degrés de liberté d'un test d'indépendance est (nombre de lignes $- 1$) $\times$ (nombre de colonnes $- 1$).

ATTENTION

UNE CONDITION D'APPLICATION SOUVENT OUBLIÉE

Le test du χ^2 n'est fiable que si les effectifs théoriques E_i restent suffisamment grands (classiquement, au moins 5 dans chaque case) ; en deçà, l'approximation statistique sur laquelle repose le test devient peu fiable, et un test exact (comme le test exact de Fisher pour un tableau 2×2) est préférable.

EXEMPLE

EXEMPLE CHIFFRÉ

Un tableau croisant deux communes (A, B) et l'occupation du sol dominante d'un échantillon de parcelles (forêt, agricole, urbain) donne des effectifs observés qui s'écartent des effectifs attendus si les deux communes avaient exactement la même répartition. Un χ^2 élevé (et une p-value $< 0,05$) indique que l'occupation du sol diffère significativement entre les deux communes — pas quelle commune a plus de forêt : c'est un test global, à compléter par une lecture directe du tableau croisé pour interpréter le sens de la différence.

SUPÉRIEUR

5. ANOVA (ANALYSE DE VARIANCE À UN FACTEUR)

Comparer plus de deux groupes en enchaînant des t-tests deux à deux gonfle artificiellement le risque global de faux positif (avec 5 groupes, cela ferait déjà 10 tests, chacun avec son propre risque de 5 % d'erreur de type I). L'ANOVA à un facteur compare directement k groupes en une seule fois, en distinguant la variabilité entre les groupes de la variabilité à l'intérieur de chaque groupe.

STATISTIQUE F DE L'ANOVA

$$F = (SSB / (k-1)) / (SSW / (N-k)) = CMB / CMW$$

SSB (somme des carrés entre groupes) mesure la dispersion des moyennes de groupe autour de la moyenne générale ; SSW (somme des carrés intra-groupe) mesure la dispersion des observations autour de leur propre moyenne de groupe. k = nombre de groupes, N = effectif total. Si les groupes ne diffèrent pas réellement, la variabilité entre groupes n'est pas plus grande que la variabilité à l'intérieur d'un groupe et F reste proche de 1 ; un F grand indique que la variabilité entre groupes dépasse largement celle attendue par le seul hasard d'échantillonnage intra-groupe.

SOURCE DE VARIATION	SOMME DES CARRÉS	DEGRÉS DE LIBERTÉ	CARRÉ
Entre les groupes	SSB	$k - 1$	$CMB = \frac{SSB}{k-1}$
Intra-groupe (résiduelle)	SSW	$N - k$	$CMW = \frac{SSW}{N-k}$
Totale	$SST = SSB + SSW$	$N - 1$	—

REMARQUE

UN F SIGNIFICATIF NE DIT PAS LESQUELS DES GROUPES DIFFÈRENT

Un résultat d'ANOVA significatif indique qu'au moins deux des k groupes diffèrent, sans préciser lesquels. Un test post-hoc (comme le test de Tukey HSD) compare ensuite les groupes deux à deux tout en contrôlant le risque global de faux positif — le prolongement logique et nécessaire d'une ANOVA significative, pas une étape optionnelle.

SUPÉRIEUR

6. CORRÉLATION ET RÉGRESSION LINÉAIRE SIMPLE

Le coefficient de corrélation de Pearson quantifie précisément la force et le sens d'une relation linéaire entre deux variables numériques, déjà abordé intuitivement piste Lycée.

COEFFICIENT DE CORRÉLATION DE PEARSON

$$r = [\sum_i (x_i - \bar{x})(y_i - \bar{y})] / [\sqrt{\sum_i (x_i - \bar{x})^2} \cdot \sqrt{\sum_i (y_i - \bar{y})^2}]$$

Le numérateur (covariance non normalisée) est positif si x et y augmentent ensemble, négatif s'ils varient en sens opposé. Le dénominateur normalise par les écarts-types respectifs, ce qui borne toujours r entre -1 et +1, quelle que soit l'unité des deux variables.

La régression linéaire simple va plus loin que la corrélation : elle ajuste une droite qui prédit y à partir de x, en choisissant la droite qui minimise la somme des carrés des écarts verticaux entre chaque point observé et la droite (méthode des moindres carrés).

DROITE DES MOINDRES CARRÉS

$$\hat{y} = b_0 + b_1 x \text{ avec } b_1 = \sum_i (x_i - \bar{x})(y_i - \bar{y}) / \sum_i (x_i - \bar{x})^2 \text{ et } b_0 = \bar{y} - b_1 \bar{x}$$

b_1 est la pente estimée (variation attendue de y pour une augmentation d'une unité de x), b_0 l'ordonnée à l'origine. « Moindres carrés » : parmi toutes les droites possibles, celle-ci minimise $\sum_i (y_i - \hat{y}_i)^2$, la somme des carrés des résidus.

COEFFICIENT DE DÉTERMINATION R^2

$$R^2 = 1 - (SS_{\text{rés}} / SS_{\text{tot}}) = 1 - [\sum_i (y_i - \hat{y}_i)^2 / \sum_i (y_i - \bar{y})^2]$$

R^2 mesure la part de variance de y expliquée par le modèle, entre 0 (le modèle n'explique rien) et 1 (ajustement parfait). Pour une régression linéaire simple à une seule variable explicative, R^2 est exactement égal au carré du coefficient de Pearson ($R^2 = r^2$) — ce qui cesse d'être vrai dès qu'on passe à plusieurs variables explicatives (section suivante).

EXEMPLE

EXEMPLE CHIFFRÉ

Une régression de la teneur en matière organique du sol (y, en %) sur l'altitude (x, en m) donne $b_1 = 0,004$: chaque mètre d'altitude supplémentaire est associé, en moyenne dans cet échantillon, à 0,004 point de matière organique en plus. Avec $R^2 = 0,62$, l'altitude seule explique 62 % de la variance observée de la teneur en matière organique entre les parcelles étudiées — les 38 % restants relèvent d'autres facteurs non inclus dans ce modèle simple (exposition, type de sol, usage agricole...).

7. RÉGRESSION LINÉAIRE MULTIPLE

La régression linéaire multiple étend la régression simple à plusieurs variables explicatives à la fois, pour estimer l'effet propre de chacune une fois les autres prises en compte.

MODÈLE DE RÉGRESSION LINÉAIRE MULTIPLE

$$\hat{y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Chaque coefficient β_j s'interprète « toutes choses égales par ailleurs » : l'effet estimé d'une augmentation d'une unité de X_j sur y , en maintenant fixes toutes les autres variables explicatives du modèle — une interprétation qui n'a de sens que si les variables explicatives ne sont pas elles-mêmes trop corrélées entre elles.

ATTENTION

MULTICOLINÉARITÉ : QUAND LES VARIABLES EXPLICATIVES SE RECOUPENT

Si deux variables explicatives sont elles-mêmes fortement corrélées (par exemple la température moyenne annuelle et l'altitude), le modèle ne parvient plus à distinguer clairement l'effet propre de chacune : les coefficients estimés deviennent instables, parfois de signe contre-intuitif, et leur erreur standard gonfle artificiellement — sans que la qualité prédictive globale du modèle (R^2) s'en trouve nécessairement dégradée.

FACTEUR D'INFLATION DE LA VARIANCE (VIF)

$$VIF_j = 1 / (1 - R_j^2)$$

R_j^2 est le R^2 obtenu en régressant la variable explicative X_j sur toutes les autres variables explicatives du modèle (pas sur y). Un VIF_j élevé (au-delà de 5, parfois 10 selon les conventions du domaine) signale que X_j est en grande partie redondante avec les autres variables explicatives déjà présentes dans le modèle.

VOIR AUSSI : ALLER PLUS LOIN : LA RÉGRESSION SPATIALE

Quand les observations sont géographiques, les résidus d'une régression classique (OLS) sont souvent eux-mêmes autocorrélés dans l'espace — le module Les Statistiques présente la régression spatiale (et la GWR) qui corrige ce problème, ignoré ici volontairement puisqu'il est propre aux données spatiales.

8. RÉGRESSION LOGISTIQUE : PRÉDIRE UNE VARIABLE BINAIRE

Quand la variable à expliquer n'est plus numérique continue mais binaire (oui/non, présence/absence, inondé/non inondé), une régression linéaire classique n'est plus adaptée : rien n'empêche une droite de prédire des valeurs négatives ou supérieures à 1, dépourvues de sens pour une probabilité. La régression logistique modélise à la place la probabilité de l'événement par une courbe en S bornée entre 0 et 1.

FONCTION LOGISTIQUE

$$p = 1 / (1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}) \Leftrightarrow \ln(p / (1-p)) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

p est la probabilité prédite de l'événement (entre 0 et 1). Le membre de droite de la seconde écriture — la combinaison linéaire des variables explicatives — prédit non pas p directement mais le logarithme de la cote (log-odds) de l'événement, $\ln(p/(1-p))$, qui lui peut prendre n'importe quelle valeur réelle.

ODDS RATIO (RAPPORT DE COTES)

$$OR = e^{\beta_j}$$

L'odds ratio associé à une variable X_j s'obtient en prenant l'exponentielle de son coefficient. Un OR de 2 signifie que la cote de l'événement est multipliée par 2 pour chaque augmentation d'une unité de X_j (toutes choses égales par ailleurs) ; un OR de 1 signifie aucun effet ; un OR entre 0 et 1 signifie un effet protecteur (qui réduit la cote de l'événement).

REMARQUE

ÉVALUER UN MODÈLE DE CLASSIFICATION : COURBE ROC ET AUC

Une régression logistique produit une probabilité, pas directement une décision — il faut fixer un seuil (souvent 0,5 par défaut) pour convertir p en une prédiction « oui/non ». La courbe ROC trace, pour tous les seuils possibles, le taux de vrais positifs contre le taux de faux positifs ; l'aire sous cette courbe (AUC) résume la capacité du modèle à distinguer les deux classes indépendamment du seuil choisi, de 0,5 (pas mieux que le hasard) à 1 (séparation parfaite). L'évaluation détaillée d'une classification à partir d'une matrice de confusion (précision, rappel, F1-score, coefficient kappa) est traitée en profondeur dans le module L'Intelligence à propos des classifications satellites — la même logique statistique s'applique ici à une prédiction binaire tabulaire plutôt qu'à un pixel.

VOIR AUSSI : VOIR EN DÉTAIL : MATRICE DE CONFUSION, PRÉCISION, RAPPEL, KAPPA

Le module L'Intelligence détaille l'évaluation d'une classification (matrice de confusion, kappa de Cohen) — les mêmes outils qui complètent une courbe ROC/AUC ici.

COMPARER DEUX PROTOCOLES DE MESURE DE TERRAIN

Deux équipes mesurent la hauteur de la canopée sur les mêmes 15 placettes forestières, l'une au télémètre laser, l'autre par photo-interprétation d'un nuage de points LiDAR. Décris, étape par étape, la démarche statistique complète que tu mettrais en œuvre pour juger si les deux protocoles donnent des mesures significativement différentes : quel test choisir (et pourquoi, notamment le choix apparié/indépendant), quelles conditions d'application vérifier avant de l'appliquer, comment interpréter une p-value obtenue, et ce que tu ferais si le test ne montre aucune différence significative.

- Le choix du t-test apparié est justifié explicitement par le fait que les mêmes placettes sont mesurées par les deux protocoles
- Au moins une condition d'application est vérifiée avant le test (normalité des différences, absence de valeur aberrante)
- L'interprétation de la p-value évite la formulation incorrecte « la probabilité que H_0 soit vraie »
- La réponse distingue explicitement absence de preuve d'un effet et preuve de l'absence d'effet, en mentionnant la puissance du test

- Bilan — à retenir : l'erreur standard ($s/\sqrt{n}$) mesure la variabilité d'échantillonnage, l'intervalle de confiance en découle ; un test d'hypothèse compare la p-value au seuil α , jamais l'inverse d'une preuve ; erreur de type I (faux positif, α) et de type II (faux négatif, β) s'opposent, la puissance ($1-\beta$) est leur miroir ; t-test (deux moyennes), χ^2 (variables qualitatives) et ANOVA (plus de deux groupes) répondent chacun à une structure de données différente ; $R^2 = r^2$ seulement en régression simple ; le VIF détecte la multicollinéarité en régression multiple ; la régression logistique prédit une probabilité via la fonction logistique, l'odds ratio en résume l'effet.

VOIR AUSSI : PRATIQUER : VALIDATION STATISTIQUE EN CONDITIONS RÉELLES

L'Atelier applique ces tests à des données géographiques réelles (comparaison de mesures, validation de classification), du protocole à l'interprétation.