

DU HASARD ET DE LA PREUVE

Les Tricheurs du Caravage lisent et manipulent le hasard aux cartes ; l'analyse statistique fait, avec rigueur plutôt qu'avec tromperie, ce que ces joueurs pressentaient déjà : le hasard obéit à des lois qu'on peut mesurer.



FIG. VIII. LE CARAVAGE, « LES TRICHEURS »,
VERS 1594

Statistique descriptive et inférentielle, tests d'hypothèse, corrélation et régression, analyse multivariée, apprentissage statistique : un très grand nombre de méthodes, en trois parcours de niveau.

SOMMAIRE

1. STATISTIQUE DESCRIPTIVE : MOYENNE, MÉDIANE, MODE

2. MESURES DE DISPERSION : ÉTENDUE, QUARTILES, ÉCART-TYPE, BOÎTE À MOUSTACHES

3. REPRÉSENTER UNE DISTRIBUTION : HISTOGRAMME, EFFECTIFS ET FRÉQUENCES

4. PROBABILITÉS DE BASE : ÉVÉNEMENT, PROBABILITÉ SIMPLE, INDÉPENDANCE, ARBRE DE PROBABILITÉ

5. LA LOI NORMALE (INTUITION) : LA COURBE EN CLOCHE

6. CORRÉLATION SIMPLE : NUAGE DE POINTS, CORRÉLATION N'EST PAS CAUSALITÉ

Dans *Les Tricheurs du Caravage*, un jeune joueur de cartes crédule affronte deux complices : l'un lit son jeu par-dessus son épaule, l'autre lui signale du bout des doigts, dans son dos, les cartes à jouer. Le tableau pose une question qui a une histoire précise en mathématiques : une série de pertes répétées relève-t-elle du hasard, ou d'un biais caché ? C'est exactement le problème que le chevalier de Méré soumit à Blaise Pascal en 1654 à propos d'une partie de dés interrompue avant son terme (le « problème des partis ») — la correspondance que Pascal échangea alors avec Pierre de Fermat pour le résoudre est reconnue comme l'acte de naissance du calcul des probabilités. Ce module part de cette même question — un résultat observé est-il dû au hasard, à une vraie régularité, ou à un

biais de mesure ou d'échantillonnage — pour construire la boîte à outils statistique générale qui soutient tout le reste du site : les indicateurs spatiaux du module Les Statistiques, la matrice de confusion et le kappa d'une classification satellite (module L'Intelligence), les scripts d'analyse du module R. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

LYCÉE

1. STATISTIQUE DESCRIPTIVE : MOYENNE, MÉDIANE, MODE

Résumer une série de nombreuses valeurs par un seul chiffre représentatif est le premier geste de toute analyse statistique. Trois indicateurs de tendance centrale existent, et ils ne répondent pas exactement à la même question.

INDICATEUR	DÉFINITION	QUAND L'UTILISER
Moyenne	Somme des valeurs divisée par leur nombre	Série numérique sans valeur extrême qui déforme le résultat
Médiane	Valeur qui partage la série triée en deux effectifs égaux	Série avec des valeurs extrêmes (salaires, prix immobiliers) : plus robuste que la moyenne
Mode	Valeur (ou catégorie) la plus fréquente	Variable qualitative, ou pour repérer le sommet d'une distribution

MOYENNE ARITHMÉTIQUE

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

$\bar{x}$ (« x barre ») désigne la moyenne d'un échantillon de n valeurs. Pour trouver la médiane, il n'y a pas de formule : on trie la série puis on prend la valeur centrale (ou la moyenne des deux valeurs centrales si n est pair).

ATTENTION

LA MOYENNE EST SENSIBLE AUX VALEURS EXTRÊMES

Sur neuf communes dont le revenu médian par foyer tourne autour de 22 000 €, une dixième commune très riche à 400 000 € fait grimper la moyenne du groupe bien au-dessus de ce que vivent neuf communes sur dix — alors que la médiane, elle, reste proche de 22 000 €. Une seule valeur extrême suffit à rendre la moyenne trompeuse ; c'est pour cela que les revenus, les prix de l'immobilier ou les notes d'un examen très hétérogène se résument plus honnêtement par une médiane.

EXEMPLE

EXEMPLE CHIFFRÉ

Relevé de température à 8h sur sept jours (en °C) : 12, 13, 12, 14, 11, 13, 38 (un capteur défaillant le 7^e jour). Moyenne = $(12+13+12+14+11+13+38)/7 \approx 16,1$ °C : un chiffre qui ne décrit aucune journée réelle. Médiane (série triée 11, 12, 12, 13, 13, 14, 38) = 13 °C : bien plus représentative des six journées normales. Mode = 12 et 13 (deux valeurs à égalité, série bimodale).

LYCÉE

2. MESURES DE DISPERSION : ÉTENDUE, QUARTILES, ÉCART-TYPE, BOÎTE À MOUSTACHES

Deux séries peuvent avoir exactement la même moyenne tout en étant très différentes : l'une resserrée autour de cette moyenne, l'autre étalée sur un grand intervalle. Les mesures de dispersion complètent la tendance centrale en décrivant cet étalement.

BRIQUE – ÉTENDUE, QUARTILES ET ÉCART-TYPE

- Étendue : différence entre la plus grande et la plus petite valeur de la série — la mesure de dispersion la plus simple, mais très sensible à une seule valeur aberrante
- Quartiles (Q1, Q2, Q3) : les trois valeurs qui découpent la série triée en quatre groupes de même effectif ; Q2 est la médiane
- Écart interquartile (EIQ = Q3 – Q1) : étendue des 50 % de valeurs centrales, insensible aux valeurs extrêmes contrairement à l'étendue totale
- Écart-type (σ) : mesure la distance moyenne de chaque valeur à la moyenne — plus il est grand, plus la série est dispersée autour de $\bar{x}$

ÉCART-TYPE D'UNE SÉRIE

$$\sigma = \sqrt{\left(\frac{1}{n} \right) \cdot \sum_i (x_i - \bar{x})^2}$$

On calcule l'écart de chaque valeur à la moyenne, on l'élève au carré (pour que les écarts positifs et négatifs ne s'annulent pas), on fait la moyenne de ces carrés (la variance, σ^2), puis on prend la racine carrée pour revenir à l'unité de départ.

EXEMPLE

LIRE UNE BOÎTE À MOUSTACHES (BOX PLOT)

Une boîte à moustaches résume une série en cinq valeurs : le minimum, Q1, la médiane, Q3, le maximum. La boîte centrale va de Q1 à Q3 (elle contient donc 50 % des valeurs) et une barre marque la médiane à l'intérieur ; les « moustaches » s'étendent jusqu'au minimum et au maximum, sauf si des points sont isolés au-delà de $1,5 \times \text{EIQ}$ au-delà de Q1 ou Q3 — ces points isolés, affichés séparément, signalent des valeurs potentiellement aberrantes plutôt qu'inclus dans la moustache.

REMARQUE

COMPARER DEUX SÉRIES D'UN COUP D'ŒIL

L'intérêt principal d'une boîte à moustaches est de comparer plusieurs séries côte à côte sur un même graphique (par exemple la température relevée dans cinq villes) : une boîte étroite et haute indique un groupe resserré autour d'une valeur élevée, une boîte large indique un groupe très dispersé — une lecture immédiate qu'un simple tableau de chiffres ne donne pas.

3. REPRÉSENTER UNE DISTRIBUTION : HISTOGRAMME, EFFECTIFS ET FRÉQUENCES

Une fois les données résumées par quelques chiffres, encore faut-il pouvoir en visualiser toute la forme : c'est le rôle d'un graphique de distribution.

TERME	DÉFINITION
Effectif	Nombre brut d'observations dans une classe ou une catégorie (ex. 12 communes ont une population entre 500 et 1000 habitants)
Fréquence	Effectif divisé par l'effectif total, souvent exprimé en % — permet de comparer deux séries d'effectifs totaux différents
Classe	Intervalle de valeurs (pour une variable numérique continue) regroupées ensemble avant de compter l'effectif

ATTENTION

HISTOGRAMME OU DIAGRAMME EN BARRES ?

Un histogramme représente une variable numérique continue découpée en classes : les barres sont jointives, car les classes se succèdent sans interruption sur l'axe. Un diagramme en barres représente une variable qualitative (catégories) ou discrète : les barres sont séparées par un espace, car il n'y a pas de continuité entre « forêt », « champ » et « zone urbaine ». Confondre les deux (barres jointives pour des catégories, par exemple) laisse croire à une continuité qui n'existe pas.

REMARQUE

LE CHOIX DE LA LARGEUR DES CLASSES N'EST PAS NEUTRE

Des classes trop larges lissent excessivement la distribution et peuvent masquer plusieurs pics réels (une distribution bimodale devient un seul bloc) ; des classes trop étroites font apparaître un bruit d'échantillonnage qui n'a rien d'une vraie structure. Il n'existe pas de largeur « juste » universelle : on ajuste en fonction de la taille de l'échantillon et on vérifie que la forme obtenue reste stable si on modifie légèrement le découpage.

LYCÉE

4. PROBABILITÉS DE BASE : ÉVÉNEMENT, PROBABILITÉ SIMPLE, INDÉPENDANCE, ARBRE DE PROBABILITÉ

Une expérience aléatoire (lancer un dé, tirer une carte) produit une issue parmi plusieurs possibles. Un événement est un ensemble d'issues qui nous intéresse (par exemple « obtenir un nombre pair »).

PROBABILITÉ D'UN ÉVÉNEMENT (CAS D'ÉQUIPROBABILITÉ)

$P(A) = (\text{nombre de cas favorables à } A) / (\text{nombre de cas possibles})$

Valable uniquement quand toutes les issues ont la même chance de se produire (dé non pipé, jeu de cartes non truqué — l'inverse, précisément, de ce que font les complices du tableau de Caravage). $P(A)$ est toujours compris entre 0 (impossible) et 1 (certain).

- Événement contraire (non A) : $P(\text{non } A) = 1 - P(A)$
- Deux événements sont indépendants quand la réalisation de l'un ne change rien à la probabilité de l'autre (tirer à pile ou face deux fois de suite : le premier résultat n'influence pas le second)
- Un arbre de probabilité représente chaque étape d'une expérience par des branches, chacune étiquetée par sa probabilité ; la probabilité d'un chemin complet (une issue précise) s'obtient en multipliant les probabilités le long des branches parcourues

ÉVÉNEMENTS INDÉPENDANTS

$$P(A \cap B) = P(A) \times P(B)$$

« $\cap$ » se lit « et » : $P(A \cap B)$ est la probabilité que A et B se produisent tous les deux. Cette formule de multiplication n'est valable que si A et B sont indépendants — sinon il faut tenir compte de l'influence de l'un sur l'autre (probabilité conditionnelle, vue en détail piste Licence/BUT et au-delà).

EXEMPLE

EXEMPLE CHIFFRÉ : DEUX TIRAGES DANS UN JEU DE CARTES

On tire une carte, on la remet dans le jeu, on mélange, puis on en tire une seconde (tirage « avec remise », donc indépendant). $P(\text{as au 1}^{\text{er}} \text{ tirage}) = 4/32 = 0,125$. $P(\text{as au 2}^{\text{e}} \text{ tirage}) = 4/32 = 0,125$, exactement la même probabilité puisque le jeu est reconstitué à l'identique. $P(\text{as puis as}) = 0,125 \times 0,125 \approx 0,016$, soit un peu plus d'une chance sur soixante. Sans remise, en revanche, les deux tirages ne seraient plus indépendants : le second dépendrait de ce qui a été retiré au premier.

LYCÉE

5. LA LOI NORMALE (INTUITION) : LA COURBE EN CLOCHE

De très nombreux phénomènes mesurés dans la nature ou la société (une taille, une erreur de mesure, un score à un test) se répartissent selon une courbe en cloche, symétrique autour d'une valeur centrale : c'est la loi normale. La plupart des valeurs se regroupent près de la moyenne, et de moins en moins de valeurs se trouvent à mesure qu'on s'en éloigne, de façon symétrique des deux côtés.

REMARQUE

LA RÈGLE EMPIRIQUE 68-95-99,7 %

Pour une distribution qui suit une loi normale : environ 68 % des valeurs se trouvent à moins d'un écart-type de la moyenne (entre $\bar{x} - \sigma$ et $\bar{x} + \sigma$), environ 95 % à moins de deux écarts-types, et environ 99,7 % à moins de trois écarts-types. Une valeur au-delà de deux écarts-types de la moyenne est donc déjà assez rare (moins de 5 % des cas) ; au-delà de trois, exceptionnelle.

EXEMPLE

EXEMPLE CHIFFRÉ

Si la taille moyenne d'une classe d'élèves est $\bar{x} = 170$ cm avec un écart-type $\sigma = 8$ cm, la règle 68-95-99,7 % indique qu'environ 68 % des élèves mesurent entre 162 et 178 cm, environ 95 % entre 154 et 186 cm. Un élève mesurant 195 cm (plus de trois écarts-types au-dessus de la moyenne) est donc statistiquement rare dans ce groupe.

LYCÉE

6. CORRÉLATION SIMPLE : NUAGE DE POINTS, CORRÉLATION N'EST PAS CAUSALITÉ

Un nuage de points place chaque individu (chaque commune, chaque élève, chaque parcelle) selon deux variables numériques, une en abscisse et une en ordonnée. La forme générale du nuage renseigne sur une éventuelle relation entre les deux variables, résumée par le coefficient de corrélation (noté r), compris entre -1 et $+1$ — sa formule complète est vue en détail piste Licence/BUT.

VALEUR DE R	LECTURE DU NUAGE DE POINTS
r proche de +1	Points alignés le long d'une droite montante : quand une variable augmente, l'autre augmente aussi
r proche de -1	Points alignés le long d'une droite descendante : quand une variable augmente, l'autre diminue
r proche de 0	Nuage sans forme linéaire nette : les deux variables ne semblent pas liées linéairement

ATTENTION

CORRÉLATION N'EST PAS CAUSALITÉ

Observer que deux variables évoluent ensemble ne prouve jamais que l'une cause l'autre. Le nombre de noyades et les ventes de glaces sont fortement corrélés d'un mois à l'autre — non parce que manger une glace ferait se noyer, mais parce qu'une troisième variable, la chaleur estivale, augmente les deux en même temps. Cette variable cachée s'appelle un facteur de confusion : avant de parler de cause, il faut toujours se demander si un facteur de confusion plausible n'explique pas à lui seul la corrélation observée.

À TOI DE VOIR

À TOI DE VOIR

Une commune où le nombre de panneaux publicitaires est élevé a aussi, en moyenne, un taux de pollution de l'air plus élevé. Peut-on en conclure que les panneaux publicitaires polluent l'air ? Quelle troisième variable pourrait expliquer cette corrélation sans lien de cause à effet direct entre les deux ?

DEVOIR À RENDRE : CALCUL ET GRAPHIQUE À LA MAIN

ANALYSER UN RELEVÉ DE TERRAIN

Voici les relevés de précipitations (en mm) enregistrés sur dix jours consécutifs par une station météo : 2, 0, 0, 15, 3, 1, 0, 42, 4, 2. Calcule la moyenne, la médiane, le mode (s'il existe), l'étendue, Q1 et Q3, puis construis à la main une boîte à moustaches de cette série. Termine par une phrase qui explique laquelle de la moyenne ou de la médiane décrit le mieux une journée « typique » de cette série, et pourquoi.

- La moyenne et la médiane sont toutes deux calculées correctement (moyenne $\approx 6,9$ mm, médiane = 2 mm)
- Q1 et Q3 sont identifiés sur la série triée, pas sur la série dans l'ordre de collecte
- La boîte à moustaches place correctement les cinq valeurs clés (min, Q1, médiane, Q3, max) et signale la valeur de 42 mm comme potentiellement aberrante
- La conclusion identifie explicitement que la valeur de 42 mm (un jour de forte pluie isolé) tire la moyenne vers le haut sans être représentative des autres jours

- Bilan — à retenir : moyenne, médiane et mode répondent à des questions différentes, et la médiane résiste mieux aux valeurs extrêmes ; étendue, quartiles et écart-type mesurent la dispersion, la boîte à moustaches les résume visuellement ; un histogramme (barres jointives) décrit une variable continue, un diagramme en barres (barres séparées) une variable qualitative ; $P(A)$ = cas favorables / cas possibles, et $P(A \cap B) = P(A) \times P(B)$ seulement si A et B sont indépendants ; la règle 68-95-99,7 % décrit la loi normale ; un nuage de points et un coefficient r décrivent une corrélation, jamais une causalité à eux seuls.

VOIR AUSSI : PRATIQUER : LIRE DES INDICES SPECTRAUX COMME UNE DISTRIBUTION

L'Atelier calcule NDVI, NDMI et NDBI par cellule : moyenne, dispersion et histogramme s'y appliquent directement à des indices géographiques réels.