

DU HASARD ET DE LA PREUVE

Les Tricheurs du Caravage lisent et manipulent le hasard aux cartes ; l'analyse statistique fait, avec rigueur plutôt qu'avec tromperie, ce que ces joueurs pressentaient déjà : le hasard obéit à des lois qu'on peut mesurer.



FIG. VIII. LE CARAVAGE, « LES TRICHEURS »,
VERS 1594

Statistique descriptive et inférentielle, tests d'hypothèse, corrélation et régression, analyse multivariée, apprentissage statistique : un très grand nombre de méthodes, en trois parcours de niveau.

SOMMAIRE

1. ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

2. ANALYSE FACTORIELLE DES CORRESPONDANCES (AFC) ET ANALYSE DES CORRESPONDANCES MULTIPLES (ACM)

3. CLASSIFICATION NON SUPERVISÉE : K-MEANS ET CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH)

4. ARBRES DE DÉCISION ET FORÊTS ALÉATOIRES (RANDOM FOREST)

5. VALIDATION CROISÉE ET SURAPPRENTISSAGE

6. SÉRIES TEMPORELLES : AUTOCORRÉLATION, ARIMA, DÉCOMPOSITION

7. BOOTSTRAP ET MÉTHODES DE RÉÉCHANTILLONNAGE

8. CHOISIR LE BON TEST : UNE SYNTHÈSE

Dans Les Tricheurs du Caravage, un jeune joueur de cartes crédule affronte deux complices : l'un lit son jeu par-dessus son épaule, l'autre lui signale du bout des doigts, dans son dos, les cartes à jouer. Le tableau pose une question qui a une histoire précise en mathématiques : une série de pertes répétées relève-t-elle du hasard, ou d'un biais caché ?

C'est exactement le problème que le chevalier de Méré soumit à Blaise Pascal en 1654 à propos d'une partie de dés interrompue avant son terme (le « problème des partis ») — la correspondance que Pascal échangea alors avec Pierre de Fermat pour le résoudre est reconnue comme l'acte de naissance du calcul des probabilités. Ce module part de cette même question — un résultat observé est-il dû au hasard, à une vraie régularité, ou à un biais de mesure ou d'échantillonnage — pour construire la boîte à outils statistique générale qui soutient tout le reste du site : les indicateurs spatiaux du module Les Statistiques, la matrice de confusion et le kappa d'une classification satellite (module L'Intelligence), les scripts d'analyse du module R. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

APPROFONDISSEMENT

1. ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

Face à un tableau de données avec de nombreuses variables numériques corrélées entre elles (par exemple une dizaine d'indicateurs socio-économiques mesurés par commune), l'analyse en composantes principales construit un nouveau jeu de variables — les composantes principales — non corrélées entre elles, ordonnées par la quantité de variance du jeu de données original qu'elles résument, ce qui permet de réduire drastiquement le nombre de dimensions à examiner tout en conservant l'essentiel de l'information.

DÉCOMPOSITION EN VALEURS PROPRES DE LA MATRICE DE COVARIANCE

$$C \cdot v = \lambda \cdot v$$

C est la matrice de covariance (ou de corrélation, si les variables sont standardisées au préalable) des variables d'origine. Chaque vecteur propre v définit la direction d'une composante principale dans l'espace des variables d'origine ; la valeur propre λ associée mesure la quantité de variance du jeu de données capturée par cette direction. Les composantes sont ordonnées par valeur propre décroissante : la première composante (PC1) capture le plus de variance, la seconde (PC2, orthogonale à PC1) la plus grande part de ce qui reste, et ainsi de suite.

PART DE VARIANCE EXPLIQUÉE PAR UNE COMPOSANTE

$$\text{Variance expliquée par PC}_i = \lambda_i / \sum_j \lambda_j$$

Le cumul des parts de variance expliquée des premières composantes indique combien de dimensions retenir : conserver par exemple les deux ou trois premières composantes si elles cumulent déjà 80 % de la variance totale du jeu de données original.

- Cercle des corrélations : représente chaque variable d'origine par une flèche dans le plan des deux premières composantes ; deux variables dont les flèches pointent dans la même direction sont corrélées positivement dans le jeu de données, deux flèches perpendiculaires sont peu corrélées
- Les variables doivent en général être standardisées (centrées-réduites) avant l'ACP si elles ne sont pas dans la même unité, sans quoi une variable à grande échelle numérique (un revenu en euros) dominerait artificiellement une variable à petite échelle (un taux en %) dans le calcul de la variance

EXEMPLE

EXEMPLE CONCRET

Une ACP sur dix indicateurs communaux (revenu médian, taux de chômage, part de logements sociaux, densité, distance au centre-ville...) révèle typiquement que les deux ou trois premières composantes suffisent à résumer 70-80 % de la variance totale : la première oppose souvent des communes aisées et denses à des communes plus modestes et périphériques, résumant à elle seule plusieurs variables corrélées entre elles en un seul axe interprétable.

2. ANALYSE FACTORIELLE DES CORRESPONDANCES (AFC) ET ANALYSE DES CORRESPONDANCES MULTIPLES (ACM)

L'ACP réduit la dimension d'un tableau de variables numériques ; l'AFC et l'ACM en sont l'équivalent conceptuel pour des données qualitatives (catégorielles), en s'appuyant sur la même logique de décomposition en valeurs propres, mais appliquée à un tableau de comptages plutôt qu'à une matrice de covariance.

AFC (ANALYSE FACTORIELLE DES CORRESPONDANCES)

- S'applique à un tableau de contingence croisant deux variables qualitatives (le même type de tableau qu'un test du χ^2)
- Représente simultanément, sur un même plan, les modalités des deux variables (par exemple types d'occupation du sol $\times$ communes)
- La distance entre deux points du graphique reflète leur profil de répartition similaire, pas une distance géographique

ACM (ANALYSE DES CORRESPONDANCES MULTIPLES)

- Généralise l'AFC à plus de deux variables qualitatives simultanément (via le tableau disjonctif complet ou la matrice de Burt)
- Utile pour résumer une enquête à plusieurs questions à choix multiples en quelques axes de synthèse
- S'interprète comme l'ACP d'un tableau de variables qualitatives plutôt que numériques

REMARQUE

LE LIEN AVEC LE TEST DU χ^2

L'AFC part du même écart entre effectifs observés et effectifs attendus sous indépendance que le test du χ^2 (piste Licence/BUT) — mais là où le χ^2 se contente d'une statistique globale résumant si un lien existe, l'AFC décompose et visualise la structure de ce lien : quelles modalités de quelles variables s'associent entre elles, et avec quelle intensité relative.

3. CLASSIFICATION NON SUPERVISÉE : K-MEANS ET CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH)

Regrouper des individus (des communes, des placettes, des relevés) en classes homogènes sans étiquette préalable est un problème de classification non supervisée — la même famille de méthodes que le k-means déjà rencontré, dans le module L'Intelligence, pour regrouper des pixels selon leur signature spectrale ; ici, les mêmes principes s'appliquent à un tableau de données quelconques (des variables socio-économiques, environnementales...), pas seulement à des bandes d'image.

FONCTION OBJECTIF DU K-MEANS

$$J = \sum_k \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

L'algorithme cherche à répartir les individus en k classes $C_1 \dots C_k$ de façon à minimiser la somme des distances au carré entre chaque individu x_i et le centre (centroïde) μ_k de sa classe — un critère purement géométrique dans l'espace des variables retenues, qui suppose que k est fixé à l'avance.

La classification ascendante hiérarchique (CAH) suit une logique différente : elle ne fixe pas k à l'avance. Elle part de chaque individu comme sa propre classe, puis fusionne à chaque étape les deux classes les plus proches, jusqu'à ce que tous les individus soient regroupés en une seule classe — un processus entièrement représenté par un dendrogramme, un arbre qui trace l'historique complet des fusions.

- Méthode de Ward : critère de fusion le plus utilisé en CAH — à chaque étape, fusionne les deux classes dont la réunion augmente le moins la variance totale intra-classe (inertie intra-classe), ce qui produit en général des classes de taille comparable et bien séparées
- Lire un dendrogramme : la hauteur à laquelle deux branches fusionnent indique à quel point les deux classes fusionnées étaient dissemblables ; couper l'arbre horizontalement à une hauteur donnée fixe le nombre final de classes retenues

K-MEANS

- Le nombre de classes k doit être fixé à l'avance

- Rapide, adapté à de très grands volumes de données
- Sensible à l'initialisation des centroïdes, résultat non déterministe d'un lancement à l'autre

CAH (WARD)

- Le nombre de classes se choisit a posteriori en coupant le dendrogramme
- Coûteuse en calcul sur de très grands effectifs (tous les individus comparés deux à deux)
- Déterministe : un même jeu de données produit toujours le même dendrogramme

VOIR AUSSI : REVOIR : K-MEANS SUR UNE IMAGE SATELLITE

Le module L'Intelligence applique le même principe de classification non supervisée aux pixels d'une image (bandes spectrales) plutôt qu'à un tableau de variables tabulaires.

APPROFONDISSEMENT

4. ARBRES DE DÉCISION ET FORÊTS ALÉATOIRES (RANDOM FOREST)

Un arbre de décision prédit une variable (qualitative ou numérique) en posant une succession de questions simples sur les variables explicatives (« altitude > 800 m ? », « pente > 15° ? »), chaque question découpant les données en deux groupes de plus en plus homogènes jusqu'à une feuille terminale qui porte la prédiction finale.

INDICE DE GINI (CRITÈRE DE DÉCOUPAGE LE PLUS COURANT)

$$\text{Gini} = 1 - \sum_i p_i^2$$

p_i est la proportion de la classe i parmi les individus présents dans un nœud de l'arbre. Gini vaut 0 quand le nœud est parfaitement pur (une seule classe présente) et augmente avec le mélange des classes. À chaque étape, l'algorithme choisit la variable et le seuil de découpage qui réduisent le plus l'indice de Gini moyen des deux nœuds enfants par rapport au nœud parent — une alternative équivalente en pratique, l'entropie ($H = -\sum_i p_i \log_2 p_i$), suit la même logique.

Un arbre unique, poussé trop profondément, mémorise facilement les particularités de son échantillon d'entraînement plutôt que la structure générale (surapprentissage, voir section suivante). La forêt aléatoire (Random Forest, Breiman 2001) corrige ce défaut en combinant un grand nombre d'arbres, chacun entraîné sur un tirage aléatoire différent

des données (bootstrap, voir section 7) et n'ayant accès, à chaque découpage, qu'à un sous-ensemble aléatoire des variables explicatives — la prédiction finale résulte d'un vote majoritaire (classification) ou d'une moyenne (régression) sur l'ensemble des arbres.

RÉGRESSION LINÉAIRE CLASSIQUE

- Suppose une relation linéaire entre variables explicatives et variable à prédire
- Coefficients directement interprétables (effet, sens, magnitude)
- Sensible à la multicolinéarité, doit être spécifiée explicitement (termes d'interaction, transformations)

FORÊT ALÉATOIRE

- Capture nativement des relations non linéaires et des interactions entre variables, sans les spécifier à la main
- Robuste aux valeurs aberrantes et aux variables corrélées entre elles
- Moins directement interprétable (boîte plus opaque), compensée par l'importance des variables

REMARQUE

IMPORTANCE DES VARIABLES (FEATURE IMPORTANCE)

Une forêt aléatoire fournit, pour chaque variable explicative, un score d'importance — le plus courant mesure de combien l'erreur de prédiction du modèle augmente lorsqu'on mélange aléatoirement les valeurs de cette seule variable (importance par permutation), ou de combien la variable contribue en moyenne à réduire l'indice de Gini sur l'ensemble des arbres. Ce classement des variables ne remplace pas un coefficient de régression interprétable, mais indique quelles variables pèsent le plus dans les prédictions du modèle.

APPROFONDISSEMENT

5. VALIDATION CROISÉE ET SURAPPRENTISSAGE

Évaluer un modèle sur les mêmes données qui ont servi à l'entraîner surestime systématiquement sa performance réelle — le module L'Intelligence introduit déjà cette tension à

propos de la classification d'images (train/validation/test) ; la validation croisée en est la version générale, applicable à n'importe quel modèle statistique.

VALIDATION CROISÉE À K BLOCS (K-FOLD CROSS-VALIDATION)

$$CV(k) = (1/k) \cdot \sum_{i=1}^k \text{Erreur}_i$$

Les données sont découpées en k blocs de taille égale. Le modèle est entraîné k fois, à chaque fois sur $k-1$ blocs et évalué sur le bloc restant (jamais vu pendant cet entraînement) ; l'erreur finale retenue est la moyenne des k erreurs obtenues. Une valeur usuelle est $k = 5$ ou $k = 10$ — un compromis entre stabilité de l'estimation (k grand) et coût de calcul (k petit).

DÉCOMPOSITION BIAIS-VARIANCE

$$E[(y - \hat{f}(x))^2] = \text{Biais}[\hat{f}(x)]^2 + \text{Var}[\hat{f}(x)] + \sigma^2$$

L'erreur de prédiction attendue se décompose en trois termes : le biais (l'écart systématique d'un modèle trop simple qui ne peut pas capturer la vraie relation — sous-apprentissage), la variance (la sensibilité d'un modèle trop complexe aux particularités de l'échantillon d'entraînement — surapprentissage), et σ^2 , une erreur irréductible propre au bruit des données elles-mêmes, que même le meilleur modèle possible ne peut éliminer.

ATTENTION

LE COMPROMIS BIAIS-VARIANCE N'A PAS DE SOLUTION UNIQUE

Réduire le biais (un modèle plus complexe, plus flexible) augmente en général la variance, et inversement : il n'existe pas de modèle qui minimise simultanément les deux. La validation croisée sert précisément à choisir, parmi plusieurs modèles ou plusieurs réglages d'un même modèle (profondeur d'un arbre, nombre de variables retenues), celui dont l'erreur estimée sur des données non vues est la plus faible — pas celui qui s'ajuste le mieux à l'échantillon d'entraînement.

APPROFONDISSEMENT

6. SÉRIES TEMPORELLES : AUTOCORRÉLATION, ARIMA, DÉCOMPOSITION

Une série temporelle (une mesure répétée dans le temps : température mensuelle, NDVI d'une parcelle sur plusieurs années) viole une hypothèse centrale des méthodes précédentes — l'indépendance des observations : une valeur à l'instant t dépend en général fortement de la valeur à l'instant $t-1$. Cette dépendance se mesure par l'autocorrélation temporelle.

AUTOCORRÉLATION À UN DÉCALAGE k (ACF)

$$r_k = \frac{\sum_{i=1}^{n-k} (x_i - \bar{x})(x_{i+k} - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

r_k mesure la corrélation d'une série avec elle-même décalée de k pas de temps — une valeur au décalage $k=12$ élevée sur une série mensuelle de NDVI, par exemple, révèle un cycle annuel (une valeur ressemble fortement à celle du même mois l'année précédente).

- Décomposition d'une série temporelle : sépare le signal observé en une tendance (évolution de fond à long terme), une composante saisonnière (motif cyclique qui se répète à intervalle fixe, comme le cycle végétatif annuel) et un résidu (ce qui reste une fois tendance et saisonnalité retirées, l'écart au modèle)
- Cette décomposition est ce qui rend une anomalie détectable : un résidu inhabituellement bas ou haut à une date donnée signale un événement ponctuel (sécheresse, gel tardif, incendie) que la seule tendance de fond masquerait

MODÈLE ARIMA(P, D, Q)

$$X_t' = \phi_1 X_{t-1}' + \dots + \phi_p X_{t-p}' + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

ARIMA combine trois briques : p (ordre autorégressif, AR) — la valeur actuelle dépend linéairement de p valeurs passées X_{t-i}' ; d (ordre de différenciation, I) — la série X_t' est la série d'origine différenciée d fois ($X_t' = X_t - X_{t-1}$ pour $d=1$), une opération qui retire une tendance non stationnaire avant modélisation ; q (ordre de moyenne mobile, MA) — la valeur actuelle dépend aussi linéairement de q erreurs passées ε_{t-j} . Un ARIMA(1,1,1), par exemple, différencie une fois la série puis modélise un terme autorégressif et un terme de moyenne mobile d'ordre 1 chacun.

VOIR AUSSI : VOIR EN PRATIQUE : EARTH TRENDS MODELER ET LES SÉRIES NDVI LONGUES

Le module TerrSet applique cette même mécanique statistique (tendance, décomposition saisonnière, anomalies) à des dizaines d'images NDVI MODIS — ce module en donne la théorie générale, TerrSet l'usage concret en télédétection.

7. BOOTSTRAP ET MÉTHODES DE RÉÉCHANTILLONNAGE

Calculer l'intervalle de confiance d'une statistique (une médiane, un coefficient de régression, un écart-type) suppose souvent, dans les formules classiques vues piste Licence/BUT, une distribution théorique connue — pas toujours réaliste sur un petit échantillon ou une statistique complexe sans formule d'erreur standard établie. Le bootstrap contourne ce problème en estimant la distribution d'échantillonnage directement à partir des données elles-mêmes, sans hypothèse théorique a priori.

INTERVALLE DE CONFIANCE BOOTSTRAP (MÉTHODE DES PERCENTILES)

IC95% = [percentile 2,5 % ; percentile 97,5 %] de la distribution de θ^* sur B réplifications

On tire, avec remise, B échantillons (typiquement $B = 1000$ ou plus) de même taille n que l'échantillon original ; « avec remise » signifie qu'une même observation peut être piochée plusieurs fois dans un même tirage bootstrap, et d'autres pas du tout. On calcule la statistique d'intérêt θ^* (une moyenne, un coefficient...) sur chacun de ces B échantillons, ce qui construit une distribution empirique de θ^* ; ses percentiles 2,5 % et 97,5 % bornent directement un intervalle de confiance à 95 %, sans jamais avoir supposé de forme théorique (normale ou autre) pour cette distribution.

EXEMPLE

À QUOI ÇA SERT CONCRÈTEMENT

L'écart-type d'une médiane, contrairement à celui d'une moyenne, n'a pas de formule simple en fonction de n et de σ . Le bootstrap donne malgré tout un intervalle de confiance pour une médiane (ou pour n'importe quelle statistique, aussi complexe soit-elle) en rééchantillonnant directement les données observées des milliers de fois, sans jamais avoir besoin de dériver une formule d'erreur standard propre à cette statistique.

VOIR AUSSI : PASSER À LA PRATIQUE : BOOTSTRAP ET PERMUTATION EN R

Le module R implémente concrètement le bootstrap et les tests de permutation en quelques lignes (`replicate()`, `sample()`) — ce module en donne la théorie générale, celui-là le code qui l'exécute réellement.

8. CHOISIR LE BON TEST : UNE SYNTHÈSE

Face à un jeu de données réel, la question n'est jamais « quel est le meilleur test statistique » dans l'absolu, mais « quel test correspond au type de mes variables et à la question posée ». Le tableau suivant synthétise les méthodes vues dans les trois pistes de ce module selon ces deux critères.

QUESTION POSÉE	TYPE(S) DE VARIABLE(S)	MÉTHODE(S) APPROPRIÉE(S)
Comparer une moyenne à une valeur de référence	1 variable numérique	t-test à un échantillon
Comparer les moyennes de deux groupes	1 numérique + 1 qualitative à 2 modalités	t-test indépendant (ou apparié si les mêmes individus sont mesurés deux fois)
Comparer les moyennes de trois groupes ou plus	1 numérique + 1 qualitative à k modalités	ANOVA à un facteur, puis test post-hoc (Tukey) si significatif
Tester un lien entre deux variables qualitatives	2 variables qualitatives	Test du χ^2 d'indépendance (ou test exact de Fisher si petits effectifs)
Mesurer/tester un lien linéaire entre deux variables numériques	2 variables numériques	Corrélation de Pearson, régression linéaire simple
Prédire une variable numérique à partir de plusieurs autres	1 numérique à expliquer + plusieurs numériques explicatives	Régression linéaire multiple (vérifier le VIF)
Prédire une variable binaire	1 binaire à expliquer + variables explicatives	Régression logistique (évaluer par ROC/AUC)
Résumer/réduire de nombreuses variables numériques corrélées	Plusieurs variables numériques	ACP
Résumer/réduire de nombreuses variables qualitatives	Plusieurs variables qualitatives	AFC (2 variables) ou ACM (plus de 2)
Regrouper des individus en classes homogènes, sans étiquette	Plusieurs variables numériques	k-means (k fixé à l'avance) ou CAH/Ward (nombre de classes choisi a posteriori)

QUESTION POSÉE	TYPE(S) DE VARIABLE(S)	MÉTHODE(S) APPROPRIÉE(S)
Prédire une variable en captant des relations non linéaires	Variable à expliquer + variables explicatives quelconques	Arbre de décision ou forêt aléatoire
Étudier une mesure répétée dans le temps	1 variable numérique datée	Autocorrélation (ACF), décomposition, ARIMA

REMARQUE

UNE QUESTION À SE POSER AVANT TOUTE AUTRE

Avant même de choisir un test dans ce tableau : les observations sont-elles indépendantes les unes des autres ? Des mesures répétées sur les mêmes individus (piste Licence/BUT, test apparié), une série temporelle (autocorrélation, section 6), ou des données géographiques voisines (autocorrélation spatiale, module Les Statistiques) violent toutes cette hypothèse d'indépendance d'une façon différente — et un test qui l'ignore surestime systématiquement la significativité de ses propres résultats.

CONSTRUIRE UN PIPELINE D'ANALYSE COMPLET

Un jeu de données rassemble, pour 200 parcelles agricoles, une dizaine de variables numériques (rendement, teneur en azote, pH du sol, pluviométrie annuelle, altitude...) et une variable qualitative (type de culture, 4 modalités). Propose un plan d'analyse statistique complet en trois étapes : (1) une étape exploratoire pour résumer et réduire les variables numériques corrélées entre elles, (2) une étape de comparaison du rendement selon le type de culture, (3) une étape de modélisation prédictive du rendement à partir des autres variables numériques, en expliquant comment tu évaluerais honnêtement la qualité de ce modèle prédictif sans le surestimer.

- L'étape 1 propose une ACP (et non une AFC/ACM, puisque les variables citées sont numériques) avec une lecture correcte de la variance expliquée
- L'étape 2 choisit une ANOVA (4 groupes, pas un t-test) et mentionne un test post-hoc en cas de résultat significatif
- L'étape 3 distingue explicitement régression linéaire multiple et forêt aléatoire comme deux options valables, avec au moins un argument de choix entre les deux
- L'évaluation du modèle prédictif s'appuie explicitement sur une validation croisée (k-fold), pas sur l'erreur mesurée sur les données d'entraînement

- Bilan — à retenir : l'ACP réduit des variables numériques corrélées via une décomposition en valeurs propres (variance expliquée = $\lambda_i/\Sigma\lambda$), l'AFC/ACM en sont l'équivalent qualitatif ; k-means (k fixé) et CAH/Ward (dendrogramme, k choisi après coup) regroupent sans étiquette ; un arbre de décision découpe selon l'indice de Gini, une forêt aléatoire combine de nombreux arbres pour réduire la variance et fournit une importance des variables ; la validation croisée (k-fold) estime honnêtement une erreur de généralisation, arbitrée par le compromis biais-variance ; l'autocorrélation temporelle et ARIMA(p,d,q) modélisent une série chronologique, décomposée en tendance/saisonnalité/résidu ; le bootstrap construit un intervalle de confiance empirique par rééchantillonnage avec remise, sans hypothèse théorique a priori ; le bon test dépend toujours du type de variable et du nombre de groupes/variables en jeu, jamais d'une préférence a priori.

VOIR AUSSI : CONTINUER : QUAND L'ESPACE COMPLIQUE TOUT

Le module Les Statistiques reprend plusieurs méthodes de ce module (régression, autocorrélation) dans leur version spatiale : autocorrélation spatiale (Moran, LISA, Gi*), MAUP, régression géographiquement pondérée.

