

DU HASARD ET DE LA PREUVE

Statistique descriptive et inférentielle, tests d'hypothèse, corrélation et régression, analyse multivariée, apprentissage statistique : un très grand nombre de méthodes, en trois parcours de niveau.

INDICATEUR	FORMULE / STATISTIQUE CLÉ	À QUOI ÇA SERT
Moyenne $\bar{x}$	$\Sigma x_i / n$	Tendance centrale, sensible aux valeurs extrêmes
Médiane	Valeur centrale de la série triée	Tendance centrale, robuste aux valeurs extrêmes
Écart-type σ	$\sqrt{[(1/n) \Sigma (x_i - \bar{x})^2]}$	Dispersion autour de la moyenne
Quartiles / EIQ	Q1, médiane, Q3 ; EIQ = Q3-Q1	Dispersion robuste, boîte à moustaches
Loi normale	Règle empirique 68-95-99,7 %	Part des valeurs à 1σ / 2σ / 3σ de la moyenne
Corrélation de Pearson r	$\Sigma (x_i - \bar{x})(y_i - \bar{y}) / [\sqrt{\Sigma (x_i - \bar{x})^2} \cdot \sqrt{\Sigma (y_i - \bar{y})^2}]$	Force et sens d'une relation linéaire, entre -1 et +1
Erreur standard SE	$s / \sqrt{n}$	Variabilité d'échantillonnage d'une moyenne
Intervalle de confiance 95 %	$\bar{x} \pm t(0,025 ; n-1) \cdot SE$	Fourchette plausible pour le paramètre de population
t-test apparié	$t = d / (s_d / \sqrt{n})$	Comparer 2 mesures sur les mêmes individus
t-test indépendant	$t = (\bar{x}_1 - \bar{x}_2) / [s_p \cdot \sqrt{(1/n_1 + 1/n_2)}]$	Comparer les moyennes de 2 groupes distincts
χ^2 (khi-deux)	$\Sigma (O_i - E_i)^2 / E_i$	Indépendance ou ajustement, variables qualitatives
ANOVA (F)	$F = CMB/CMW = [SSB/(k-1)] / [SSW/(N-k)]$	Comparer les moyennes de 3 groupes ou plus
Régression simple	$\hat{y} = b_0 + b_1 x$, $b_1 = \Sigma (x_i - \bar{x})(y_i - \bar{y}) / \Sigma (x_i - \bar{x})^2$	Prédire y à partir d'un seul x (moindres carrés)
R^2	$1 - SS_{rés}/SS_{tot}$	Part de variance de y expliquée (= r^2 en régression simple)

INDICATEUR	FORMULE / STATISTIQUE CLÉ	À QUOI ÇA SERT
Régression multiple	$\hat{y} = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$	Prédire y à partir de plusieurs X, coefficients « toutes choses égales »
VIF	$VIF_j = 1/(1-R_j^2)$	Détecter la multicolinéarité (seuil usuel : 5 ou 10)
Régression logistique	$\ln(p/(1-p)) = \beta_0 + \beta_1 X_1 + \dots$	Prédire une variable binaire (probabilité, log-odds)
Odds ratio	$OR = e^{\beta_j}$	Effet multiplicatif sur la cote de l'événement
ROC / AUC	Aire sous la courbe (taux VP vs taux FP)	Qualité d'un classifieur binaire, indépendamment du seuil
ACP	$C \cdot v = \lambda \cdot v$; variance expliquée = $\lambda_i / \sum \lambda_j$	Réduire des variables numériques corrélées
AFC / ACM	Décomposition d'un tableau de contingence	Équivalent de l'ACP pour des variables qualitatives
k-means	$\min \sum_k \sum_{i \in C_k} \ x_i - \mu_k\ ^2$	Classer en k groupes fixés à l'avance
CAH / Ward	Fusions successives minimisant l'inertie intra	Classer sans fixer k à l'avance (dendrogramme)
Indice de Gini	$1 - \sum p_i^2$	Critère de découpage d'un arbre de décision
Forêt aléatoire	Vote/moyenne sur de nombreux arbres bootstrappés	Prédiction robuste + importance des variables
Validation croisée k-fold	$CV = (1/k) \sum \text{Erreur}_i$	Estimer une erreur de généralisation honnête
Biais-variance	$\text{Erreur} = \text{Biais}^2 + \text{Variance} + \sigma^2$	Arbitrage entre sous- et sur-apprentissage
Autocorrélation (ACF)	$r_k = \sum (x_t - \bar{x})(x_{t+k} - \bar{x}) / \sum (x_t - \bar{x})^2$	Dépendance d'une série temporelle à elle-même

INDICATEUR	FORMULE / STATISTIQUE CLÉ	À QUOI ÇA SERT
ARIMA(p,d,q)	AR(p) + différenciation(d) + MA(q)	Modéliser/prévoir une série temporelle
Bootstrap	Rééchantillonnage avec remise, B réplifications	IC empirique sans hypothèse de distribution

SITUATION	TEST / MÉTHODE
1 numérique, 2 groupes	t-test (apparié ou indépendant)
1 numérique, 3+ groupes	ANOVA + post-hoc (Tukey)
2 qualitatives	χ^2 d'indépendance
2 numériques, lien linéaire	Pearson + régression simple
1 numérique à prédire, plusieurs X numériques	Régression multiple (VIF) ou forêt aléatoire
1 binaire à prédire	Régression logistique (ROC/AUC)
Réduire beaucoup de variables numériques	ACP
Réduire beaucoup de variables qualitatives	AFC / ACM
Grouper sans étiquette	k-means (k connu) ou CAH/Ward (k inconnu)
Donnée datée, répétée dans le temps	ACF, décomposition, ARIMA

ERREUR DE TYPE I

- Rejeter H_0 alors qu'elle est vraie
- Risque = α , fixé avant le test

ERREUR DE TYPE II

- Ne pas rejeter H_0 alors qu'elle est fausse

- Risque = β , lié à la puissance ($1-\beta$)

ATTENTION

PIÈGES CLASSIQUES

Corrélation n'est pas causalité (chercher un facteur de confusion). Une p-value non significative ne prouve pas l'absence d'effet — vérifier la puissance. $R^2 = r^2$ seulement en régression simple. Un VIF élevé signale une multicolinéarité, pas une erreur de calcul. Un F d'ANOVA significatif ne dit pas quels groupes diffèrent : test post-hoc nécessaire. Évaluer un modèle sur ses données d'entraînement surestime toujours sa performance réelle : toujours passer par une validation croisée.

REMARQUE

CROSS-RÉFÉRENCES

Régression spatiale, autocorrélation spatiale (Moran, LISA, G_i^*), MAUP : module Les Statistiques. Matrice de confusion, kappa, k-means sur pixels, biais-variance en deep learning : module L'Intelligence. Bootstrap et permutation en code R : module R. Décomposition tendance/saisonnalité/résidu appliquée au NDVI : module TerrSet (Earth Trends Modeler).