

DU HASARD ET DE LA PREUVE

10 questions — entourer la bonne réponse.

1. POURQUOI LA MÉDIANE EST-ELLE SOUVENT PRÉFÉRÉE À LA MOYENNE POUR RÉSUMER UN REVENU ?

- ☐ A. La médiane est toujours plus simple à calculer que la moyenne
- ☐ B. La médiane est robuste aux valeurs extrêmes, contrairement à la moyenne qu'un très haut revenu isolé peut fortement déplacer
- ☐ C. La moyenne ne peut se calculer que sur un nombre pair de valeurs
- ☐ D. La médiane et la moyenne donnent toujours exactement le même résultat

2. QUE SIGNIFIE LA RÈGLE EMPIRIQUE « 68-95-99,7 % » POUR UNE LOI NORMALE ?

- ☐ A. 68 % des valeurs sont inférieures à la moyenne, 95 % supérieures, 99,7 % égales à la médiane
- ☐ B. Environ 68 %, 95 % et 99,7 % des valeurs se trouvent respectivement à moins de 1, 2 et 3 écarts-types de la moyenne
- ☐ C. Le test statistique est valide à condition d'avoir au moins 68 observations
- ☐ D. 68 % des données sont toujours des valeurs aberrantes à exclure

3. UNE ÉTUDE TROUVE UNE FORTE CORRÉLATION ENTRE LE NOMBRE DE NOYADES ET LES VENTES DE GLACES. QUE PEUT-ON EN CONCLURE ?

- ☐ A. Manger des glaces cause des noyades
- ☐ B. Les noyades causent une hausse des ventes de glaces
- ☐ C. Rien de causal directement : un facteur de confusion (la chaleur estivale) explique probablement les deux à la fois
- ☐ D. La corrélation est nécessairement calculée avec une erreur, puisque le résultat est absurde

4. DANS UN TEST D'HYPOTHÈSE, QUE REPRÉSENTE L'ERREUR DE TYPE I ?

- ☐ A. Ne pas rejeter H_0 alors qu'elle est fausse
- ☐ B. Rejeter H_0 alors qu'elle est en réalité vraie
- ☐ C. Choisir un échantillon trop petit pour le test
- ☐ D. Confondre corrélation et causalité

5. À QUOI SERT LE COEFFICIENT DE DÉTERMINATION R^2 D'UNE RÉGRESSION LINÉAIRE ?

- ☐ A. Il indique le nombre de variables explicatives utilisées dans le modèle
- ☐ B. Il mesure la part de variance de la variable à expliquer effectivement expliquée par le modèle
- ☐ C. Il remplace le test de Student pour comparer deux moyennes
- ☐ D. Il indique toujours si la relation entre les variables est causale

6. UN FACTEUR D'INFLATION DE LA VARIANCE (VIF) ÉLEVÉ POUR UNE VARIABLE D'UNE RÉGRESSION MULTIPLE SIGNALE :

- ☐ A. Que cette variable n'a aucun effet sur la variable à expliquer
- ☐ B. Une forte multicollinéarité : cette variable est fortement corrélée à d'autres variables explicatives du modèle
- ☐ C. Que le modèle contient une erreur de calcul qu'il faut corriger
- ☐ D. Que la variable doit obligatoirement être transformée en variable qualitative

7. QUE FAIT CONCRÈTEMENT L'ANALYSE EN COMPOSANTES PRINCIPALES (ACP) ?

- ☐ A. Elle teste si deux groupes ont des moyennes significativement différentes
- ☐ B. Elle réduit un grand nombre de variables numériques corrélées en un petit nombre de nouvelles variables (composantes) qui résument l'essentiel de la variance
- ☐ C. Elle prédit une variable binaire à partir de plusieurs variables explicatives
- ☐ D. Elle calcule un intervalle de confiance pour une moyenne

8. QUELLE EST LA DIFFÉRENCE ESSENTIELLE ENTRE LE K-MEANS ET LA CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH) ?

- ☐ A. Le k-means ne fonctionne que sur des données qualitatives, la CAH uniquement sur des données numériques
- ☐ B. Le k-means exige de fixer le nombre de groupes k à l'avance, la CAH construit un dendrogramme sans imposer k au départ
- ☐ C. La CAH est toujours plus rapide à calculer que le k-means
- ☐ D. Les deux méthodes produisent systématiquement exactement le même résultat

9. POURQUOI ÉVALUER UN MODÈLE PRÉDICTIF UNIQUEMENT SUR SES DONNÉES D'ENTRAÎNEMENT EST-IL TROMPEUR ?

- ☐ A. Parce que cela surestime systématiquement la performance réelle du modèle sur de nouvelles données (surapprentissage)
- ☐ B. Parce que les données d'entraînement contiennent toujours des erreurs de saisie
- ☐ C. Parce qu'un modèle ne peut techniquement pas être évalué sur les données qui ont servi à l'entraîner
- ☐ D. Parce que cela sous-estime systématiquement la performance réelle du modèle

10. LE BOOTSTRAP (RÉÉCHANTILLONNAGE AVEC REMISE) PERMET NOTAMMENT DE :

- ☐ A. Calculer un intervalle de confiance empirique sans supposer de forme théorique particulière pour la distribution de la statistique
- ☐ B. Remplacer entièrement le besoin de collecter de nouvelles données
- ☐ C. Éliminer automatiquement toute valeur aberrante d'un jeu de données
- ☐ D. Transformer une variable qualitative en variable quantitative