

DE L'ART DU COMPAS

Le géographe de Vermeer prend le compas pour mesurer sa carte. Le SIG est ce même compas, rendu numérique et systématique.



FIG. III. JOHANNES VERMEER, « LE GÉOGRAPHE », 1669

QGIS, analyses spatiales, géostatistique et traitement de données géographiques.

SOMMAIRE

1. PRISE EN MAIN DE QGIS, EN PROFONDEUR

2. LES GRANDES FAMILLES D'ANALYSES SPATIALES

3. REQUÊTES ATTRIBUTAIRES ET SPATIALES

4. LES FONDEMENTS THÉORIQUES DE L'ANALYSE SPATIALE

5. STATISTIQUES DE ZONE ET ALGÈBRE RASTER

6. AUTOMATISATION AVEC PYTHON

7. QUALITÉ DES DONNÉES ET MÉTADONNÉES

Un SIG (Système d'Information Géographique) permet de stocker, visualiser, interroger et analyser des données géographiques. Ce module présente QGIS (le SIG open-source de référence, gratuit et multiplateforme), puis les grandes familles d'analyses spatiales qu'on retrouve dans tout logiciel SIG, les bases théoriques de l'analyse spatiale, les bases de données géographiques, avant d'introduire l'automatisation en Python. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

SUPÉRIEUR

1. PRISE EN MAIN DE QGIS, EN PROFONDEUR

- Panneau des couches (Layers) : liste des données chargées, ordre d'affichage du haut vers le bas
- Vue carte : navigation (zoom/pan), affichage selon le système de coordonnées du projet
- Table attributaire : chaque entité géométrique (point/ligne/polygone) est une ligne, chaque colonne un attribut
- Symbologie : un clic droit sur une couche > Propriétés > Symbologie permet de styliser selon un attribut (couleur par catégorie, dégradé par valeur...)
- Boîte à outils de traitement (Processing Toolbox) : accès à des centaines d'algorithmes d'analyse prêts à l'emploi, dont beaucoup viennent en réalité de GDAL/OGR et SAGA, intégrés à QGIS plutôt que réécrits

REMARQUE

SYSTÈME DE COORDONNÉES DU PROJET

QGIS reprojette à la volée l'affichage des couches, mais tout calcul de distance/surface doit se faire dans un système de coordonnées projeté et métrique (voir module Fondements). Vérifier le CRS du projet (coin bas-droit de la fenêtre) avant tout calcul.

SUPÉRIEUR

2. LES GRANDES FAMILLES D'ANALYSES SPATIALES

OPÉRATION	CE QU'ELLE FAIT	EXEMPLE D'USAGE
Buffer (zone tampon)	Crée un polygone à une distance fixe autour d'une géométrie	Zone de 200 m autour d'un cours d'eau (bande réglementaire)
Intersection	Ne garde que la partie commune entre deux couches	Parcelles agricoles qui recoupent une zone inondable
Union / Dissolve	Fusionne des géométries adjacentes de même valeur	Fusionner des parcelles cadastrales par commune
Différence	Retire d'une couche la partie qui recoupe une seconde couche	Zone constructible = zone urbaine moins zone inondable
Différence symétrique	Garde tout sauf la partie commune entre deux couches	Zones qui ont changé d'usage entre deux dates (ce qui n'est ni dans l'un ni dans l'autre exclusivement)
Jointure spatiale	Associe les attributs d'une couche à une autre selon leur position	Attribuer à chaque bâtiment la commune dans laquelle il se trouve
Clip (découpage)	Découpe une couche selon l'emprise d'une autre	Extraire uniquement les routes situées dans un département




PLANCHE VI. TROIS OPÉRATIONS SPATIALES FONDAMENTALES, VUES COMME DES FIGURES GÉOMÉTRIQUES.

ATTENTION

CES OPÉRATIONS REPOSENT SUR L'ALGÈBRE DES ENSEMBLES

Buffer, intersection, union, différence et différence symétrique sont les cinq opérations classiques de l'algèbre booléenne appliquées à des polygones plutôt qu'à des ensembles abstraits. Comprendre l'une d'elles comme un diagramme de Venn géométrique rend les quatre autres immédiates : c'est la même logique, seule l'opération change.

À TOI DE JOUER

LE SIMULATEUR D'OPÉRATIONS SPATIALES

Deux formes fixes, A et B (en pointillés) : reconnais visuellement le résultat de chaque opération spatiale parmi 4 vignettes.

Exercice interactif, à faire sur la version web du site.

SUPÉRIEUR

3. REQUÊTES ATTRIBUTAIRES ET SPATIALES

Une requête attributaire filtre des entités selon leurs valeurs de champ (ex. : "altitude > 500").

Une requête spatiale filtre selon une relation géométrique avec une autre couche (ex. : "parcelles situées à moins de 500 m d'une route"). QGIS permet de combiner les deux via le générateur d'expressions ou l'outil "Sélection par emplacement".

EXEMPLE D'EXPRESSION QGIS

"altitude" > 500 AND "pente" > 15

Sélectionne les entités dont l'altitude dépasse 500 m ET la pente dépasse 15° : syntaxe du générateur d'expressions QGIS, proche du SQL.

RELATION SPATIALE	SIGNIFICATION
Intersects	Les deux géométries ont au moins un point commun (y compris un simple contact au bord)
Contains / Within	L'une contient entièrement l'autre (relation asymétrique)
Touche	Les géométries se touchent en un point ou une ligne, sans se superposer
Disjoint	Aucun point commun entre les deux géométries
Within distance	Distance entre les deux géométries inférieure à un seuil donné

SUPÉRIEUR

4. LES FONDEMENTS THÉORIQUES DE L'ANALYSE SPATIALE

L'analyse spatiale ne se limite pas à une boîte à outils : elle repose sur des principes formulés en géographie théorique, qui expliquent pourquoi certaines méthodes fonctionnent et où elles peuvent tromper.

REMARQUE

LA PREMIÈRE LOI DE LA GÉOGRAPHIE (TOBLER, 1970)

« Tout est lié à tout le reste, mais les choses proches sont plus liées que les choses distantes. » Formulée par Waldo Tobler, cette proposition justifie l'essentiel des méthodes d'analyse spatiale : l'interpolation (estimer une valeur inconnue à partir des points voisins), le lissage spatial, l'autocorrélation. Sans elle, un buffer ou une jointure spatiale n'aurait aucune justification théorique : ce ne serait qu'un calcul arbitraire.

L'autocorrélation spatiale mesure précisément à quel point cette proximité influence la ressemblance : un indice de Moran (I de Moran, Moran 1950) proche de +1 signale un fort regroupement de valeurs similaires (une maladie qui se propage en tache d'huile, un indice de végétation homogène par massif) ; proche de -1, une alternance de valeurs opposées ; proche de 0, une répartition aléatoire sans structure spatiale.

INDICE DE MORAN I

$$I = (n / S0) \cdot [\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})] / \sum_i (x_i - \bar{x})^2$$

n = nombre d'entités, x_i = valeur de l'entité i , $\bar{x}$ = moyenne de toutes les valeurs, w_{ij} = poids de voisinage entre i et j (souvent 1 si les entités sont adjacentes, 0 sinon), $S0$ = somme de tous les poids w_{ij} . Le numérateur compare chaque paire d'entités voisines à la moyenne globale ; le dénominateur normalise par la variance totale. Le choix de la matrice de poids w_{ij} (contiguïté, distance, k plus proches voisins) n'est pas neutre : deux définitions de voisinage différentes sur la même donnée peuvent donner des I sensiblement différents, à documenter comme tout autre choix méthodologique.

ATTENTION

LE PROBLÈME DU ZONAGE ARBITRAIRE (MAUP)

Le Modifiable Areal Unit Problem, formalisé par Openshaw (1984), montre qu'un même jeu de données peut donner des résultats statistiques très différents selon le découpage administratif ou la maille choisie pour l'agréger (commune, canton, carreau de 1 km). Ce n'est pas une erreur de calcul : c'est une propriété structurelle de toute donnée agrégée spatialement. Toute carte de statistiques par zone (densité par commune, taux par département) doit être lue en gardant ce biais potentiel à l'esprit : changer d'échelle de zonage peut faire apparaître ou disparaître une corrélation.

EXEMPLE

EXEMPLE CHIFFRÉ : LE MAUP EN ACTION

Un taux de criminalité calculé par quartier peut montrer une forte corrélation avec le taux de chômage local ; recalculé sur les mêmes données mais agrégées à l'échelle de la ville entière, la même corrélation peut s'effondrer ou même s'inverser, sans qu'aucune donnée n'ait changé — seul le découpage a changé. C'est cette sensibilité au zonage, pas une erreur de mesure, qu'Openshaw a formalisée.

SUPÉRIEUR

5. STATISTIQUES DE ZONE ET ALGÈBRE RASTER

Sur une donnée raster, deux familles d'opérations complètent les opérations vectorielles vues en section 2 :

- Statistiques de zone (zonal statistics) : calcule une statistique (moyenne, somme, max, écart-type) d'un raster à l'intérieur de chaque polygone d'une couche vectorielle, l'outil qui permet, par exemple, de résumer le NDVI moyen de chaque parcelle plutôt que de garder un indice pixel par pixel
- Algèbre raster (map algebra, calculatrice raster) : combine plusieurs rasters pixel à pixel avec des opérations arithmétiques ou logiques : c'est ainsi que se calcule tout indice spectral ($NDVI = (NIR - Rouge) / (NIR + Rouge)$) directement dans QGIS ou avec GDAL
- Analyse de voisinage (focal statistics, filtre à noyau) : recalcule chaque pixel à partir de son voisinage, détaillée dans le module L'Intelligence, qui la relie aux réseaux de neurones convolutifs

DONNÉE INTERROGÉE EN DIRECT

Cette planche affiche la grille 100 m interactive, consulter la version web du module pour cliquer une cellule.

Planche vivante. Statistiques de zone réelles (résultat de référence de la séance 3 de l'Atelier) : 1122 cellules de 100 m, moyenne NDVI/NDMI/NDBI par cellule.

VOIR AUSSI : VOIR EN PRATIQUE : LA CALCULATRICE RASTER POUR UN NDVI

Le module Les Couleurs utilise directement l'algèbre raster présentée ici pour calculer NDVI, NDMI, NDBI et leurs dérivés.

SUPÉRIEUR

6. AUTOMATISATION AVEC PYTHON

Au-delà de quelques traitements manuels, l'automatisation devient indispensable : traiter des dizaines de fichiers, reproduire un même enchaînement d'analyses sur des données mises à jour régulièrement, ou effectuer des calculs qui n'existent pas nativement dans l'interface. Deux approches complémentaires :

BRIQUE — AUTOMATISER AVEC PYQGIS ET GEOPANDAS

PYQGIS

- API Python intégrée à QGIS
- Accès à la console Python (Extension > Console Python)
- Permet d'automatiser des chaînes de traitements QGIS existants
- Utile pour scripter des exports, styles, ou traitements répétitifs dans QGIS

GEOPANDAS (HORS QGIS)

- Bibliothèque Python autonome, basée sur pandas + Shapely
- Manipulation de données vecteur en dehors de toute interface graphique
- Standard pour les pipelines de traitement de données géographiques en Python
- S'intègre naturellement avec rasterio (raster), matplotlib (cartes rapides)

EXEMPLE GEOPANDAS : CALCUL DE SURFACE

```
gdf['surface_ha'] = gdf.to_crs(epsg=2154).area / 10_000
```

Reprojection en Lambert-93 (EPSG:2154) avant calcul de surface : indispensable, voir la mise en garde du module Fondements sur les coordonnées géographiques.

La console Python de QGIS convient pour un test rapide, mais pas pour un vrai script GeoPandas de plusieurs dizaines de lignes : sans coloration ni autocomplétion fiable, sans

historique de versions, la moindre erreur devient longue à localiser. Visual Studio Code (VS Code), éditeur de code gratuit, comble ce manque : c'est l'environnement de travail réel pour écrire, déboguer et versionner les scripts GeoPandas/PyQGIS présentés ci-dessus, en dehors de toute interface SIG.

- Extension « Python » (Microsoft) : coloration syntaxique, autocomplétion sur les objets GeoPandas (GeoDataFrame, geometry...), détection des erreurs avant même d'exécuter le script
- Extension « Jupyter » : exécuter le script cellule par cellule pour inspecter un GeoDataFrame intermédiaire (gdf.head(), gdf.plot()) sans tout relancer depuis le début
- Terminal intégré : lancer le script (python mon_script.py) sans quitter l'éditeur, dans le même environnement Python que les imports du fichier
- Extension Git (intégrée nativement) : suivre l'évolution d'un script de traitement dans le temps, comme un plan de carte qu'on versionnerait — utile dès qu'un script est repris ou partagé

CONSOLE PYTHON QGIS

- Ouverte en permanence dans QGIS, accès direct aux couches déjà chargées
- Adaptée à un test ponctuel de quelques lignes
- Pas de vrai débogueur, pas de suivi de versions

VS CODE

- Éditeur dédié, en dehors de QGIS
- Adapté à un script GeoPandas complet, réutilisable, versionné
- Point d'arrêt (breakpoint) pour inspecter une variable à l'endroit exact où le calcul dérape, plutôt que d'augmenter les print()

REMARQUE

UN POINT D'ARRÊT VAUT MIEUX QU'UN PRINT()

Poser un point d'arrêt (clic dans la marge à gauche d'une ligne, puis F5 en mode débogage) suspend le script à cet endroit précis et permet d'inspecter le contenu réel de chaque variable — gdf, une géométrie, un CRS — au lieu de deviner où ça casse en semant des print() qu'il faut ensuite retirer un par un.

EXEMPLE

VERS LA PRATIQUE

Le module Travaux pratiques met en œuvre ces outils sur des cas concrets : chargement d'une image Sentinel-2 dans QGIS, calcul de NDVI par calculatrice raster, puis croisement avec une couche vectorielle via une analyse spatiale.

SUPÉRIEUR

7. QUALITÉ DES DONNÉES ET MÉTADONNÉES

Une donnée géographique n'est jamais parfaitement exacte, et ne prétend jamais l'être : ce qui compte, c'est de savoir à quel point elle l'est, et de le documenter pour quiconque la réutilise après vous.

PRÉCISION

- Répétabilité de la mesure : des mesures répétées donnent-elles des résultats proches ?
- Une donnée peut être précise sans être exacte (biais systématique)

EXACTITUDE

- Proximité avec la valeur réelle sur le terrain
- Se vérifie par comparaison à une référence indépendante (relevé GPS de contrôle, orthophoto)

ATTENTION

RÉSOLUTION N'EST PAS PRÉCISION

Un raster à 10 m de résolution spatiale n'est pas nécessairement localisé avec une précision de 10 m : la résolution décrit la taille du pixel, la précision géométrique décrit l'écart entre la position affichée et la position réelle. Les deux notions sont indépendantes et se confondent souvent à tort.

- Les métadonnées documentent la source, la date, le système de coordonnées, la précision estimée et la méthode de production d'une couche

- Sans métadonnées, une donnée téléchargée reste invérifiable : impossible de savoir si elle est encore à jour ou dans quelles conditions elle a été produite
- La norme ISO 19115 encadre la structure des métadonnées géographiques, reprise par la plupart des portails de données ouvertes (dont data.gouv.fr)

EXEMPLE

L'ERREUR QUADRATIQUE MOYENNE (RMSE), LA MESURE STANDARD DE LA PRÉCISION GÉOMÉTRIQUE

Après un géoréférencement (voir module Travaux pratiques, séance 2) ou un contrôle qualité, la précision d'un jeu de données se documente souvent par une RMSE (Root Mean Square Error) : la racine carrée de la moyenne des écarts au carré entre la position mesurée et la position de référence, sur un ensemble de points de contrôle indépendants. Une RMSE de 5 m signifie, en simplifiant, qu'un point typique de la couche est décalé d'environ 5 m par rapport à la réalité terrain — déjà rencontrée dans l'exercice du module Fondements.

- Bilan — à retenir : Tobler justifie théoriquement l'analyse spatiale (proximité = ressemblance) ; Moran quantifie l'autocorrélation, le MAUP rappelle que le découpage n'est jamais neutre ; statistiques de zone (vecteur+raster) et algèbre raster (pixel à pixel) sont les deux ponts entre les deux familles de données ; PyQGIS automatise QGIS, GeoPandas s'en affranchit ; précision $\neq$ exactitude $\neq$ résolution, et une RMSE documente la précision géométrique.

VOIR AUSSI : CONTINUER : LISA, POINTS CHAUDS ET RÉGRESSION SPATIALE

Le module Les Statistiques prolonge Moran et Tobler vers des méthodes locales (LISA, G_i^*) et la régression spatiale.