

DE L'ART DU COMPAS

Le géographe de Vermeer prend le compas pour mesurer sa carte. Le SIG est ce même compas, rendu numérique et systématique.



FIG. IV. JOHANNES VERMEER, « LE GÉOGRAPHE »,
1669

QGIS, analyses spatiales, géostatistique et traitement de données géographiques.

SOMMAIRE

1. PRISE EN MAIN DE QGIS

2. LES GRANDES FAMILLES D'ANALYSES SPATIALES

3. REQUÊTES ATTRIBUTAIRES ET SPATIALES

4. LES FONDEMENTS THÉORIQUES DE L'ANALYSE SPATIALE

5. STATISTIQUES DE ZONE ET ALGÈBRE RASTER

6. AUTOMATISATION AVEC PYTHON

7. BASES DE DONNÉES GÉOGRAPHIQUES : POSTGIS

8. GÉOSTATISTIQUE : INTERPOLER AVEC LE KRIGEAGE

9. ANALYSE RÉSEAU ET DÉCISION MULTICRITÈRE

10. QUALITÉ DES DONNÉES ET MÉTADONNÉES

Un SIG (Système d'Information Géographique) permet de stocker, visualiser, interroger et analyser des données géographiques. Ce module présente QGIS (le SIG open-source de référence, gratuit et multiplateforme), puis les grandes familles d'analyses spatiales qu'on

retrouve dans tout logiciel SIG, les bases théoriques de l'analyse spatiale (autocorrélation, échelle), les bases de données géographiques, avant d'introduire l'automatisation en Python.

1. PRISE EN MAIN DE QGIS

- Panneau des couches (Layers) : liste des données chargées, ordre d'affichage du haut vers le bas
- Vue carte : navigation (zoom/pan), affichage selon le système de coordonnées du projet
- Table attributaire : chaque entité géométrique (point/ligne/polygone) est une ligne, chaque colonne un attribut
- Symbologie : un clic droit sur une couche > Propriétés > Symbologie permet de styliser selon un attribut (couleur par catégorie, dégradé par valeur...)
- Boîte à outils de traitement (Processing Toolbox) : accès à des centaines d'algorithmes d'analyse prêts à l'emploi, dont beaucoup viennent en réalité de GDAL/OGR et SAGA, intégrés à QGIS plutôt que réécrits

REMARQUE

SYSTÈME DE COORDONNÉES DU PROJET

QGIS reprojette à la volée l'affichage des couches, mais tout calcul de distance/surface doit se faire dans un système de coordonnées projeté et métrique (voir module 1). Vérifier le CRS du projet (coin bas-droit de la fenêtre) avant tout calcul.

2. LES GRANDES FAMILLES D'ANALYSES SPATIALES

OPÉRATION	CE QU'ELLE FAIT	EXEMPLE D'USAGE
Buffer (zone tampon)	Crée un polygone à une distance fixe autour d'une géométrie	Zone de 200 m autour d'un cours d'eau (bande réglementaire)
Intersection	Ne garde que la partie commune entre deux couches	Parcelles agricoles qui recoupent une zone inondable
Union / Dissolve	Fusionne des géométries adjacentes de même valeur	Fusionner des parcelles cadastrales par commune
Différence	Retire d'une couche la partie qui recoupe une seconde couche	Zone constructible = zone urbaine moins zone inondable
Différence symétrique	Garde tout sauf la partie commune entre deux couches	Zones qui ont changé d'usage entre deux dates (ce qui n'est ni dans l'un ni dans l'autre exclusivement)
Jointure spatiale	Associe les attributs d'une couche à une autre selon leur position	Attribuer à chaque bâtiment la commune dans laquelle il se trouve
Clip (découpage)	Découpe une couche selon l'emprise d'une autre	Extraire uniquement les routes situées dans un département




PLANCHE VI. TROIS OPÉRATIONS SPATIALES FONDAMENTALES, VUES COMME DES FIGURES GÉOMÉTRIQUES.

ATTENTION

CES OPÉRATIONS REPOSENT SUR L'ALGÈBRE DES ENSEMBLES

Buffer, intersection, union, différence et différence symétrique sont les cinq opérations classiques de l'algèbre booléenne appliquées à des polygones plutôt qu'à des ensembles abstraits. Comprendre l'une d'elles comme un diagramme de Venn géométrique rend les quatre autres immédiates : c'est la même logique, seule l'opération change.

À TOI DE JOUER

LE SIMULATEUR D'OPÉRATIONS SPATIALES

Deux formes fixes, A et B (en pointillés) : reconnais visuellement le résultat de chaque opération spatiale parmi 4 vignettes.

Exercice interactif, à faire sur la version web du site.

Reconnaître le bon résultat parmi des vignettes (jeu ci-dessus) est une chose ; le construire soi-même en est une autre. L'exercice suivant demande de dessiner directement le résultat de l'opération, sommet par sommet, comparé automatiquement au vrai résultat via l'IoU (Intersection over Union — voir aussi module L'Intelligence).

À TOI DE JOUER

Exercice interactif de dessin, à faire sur la version web du site.

3. REQUÊTES ATTRIBUTAIRES ET SPATIALES

Une requête attributaire filtre des entités selon leurs valeurs de champ (ex. : "altitude > 500"). Une requête spatiale filtre selon une relation géométrique avec une autre couche (ex. : "parcelles situées à moins de 500 m d'une route"). QGIS permet de combiner les deux via le générateur d'expressions ou l'outil "Sélection par emplacement".

EXEMPLE D'EXPRESSION QGIS

`"altitude" > 500 AND "pente" > 15`

Sélectionne les entités dont l'altitude dépasse 500 m ET la pente dépasse 15° : syntaxe du générateur d'expressions QGIS, proche du SQL.

RELATION SPATIALE	SIGNIFICATION
Intersects	Les deux géométries ont au moins un point commun (y compris un simple contact au bord)
Contains / Within	L'une contient entièrement l'autre (relation asymétrique)
Touche	Les géométries se touchent en un point ou une ligne, sans se superposer
Disjoint	Aucun point commun entre les deux géométries
Within distance	Distance entre les deux géométries inférieure à un seuil donné

SUPÉRIEUR

4. LES FONDEMENTS THÉORIQUES DE L'ANALYSE SPATIALE

L'analyse spatiale ne se limite pas à une boîte à outils : elle repose sur des principes formulés en géographie théorique, qui expliquent pourquoi certaines méthodes fonctionnent et où elles peuvent tromper.

REMARQUE

LA PREMIÈRE LOI DE LA GÉOGRAPHIE (TOBLER, 1970)

« Tout est lié à tout le reste, mais les choses proches sont plus liées que les choses distantes. » Formulée par Waldo Tobler, cette proposition justifie l'essentiel des méthodes d'analyse spatiale : l'interpolation (estimer une valeur inconnue à partir des points voisins), le lissage spatial, l'autocorrélation. Sans elle, un buffer ou une jointure spatiale n'aurait aucune justification théorique : ce ne serait qu'un calcul arbitraire.

L'autocorrélation spatiale mesure précisément à quel point cette proximité influence la ressemblance : un indice de Moran (I de Moran, Moran 1950) proche de +1 signale un fort regroupement de valeurs similaires (une maladie qui se propage en tache d'huile, un indice de végétation homogène par massif) ; proche de -1, une alternance de valeurs opposées ; proche de 0, une répartition aléatoire sans structure spatiale.

INDICE DE MORAN I

$$I = (n / S0) \cdot [\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})] / \sum_i (x_i - \bar{x})^2$$

n = nombre d'entités, x_i = valeur de l'entité i , $\bar{x}$ = moyenne de toutes les valeurs, w_{ij} = poids de voisinage entre i et j (souvent 1 si les entités sont adjacentes, 0 sinon), $S0$ = somme de tous les poids w_{ij} . Le numérateur compare chaque paire d'entités voisines à la moyenne globale ; le dénominateur normalise par la variance totale. Le choix de la matrice de poids w_{ij} (contiguïté, distance, k plus proches voisins) n'est pas neutre : deux définitions de voisinage différentes sur la même donnée peuvent donner des I sensiblement différents, à documenter comme tout autre choix méthodologique.

ATTENTION

LE PROBLÈME DU ZONAGE ARBITRAIRE (MAUP)

Le Modifiable Areal Unit Problem, formalisé par Openshaw (1984), montre qu'un même jeu de données peut donner des résultats statistiques très différents selon le découpage administratif ou la maille choisie pour l'agréger (commune, canton, carreau de 1 km). Ce n'est pas une erreur de calcul : c'est une propriété structurelle de toute donnée agrégée spatialement. Toute carte de statistiques par zone (densité par commune, taux par département) doit être lue en gardant ce biais potentiel à l'esprit : changer d'échelle de zonage peut faire apparaître ou disparaître une corrélation.

SUPÉRIEUR

5. STATISTIQUES DE ZONE ET ALGÈBRE RASTER

Sur une donnée raster, deux familles d'opérations complètent les opérations vectorielles vues en section 2 :

- Statistiques de zone (zonal statistics) : calcule une statistique (moyenne, somme, max, écart-type) d'un raster à l'intérieur de chaque polygone d'une couche vectorielle, l'outil

qui permet, par exemple, de résumer le NDVI moyen de chaque parcelle plutôt que de garder un indice pixel par pixel

- Algèbre raster (map algebra, calculatrice raster) : combine plusieurs rasters pixel à pixel avec des opérations arithmétiques ou logiques : c'est ainsi que se calcule tout indice spectral ($NDVI = (NIR - Rouge) / (NIR + Rouge)$) directement dans QGIS ou avec GDAL
- Analyse de voisinage (focal statistics, filtre à noyau) : recalcule chaque pixel à partir de son voisinage, détaillée dans le module L'Intelligence, qui la relie aux réseaux de neurones convolutifs

DONNÉE INTERROGÉE EN DIRECT

Cette planche affiche la grille 100 m interactive, consulter la version web du module pour cliquer une cellule.

Planche vivante. Statistiques de zone réelles (résultat de référence de la séance 3 de l'Atelier) : 1122 cellules de 100 m, moyenne NDVI/NDMI/NDBI par cellule.

VOIR AUSSI : VOIR EN PRATIQUE : LA CALCULATRICE RASTER POUR UN NDVI

Le module Les Couleurs utilise directement l'algèbre raster présentée ici pour calculer NDVI, NDMI, NDBI et leurs dérivés.

6. AUTOMATISATION AVEC PYTHON

Au-delà de quelques traitements manuels, l'automatisation devient indispensable : traiter des dizaines de fichiers, reproduire un même enchaînement d'analyses sur des données mises à jour régulièrement, ou effectuer des calculs qui n'existent pas nativement dans l'interface. Deux approches complémentaires :

PYQGIS

- API Python intégrée à QGIS
- Accès à la console Python (Extension > Console Python)
- Permet d'automatiser des chaînes de traitements QGIS existants
- Utile pour scripter des exports, styles, ou traitements répétitifs dans QGIS

GEOPANDAS (HORS QGIS)

- Bibliothèque Python autonome, basée sur pandas + Shapely

- Manipulation de données vecteur en dehors de toute interface graphique
- Standard pour les pipelines de traitement de données géographiques en Python
- S'intègre naturellement avec rasterio (raster), matplotlib (cartes rapides)

EXEMPLE GEOPANDAS : CALCUL DE SURFACE

```
gdf['surface_ha'] = gdf.to_crs(epsg=2154).area / 10_000
```

Reprojection en Lambert-93 (EPSG:2154) avant calcul de surface : indispensable, voir la mise en garde du module 1 sur les coordonnées géographiques.

EXEMPLE

VERS LA PRATIQUE

Le module Travaux pratiques met en œuvre ces outils sur des cas concrets : chargement d'une image Sentinel-2 dans QGIS, calcul de NDVI par calculatrice raster, puis croisement avec une couche vectorielle via une analyse spatiale.

APPROFONDISSEMENT

7. BASES DE DONNÉES GÉOGRAPHIQUES : POSTGIS

Au-delà d'un fichier unique (Shapefile, GeoPackage), une organisation qui gère de gros volumes de données géographiques, avec plusieurs utilisateurs simultanés, s'appuie généralement sur une base de données spatiale. PostGIS, une extension du système de gestion de base de données relationnelle libre PostgreSQL, en est le standard open-source de référence.

EXEMPLE DE REQUÊTE SPATIALE SQL (POSTGIS)

```
SELECT nom FROM communes WHERE ST_Intersects(geom,  
ST_Buffer(riviere_geom, 200));
```

Sélectionne toutes les communes qui intersectent une zone tampon de 200 m autour d'une rivière, la même opération que la section 2 (buffer + intersection), mais exprimée directement en SQL spatial, exécutable sur des millions d'entités sans passer par une interface graphique.

- Index spatial (GiST) : structure qui accélère considérablement les requêtes spatiales sur de grands volumes, indispensable au-delà de quelques dizaines de milliers d'entités
- Topologie : PostGIS peut imposer des règles de cohérence géométrique (pas de chevauchement entre parcelles, réseau routier topologiquement connecté) : un vrai fichier Shapefile ne garantit rien de tel par construction
- Un serveur PostGIS peut alimenter directement QGIS (comme n'importe quelle couche), un service web (WMS/WFS, voir module Fondements), ou une application cartographique en ligne

APPROFONDISSEMENT

8. GÉOSTATISTIQUE : INTERPOLER AVEC LE KRIGEAGE

Estimer une valeur continue (pluviométrie, teneur en polluant, altitude) en un point non mesuré à partir d'un échantillon de points de mesure est un problème classique d'interpolation spatiale. Les méthodes déterministes simples (plus proche voisin, pondération inverse à la distance, IDW) ignorent la structure spatiale propre du phénomène ; le krigeage, lui, l'estime statistiquement avant d'interpoler.

VARIOGRAMME EXPÉRIMENTAL : MESURER COMMENT LA RESSEMBLANCE DÉCROÎT AVEC LA DISTANCE

$$\gamma(h) = (1 / 2N(h)) \cdot \sum [z(x_i) - z(x_i + h)]^2$$

$\gamma(h)$ est la semi-variance moyenne entre toutes les paires de points séparées d'une distance h , $N(h)$ leur nombre. Contrairement à l'indice de Moran (mesure globale d'autocorrélation, section 4), le variogramme décrit comment la ressemblance décroît spécifiquement en fonction de la distance. Un modèle théorique (sphérique, exponentiel, gaussien) est ensuite ajusté sur ce nuage de points expérimental.




PLANCHE XV. FORME TYPIQUE D'UN VARIOGRAMME : EFFET DE PÉPITE À L'ORIGINE, MONTÉE JUSQU'AU PALIER, ATTEINT À LA PORTÉE.

- Portée (range) : distance au-delà de laquelle deux points ne sont plus statistiquement liés ; au-delà, $\gamma(h)$ plafonne
- Palier (sill) : valeur de $\gamma(h)$ à laquelle le variogramme plafonne, proche de la variance totale du phénomène
- Effet de pépité (nugget) : discontinuité à l'origine ($h \rightarrow 0$), traduisant soit une erreur de mesure, soit une variabilité à une échelle plus fine que l'échantillonnage

REMARQUE

CE QUE LE KRIGEAGE AJOUTE PAR RAPPORT À L'IDW

Une fois le variogramme ajusté, le krigeage l'utilise pour pondérer optimalement chaque point de mesure (au sens de la variance d'estimation minimale, sous hypothèse de stationnarité du phénomène), contrairement à l'IDW, dont la pondération par la seule distance est une convention arbitraire, pas une propriété statistiquement optimale du phénomène étudié. Le krigeage fournit en prime une carte d'incertitude (variance de krigeage), pas seulement une carte de valeurs estimées : on sait où l'estimation est fiable et où elle ne l'est pas, typiquement loin de tout point de mesure.

APPROFONDISSEMENT

9. ANALYSE RÉSEAU ET DÉCISION MULTICRITÈRE

Deux familles d'analyse spatiale, distinctes des opérations vectorielles/raster déjà vues, répondent à des questions différentes : « comment circule-t-on dans l'espace ? » et «

comment arbitrer entre plusieurs critères contradictoires sur un même territoire ? »

- Analyse réseau (plus court chemin) : un réseau routier ou hydrographique est modélisé comme un graphe (nœuds = intersections, arêtes = tronçons pondérés par une distance, un temps ou un coût) ; l'algorithme de Dijkstra (1959) calcule le chemin de coût minimal entre deux nœuds, la base de tout calcul d'itinéraire ou de zone de chalandise (isochrone)
- Zone de service (service area) : ensemble des points atteignables depuis un point donné en deçà d'un coût maximal (ex. tout ce qui est à moins de 15 minutes d'un hôpital), une extension directe de Dijkstra, pas un algorithme différent

AHP (ANALYTIC HIERARCHY PROCESS, SAATY, 1980) : PONDÉRER PLUSIEURS CRITÈRES SPATIAUX

$$\text{Score}(x) = \sum_i w_i \cdot \text{critère}_i(x) \text{ avec } \sum_i w_i = 1$$

Utilisée pour combiner plusieurs couches raster/vecteur normalisées (pente, distance aux routes, exposition, occupation du sol...) en une carte de synthèse unique : typiquement une carte d'aptitude ou de risque. Les poids w_i ne sont pas fixés arbitrairement : l'AHP les dérive d'une matrice de comparaisons deux à deux entre critères (« la pente compte-t-elle plus ou moins que la distance aux routes, et dans quelle proportion ? »), avec un ratio de cohérence qui signale si les comparaisons fournies par l'expert sont mutuellement contradictoires.

EXEMPLE

LIEN DIRECT AVEC LES INDICES COMPOSITES DU MODULE LES COULEURS

Un indice composite de comportement du feu (module Les Couleurs, section indices composés) qui pondère NDMI, alignement vent/pente et exposition solaire est, de fait, une application d'AHP simplifiée : chaque couche est un critère normalisé, chaque poids reflète l'importance relative jugée du critère. Documenter explicitement ces poids (et idéalement leur cohérence, au sens de Saaty) plutôt que les fixer "au jugé" est ce qui distingue une analyse multicritère rigoureuse d'un bricolage de pondérations.

SUPÉRIEUR

10. QUALITÉ DES DONNÉES ET MÉTADONNÉES

Une donnée géographique n'est jamais parfaitement exacte, et ne prétend jamais l'être : ce qui compte, c'est de savoir à quel point elle l'est, et de le documenter pour quiconque la réutilise après vous.

PRÉCISION

- Répétabilité de la mesure : des mesures répétées donnent-elles des résultats proches ?
- Une donnée peut être précise sans être exacte (biais systématique)

EXACTITUDE

- Proximité avec la valeur réelle sur le terrain
- Se vérifie par comparaison à une référence indépendante (relevé GPS de contrôle, orthophoto)

ATTENTION

RÉSOLUTION N'EST PAS PRÉCISION

Un raster à 10 m de résolution spatiale n'est pas nécessairement localisé avec une précision de 10 m : la résolution décrit la taille du pixel, la précision géométrique décrit l'écart entre la position affichée et la position réelle. Les deux notions sont indépendantes et se confondent souvent à tort.

- Les métadonnées documentent la source, la date, le système de coordonnées, la précision estimée et la méthode de production d'une couche
- Sans métadonnées, une donnée téléchargée reste invérifiable : impossible de savoir si elle est encore à jour ou dans quelles conditions elle a été produite
- La norme ISO 19115 encadre la structure des métadonnées géographiques, reprise par la plupart des portails de données ouvertes (dont data.gouv.fr)

EXEMPLE

L'ERREUR QUADRATIQUE MOYENNE (RMSE), LA MESURE STANDARD DE LA PRÉCISION GÉOMÉTRIQUE

Après un géoréférencement (voir module Travaux pratiques, séance 2) ou un contrôle qualité, la précision d'un jeu de données se documente souvent par une RMSE (Root Mean Square Error) : la racine carrée de la moyenne des écarts au carré entre la position mesurée et la position de référence, sur un ensemble de points de contrôle indépendants. Une RMSE de 5 m signifie, en simplifiant, qu'un point typique de la couche est décalé d'environ 5 m par rapport à la réalité terrain.