

DE L'INSTRUMENT ET DU NOMBRE

Les Ambassadeurs de Holbein posent leurs instruments de mesure du monde — globe, quadrant, cadran — sur un tapis richement chargé : R est ce même établi, réduit à un langage, où chaque fonction mesure, résume ou représente une donnée à la place d'un instrument de laiton.



FIG. VI. HANS HOLBEIN LE JEUNE, « LES AMBASSADEURS », 1533

Tutoriel complet du langage R : syntaxe, structures de données, visualisation avec ggplot2, statistique et cartographie spatiale, en trois parcours de niveau.

SOMMAIRE

1. INSTALLER R ET RSTUDIO, L'ATELIER DE TRAVAIL

2. PREMIERS CALCULS, VARIABLES, TYPES SIMPLES

3. VECTEURS, FONCTIONS DE BASE, L'AIDE INTÉGRÉE

4. IMPORTER UN TABLEAU, UN DATA FRAME

5. PREMIER GRAPHIQUE AVEC GGLOT2

6. FILTRER ET TRIER AVEC DPLYR, LE PIPE NATIF

R est un langage de programmation et un environnement dédiés au calcul statistique et à la visualisation de données, né au début des années 1990 comme implémentation libre du langage S. En géomatique, R occupe une place particulière : au-delà de la statistique généraliste, il porte un écosystème de packages spatiaux mature (`sf`, `terra`, `spdep`, `gstat`, `tmap`) qui permet de reproduire en code, ligne par ligne, ce qu'un SIG comme QGIS fait par clics — avec l'avantage d'un script reproductible, versionnable et automatisable sur des dizaines de jeux de données identiques. Ce module présente RStudio, la syntaxe du langage, la visualisation avec `ggplot2`, puis la cartographie et la statistique spatiale. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

1. INSTALLER R ET RSTUDIO, L'ATELIER DE TRAVAIL

R et RStudio sont deux logiciels distincts, installés séparément et dans cet ordre : R est le moteur qui exécute réellement le code (à télécharger sur le CRAN, cran.r-project.org) ; RStudio est l'IDE (Integrated Development Environment) qui l'entoure d'une interface confortable — éditeur de script, aide contextuelle, gestion des graphiques. Sans R déjà installé, RStudio n'a rien à exécuter : c'est une coquille vide.

ATTENTION

UNE CONFUSION FRÉQUENTE AU PREMIER LANCEMENT

Installer uniquement RStudio sans R au préalable (ou l'inverse dans le mauvais ordre) fait échouer le lancement de RStudio, ou le laisse sans version de R détectée à sélectionner. Toujours installer R en premier, RStudio ensuite : RStudio se contente de le détecter automatiquement au démarrage.

- Console (en bas à gauche, ou à gauche seul) : zone où le code s'exécute réellement, ligne par ligne, résultat affiché immédiatement — utile pour tester une instruction ponctuelle
- Script / Source (en haut à gauche) : éditeur de texte pour écrire un fichier .R complet, gardé, modifiable, réexécutable — Ctrl+Entrée (Cmd+Entrée sur Mac) envoie la ligne courante à la Console sans quitter l'éditeur
- Environnement / Historique (en haut à droite) : liste de toutes les variables actuellement en mémoire (un data frame chargé, un vecteur créé) et de l'historique des commandes exécutées
- Fichiers / Graphiques / Packages / Aide (en bas à droite) : navigateur de fichiers du projet, affichage des graphiques produits, liste des packages installés/activés, et panneau d'aide intégrée

REMARQUE

TOUJOURS TRAVAILLER DANS UN SCRIPT, JAMAIS SEULEMENT DANS LA CONSOLE

Une ligne tapée directement dans la Console s'exécute mais disparaît de toute trace organisée. Écrire dans un fichier Script (.R), puis l'envoyer ligne par ligne ou en bloc vers la Console, garde un historique complet et réexécutable de tout le travail — le même réflexe qu'enregistrer un projet QGIS plutôt que de faire des traitements qu'on ne pourra jamais reproduire à l'identique.

LYCÉE

2. PREMIERS CALCULS, VARIABLES, TYPES SIMPLES

La Console de R se comporte d'abord comme une calculatrice : taper $2 + 2$ et valider affiche 4. L'opérateur d'affectation `<-` (une flèche, composée d'un chevron et d'un tiret) stocke un résultat dans une variable, pour le réutiliser ensuite sans le retaper.

AFFECTER UNE VALEUR À UNE VARIABLE

```
altitude <- 1250 nom_sommet <- 'Aiguille du Midi' est enneige  
<- TRUE
```

`<-` est l'opérateur d'affectation conventionnel en R (= fonctionne aussi dans la plupart des contextes, mais `<-` reste la convention à adopter). Une fois exécutée, chaque variable apparaît dans le panneau Environnement, à droite.

TYPE SIMPLE	EXEMPLE	FONCTION POUR VÉRIFIER
numeric	1250, 3.14, -8	<code>class(alitude)</code>
character	'Aiguille du Midi'	<code>class(nom_sommet)</code>
logical	TRUE, FALSE	<code>class(est enneige)</code>

REMARQUE

CLASS() DIT CE QU'EST UNE VARIABLE

`class(x)` renvoie le type d'une variable `x`. C'est le premier réflexe de diagnostic en R : avant de comprendre pourquoi un calcul échoue, vérifier que la variable est bien du type attendu (un nombre plutôt qu'un texte, par exemple, est une source d'erreur très courante en important un tableau).

LYCÉE

3. VECTEURS, FONCTIONS DE BASE, L'AIDE INTÉGRÉE

En R, même une valeur unique (`altitude <- 1250` ci-dessus) est techniquement un vecteur de longueur 1 : le vecteur est l'unité de base du langage. La fonction `c()` (« combine ») assemble plusieurs valeurs en un seul vecteur.

CRÉER UN VECTEUR DE NOTES

```
notes <- c(12, 8, 15, 10, 16)
```

`notes` contient maintenant cinq valeurs numériques, dans l'ordre où elles ont été saisies, accessibles individuellement par leur position : `notes[1]` vaut 12 (R indexe à partir de 1, pas de 0).

- `mean(notes)` : moyenne des valeurs du vecteur
- `sum(notes)` : somme des valeurs
- `length(notes)` : nombre de valeurs dans le vecteur
- `max(notes)` et `min(notes)` : valeur la plus haute et la plus basse
- `sort(notes)` : trie le vecteur par ordre croissant

REMARQUE

?FONCTION : L'AIDE EST TOUJOURS À PORTÉE DE MAIN

Taper `?mean` (ou `help(mean)`) dans la Console ouvre, dans le panneau Aide en bas à droite, la documentation officielle de la fonction `mean()` : ce qu'elle attend en argument, ce qu'elle renvoie, des exemples d'usage. Ce réflexe — consulter l'aide intégrée plutôt que deviner — est la compétence la plus rentable à acquérir dès le début, bien avant de mémoriser des fonctions par cœur.

EXEMPLE

EXEMPLE CONCRET

`mean(notes)` sur `c(12, 8, 15, 10, 16)` renvoie 12.2 : la moyenne de classe. `sort(notes)` renvoie `c(8, 10, 12, 15, 16)` — utile pour repérer d'un coup d'œil la note la plus basse et la plus haute sans les chercher une par une.

LYCÉE

4. IMPORTER UN TABLEAU, UN DATA FRAME

Un data frame est la structure de données centrale de R pour tout tableau : chaque ligne est une observation, chaque colonne une variable — exactement la même logique qu'une table attributaire QGIS ou une feuille de tableur. `read.csv()` importe directement un fichier .csv dans un data frame.

IMPORTER UN FICHIER .CSV

```
donnees <- read.csv('meteo_communes.csv')
```

`donnees` est désormais un data frame en mémoire, visible dans le panneau Environnement. Le chemin est relatif au répertoire de travail courant (`getwd()` l'affiche ; `setwd()` le change, ou mieux : ouvrir RStudio via un fichier .Rproj, voir piste Master/Recherche sur `here::here()`).

ATTENTION

READ.CSV() OU READ.CSV2() ? UN PIÈGE TRÈS FRÉQUENT EN FRANCE

`read.csv()` attend une virgule comme séparateur de colonnes et un point comme séparateur décimal (convention anglo-saxonne). Un fichier exporté depuis Excel en France utilise typiquement le point-virgule comme séparateur de colonnes et la virgule comme séparateur décimal : il faut alors `read.csv2()`, pas `read.csv()`. Un import qui ne produit qu'une seule colonne géante au lieu de plusieurs colonnes distinctes est le symptôme classique de cette confusion.

- `View(donnees)` : ouvre le tableau dans un onglet façon tableur, pour l'inspecter visuellement
- `str(donnees)` : affiche la structure du data frame — nombre de lignes/colonnes, type de chaque colonne, premières valeurs
- `head(donnees)` : affiche seulement les six premières lignes, utile sur un gros tableau
- `nrow(donnees)` et `ncol(donnees)` : nombre de lignes et de colonnes
- `donnees$temperature` : accède directement à la colonne `temperature` du data frame `donnees`

LYCÉE

5. PREMIER GRAPHIQUE AVEC GGLOT2

`ggplot2` (package à installer une fois avec `install.packages('ggplot2')`, puis à charger à chaque session avec `library(ggplot2)`) construit un graphique par couches successives, ajoutées avec l'opérateur `+`. En une phrase, sa grammaire des graphiques répond toujours à trois questions : quelles données (data), quelle correspondance entre une colonne et un élément visuel (aes, les esthétiques : axe x, axe y, couleur...), et quelle forme géométrique représente chaque observation (`geom_point` pour des points, `geom_bar`/`geom_col` pour des barres...).

NUAGE DE POINTS AVEC GGPLOT2

```
ggplot(donnees, aes(x = altitude, y = temperature)) +  
geom_point()
```

ggplot(donnees, aes(...)) prépare le système d'axes à partir du data frame donnees ; +
geom_point() ajoute la couche qui dessine effectivement un point par ligne du tableau.
Chaque + ajoute une couche supplémentaire sans jamais retirer les précédentes.

DIAGRAMME EN BARRES AVEC GGPLOT2

```
ggplot(donnees, aes(x = commune, y = temperature)) +  
geom_col()
```

geom_col() dessine une barre dont la hauteur vaut directement la valeur de y (contrairement à geom_bar(), qui compte par défaut le nombre d'observations par catégorie plutôt que de lire une colonne de hauteur).

REMARQUE

L'OPÉRATEUR + N'EST PAS UNE ADDITION ARITHMÉTIQUE ICI

Dans ggplot(...) + geom_point() + labs(title = '...'), le + empile des couches graphiques (données, géométrie, habillage) les unes sur les autres, comme des calques QGIS superposés. C'est une syntaxe propre à ggplot2, à ne pas confondre avec le pipe |> vu en section suivante, qui enchaîne lui des étapes de traitement sur un tableau, pas des couches graphiques.

LYCÉE

6. FILTRER ET TRIER AVEC DPLYR, LE PIPE NATIF

Le package dplyr fournit des verbes simples pour manipuler un data frame : filter() garde seulement certaines lignes selon une condition, arrange() les trie selon une colonne. Le pipe natif |> (disponible depuis R 4.1, sans package supplémentaire) enchaîne plusieurs étapes en les lisant de gauche à droite, comme une phrase.

FILTREDR PUIS TRIER AVEC LE PIPE

```
donnees |> filter(temperature > 20) |>  
arrange(desc(temperature))
```

Se lit : « prends donnees, PUIS garde les lignes où temperature > 20, PUIS trie par température décroissante (desc()) ». Sans le pipe, la même opération s'écrit arrange(filter(donnees, temperature > 20), desc(temperature)) — techniquement identique, mais lue de l'intérieur vers l'extérieur, dans l'ordre inverse des étapes réellement effectuées.

EXEMPLE

POURQUOI LE PIPE SE LIT PLUS NATURELLEMENT

Une suite d'opérations imbriquées (arrange(filter(select(donnees, commune, temperature), temperature > 20), desc(temperature))) oblige à lire de l'intérieur vers l'extérieur pour reconstituer l'ordre réel des étapes. La même suite avec |> se lit dans l'ordre où elle s'exécute réellement, du haut vers le bas — un gain de lisibilité qui devient décisif dès qu'une chaîne dépasse deux ou trois étapes (voir la piste Licence/BUT).

DEVOIR À RENDRE : SCRIPT R COMMENTÉ

ANALYSER UN RELEVÉ MÉTÉO COMMUNAL

Importe un tableau météo (température moyenne par commune, une colonne commune et une colonne temperature — utilise un relevé public téléchargé ou un tableau que tu construis toi-même à partir de dix communes de ta région) avec read.csv() ou read.csv2() selon son format. Produis un graphique ggplot2 (geom_col ou geom_point) montrant la température par commune, avec un titre et des axes nommés via labs(). Ajoute un filtre dplyr qui ne garde que les communes au-dessus de la température moyenne, calculée avec mean().

- Le bon séparateur (read.csv ou read.csv2) a été identifié et l'import ne produit pas une colonne unique mal découpée
- Le graphique porte un titre et des axes nommés (labs(title = ..., x = ..., y = ...))
- Le filtre dplyr utilise effectivement la moyenne calculée avec mean(), pas un seuil choisi au hasard
- Le script est commenté (lignes commençant par #) pour expliquer chaque étape à quelqu'un qui le lirait après coup

- Bilan — à retenir : R exécute le code, RStudio l'entoure d'une interface (Console, Script, Environnement, Fichiers/Graphiques) ; `<-` affecte une valeur à une variable, `class()` en donne le type ; `c()` construit un vecteur, `mean()`/`sum()`/`length()` le résumant, `?fonction` ouvre l'aide intégrée ; `read.csv()`/`read.csv2()` importe un tableau en data frame (`str()`, `head()`, `View()` pour l'inspecter) ; `ggplot2` empile des couches avec `+` (données, esthétiques `aes()`, géométrie `geom_...()`) ; `dplyr` filtre (`filter()`) et trie (`arrange()`), le pipe `|>` enchaîne les étapes dans leur ordre réel d'exécution.

VOIR AUSSI : VOIR AUSSI : LES MÊMES OPÉRATIONS, EN INTERFACE GRAPHIQUE

Le module Le Compas présente les mêmes gestes (filtrer, trier, représenter) directement dans l'interface de QGIS, sans écrire de code.