

DE CE QUI SE REGROUPE

Le géographe de Vermeer mesurait déjà où les choses se regroupent sur sa carte ; l'indice local et le point chaud statistique font, avec des nombres, ce que son compas faisait à l'œil.



FIG. X. JOHN SNOW (CARTOGRAPHIE : CHARLES CHEFFINS), « CARTE DU CHOLÉRA DE BROAD STREET », 1854

Indicateurs locaux d'association spatiale (LISA), points chauds (G_i^*), densité par noyau, régression spatiale, cartographie du risque.

SOMMAIRE

1. INDICATEURS LOCAUX D'ASSOCIATION SPATIALE (LISA)

2. DÉTECTER LES POINTS CHAUDS : LA STATISTIQUE G_i^* DE GETIS-ORD

3. DENSITÉ DE POINTS : L'ESTIMATION PAR NOYAU (KDE)

4. ALÉA, ENJEUX, VULNÉRABILITÉ : LA STRUCTURE D'UNE CARTOGRAPHIE DU RISQUE

5. PIÈGES STATISTIQUES PROPRES AUX DONNÉES SPATIALES

6. OUTILS ET BIBLIOTHÈQUES

Le module Le Compas introduit l'indice de Moran global et le krigeage : la position dans l'espace n'est pas neutre statistiquement, la première loi de la géographie de Tobler le pose clairement. Cette salle va plus loin sur trois terrains que Le Compas ne fait qu'effleurer : détecter où, précisément, une structure spatiale se manifeste (pas seulement si elle existe globalement), analyser des semis de points plutôt que des zones, et cartographier un risque en combinant plusieurs couches statistiques rigoureusement. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : INDICE DE MORAN GLOBAL, MAUP, VARIOGRAMME

SUPÉRIEUR

1. INDICATEURS LOCAUX D'ASSOCIATION SPATIALE (LISA)

Le Local Indicator of Spatial Association (LISA), formalisé par Luc Anselin (1995), décompose l'indice de Moran global en une valeur par entité, plutôt qu'un seul chiffre pour l'ensemble de l'étude. Chaque entité reçoit un Local Moran's I, qui la classe dans l'un de quatre types selon sa propre valeur et celle de son voisinage.

LOCAL MORAN'S I (LISA)

$$I_i = [(x_i - \bar{x}) / S^2] \cdot \sum_j w_{ij} (x_j - \bar{x})$$

$S^2 = \sum (x_i - \bar{x})^2 / n$, la variance de l'ensemble des entités (et non la variance d'échantillon au sens usuel, qui diviserait par $n-1$). Contrairement à l'indice global (une seule valeur), chaque entité i reçoit son propre I_i , cartographiable directement — c'est cette cartographie, pas la formule seule, qui rend le LISA opérationnellement utile.

TYPE LISA	SIGNIFICATION	EXEMPLE
Haut-Haut (HH)	Une valeur élevée entourée de voisins à valeur élevée	Un foyer de forte densité d'habitat entouré d'autres zones denses
Bas-Bas (LL)	Une valeur faible entourée de voisins à valeur faible	Une zone rurale peu peuplée, entourée d'autres zones rurales
Haut-Bas (HL)	Une valeur élevée isolée au milieu de voisins faibles — une anomalie locale	Un hameau dense isolé au milieu d'un massif peu peuplé
Bas-Haut (LH)	Une valeur faible isolée au milieu de voisins élevés — une anomalie locale	Une zone naturelle protégée enclavée dans un tissu urbain dense

EXEMPLE

EXEMPLE CHIFFRÉ

Cinq communes alignées le long d'une vallée, valeur observée $x = [10, 10, 50, 10, 10]$ (par exemple un taux pour 1000 habitants). Moyenne $\bar{x} = 18$. Variance de l'ensemble $S^2 = \sum (x_i - \bar{x})^2 / 5 = (64 + 64 + 1024 + 64 + 64) / 5 = 256$. Pour la commune 3 (voisins : communes 2 et 4 uniquement) : $(x_3 - \bar{x}) = 32$; $\sum_j w_{ij}(x_j - \bar{x}) = (10 - 18) + (10 - 18) = -16$. $I_3 = (32/256) \times (-16) = -2.0$. Un I négatif alors que la commune elle-même est au-dessus de la moyenne classe la commune 3 en Haut-Bas (HL) : un pic isolé, pas un cluster — exactement le cas que le G_i^* de la section suivante, lui, ne signalera pas comme point chaud.




PLANCHE XVIII. LE NUAGE DE MORAN : CHAQUE ENTITÉ CLASSÉE SELON SA PROPRE VALEUR ET CELLE DE SON VOISINAGE — HAUT-HAUT ET BAS-BAS SIGNALENT UN VRAI REGROUPEMENT, HAUT-BAS ET BAS-HAUT UNE ANOMALIE LOCALE.

ATTENTION

COMPARAISONS MULTIPLES : NE PAS LIRE CHAQUE I_i ISOLÉMENT SANS CORRECTION

Calculer un Local Moran's I pour chacune de plusieurs milliers d'entités revient à effectuer autant de tests statistiques simultanés : au seuil conventionnel $p < 0.05$, environ 5 % des entités apparaîtront « significatives » par pur hasard, même en l'absence de toute vraie structure spatiale. Une correction pour comparaisons multiples (ex. Bonferroni, ou le taux de fausse découverte de Benjamini-Hochberg) est nécessaire avant d'interpréter une carte LISA comme identifiant des clusters réellement significatifs plutôt qu'un artefact du grand nombre de tests effectués.

SUPÉRIEUR

2. DÉTECTER LES POINTS CHAUDS : LA STATISTIQUE G_i^* DE GETIS-ORD

Le Local Moran's I détecte des similarités locales (y compris de faibles valeurs regroupées, LL). Quand la question posée est spécifiquement « où sont les points chauds de valeurs élevées, et où sont les points froids de valeurs faibles », la statistique G_i^* (Getis & Ord, 1992) est l'outil dédié : elle compare la somme des valeurs dans un voisinage local à ce qu'on attendrait si les valeurs étaient réparties au hasard sur toute la zone d'étude.

STATISTIQUE G_i^* DE GETIS-ORD

$$G_i^* = [\sum_j w_{ij} x_j - \bar{X} \sum_j w_{ij}] / [S \cdot \sqrt{ (n \sum_j w_{ij}^2 - (\sum_j w_{ij})^2) / (n-1) }]$$

$S = \sqrt{(\sum_j x_j^2 / n - \bar{X}^2)}$, l'écart-type de l'ensemble des entités (même convention en n , pas $n-1$, que le S^2 du Local Moran's I ci-dessus). Un G_i^* positif et statistiquement significatif signale un point chaud (hot spot) ; négatif et significatif, un point froid (cold spot). Le résultat est un score Z , directement interprétable comme un test statistique standard ($Z > 1.96 \approx p < 0.05$, avec la même réserve sur les comparaisons multiples que pour le LISA).

EXEMPLE

EXEMPLE CHIFFRÉ : CETTE FOIS, UN VRAI CLUSTER

Mêmes cinq communes, mais $x = [10, 10, 60, 65, 60]$: les communes 3, 4 et 5 forment cette fois un groupe contigu de valeurs élevées, pas un pic isolé. $\bar{x} = 41$, $S \approx 25.4$. Pour la commune 4 (voisinage G_i^* , elle-même incluse : communes 3, 4, 5) : $\sum_j w_{ij} x_j = 60 + 65 + 60 = 185$, $\sum_j w_{ij} = 3$. Numérateur = $185 - 41 \times 3 = 62$. Dénominateur = $25.4 \times \sqrt{((5 \times 3 - 9)/4)} \approx 25.4 \times 1.225 \approx 31.1$. $G_i^* \approx 62/31.1 \approx 1.99 > 1.96$: un point chaud tout juste significatif à $p < 0.05$ — contrairement à la commune 3 isolée de l'exemple LISA ci-dessus, ici la valeur élevée est partagée par ses voisins immédiats, ce qui est précisément ce que le G_i^* est construit pour détecter.

EXEMPLE

APPLICATION DIRECTE À LA CARTOGRAPHIE DU RISQUE

Sur une couche de points d'éclosion de feux de forêt sur plusieurs décennies, une carte G_i^* identifie précisément les secteurs où les départs de feu se concentrent statistiquement au-delà du hasard, distincts des secteurs qui en comptent simplement beaucoup parce que la zone d'étude y est plus grande ou plus peuplée d'entités. C'est cette distinction — concentration réelle vs simple densité brute — qui rend le G_i^* directement utile à la priorisation d'une politique de prévention, plutôt qu'une carte de densité brute qui confond les deux.

LISA (LOCAL MORAN'S I)

- Compare chaque entité à ses voisins directs : mesure une similarité locale
- Distingue quatre configurations, y compris les anomalies isolées (HL, LH)
- Répond à : « cette entité ressemble-t-elle à son voisinage, ou détonne-t-elle ? »

G_i^* (GETIS-ORD)

- Compare la somme locale des valeurs à la moyenne de toute la zone d'étude
- Ne distingue que deux issues significatives : point chaud ou point froid
- Répond à : « où, précisément, les valeurs fortes (ou faibles) se concentrent-elles statistiquement ? »

REMARQUE

DEUX OUTILS COMPLÉMENTAIRES, PAS CONCURRENTS

Sur un même jeu de données, un praticien calcule fréquemment les deux : le LISA pour repérer aussi les anomalies locales (un point isolé qui détonne, potentiellement une erreur de saisie ou un cas réellement singulier à examiner), le Gi* pour produire une carte de points chauds/froids directement lisible par un décideur, sans les quatre catégories du LISA à expliquer. Le choix de la matrice de poids spatiaux w_{ij} affecte les deux de la même façon.

SUPÉRIEUR

3. DENSITÉ DE POINTS : L'ESTIMATION PAR NOYAU (KDE)

Le Gi* teste une hypothèse sur des zones déjà découpées (communes, carreaux). Pour un semis de points brut (chaque incendie, chaque accident, chaque observation individuelle géolocalisée), l'estimation par noyau (Kernel Density Estimation, KDE) construit directement une surface continue de densité, sans imposer de découpage arbitraire au préalable — une façon d'éviter d'emblée le MAUP (module Le Compas) pour cette étape de l'analyse.

ESTIMATION DE DENSITÉ PAR NOYAU

$$f(x) = (1 / n \cdot h^2) \cdot \sum_i K((x - x_i) / h)$$

K = fonction noyau (souvent gaussienne ou quartique), h = largeur de bande (bandwidth) : le paramètre le plus déterminant du résultat. Un h trop petit produit une carte bruitée, dominée par chaque point individuel ; un h trop grand lisse excessivement et masque les concentrations réelles. Le choix de h doit être justifié (par validation croisée, ou par une distance caractéristique du phénomène étudié), jamais laissé à la valeur par défaut du logiciel sans vérification.

🔔 RAPPEL

RAPPEL : TRAVAILLER EN COORDONNÉES PROJÉTÉES, PAS EN DEGRÉS (MODULE FONDEMENTS)

Le module Fondements pose la règle : un calcul de distance ou de surface exige des coordonnées projetées métriques (Lambert-93 en France), jamais des degrés WGS84, où un même écart angulaire ne représente pas la même distance au sol selon la latitude. La largeur de bande h ci-dessus n'a de sens en mètres que si les points d'entrée sont déjà dans un tel système projeté.

DONNÉE INTERROGÉE EN DIRECT

Cette planche affiche une carte de densité par noyau interactive sur six mégafeux français réels, consulter la version web du module pour faire varier la bande passante h .

ATTENTION

UNE CARTE DE CHALEUR (HEATMAP) N'EST PAS NEUTRE

Une carte de densité par noyau produit toujours une image visuellement convaincante, y compris sur des données sans aucune structure spatiale réelle : la seule présence de quelques points suffit à générer des zones colorées d'apparence significative. Contrairement au G_i^* , une KDE simple ne fournit par défaut aucun test de significativité — elle décrit une densité observée, elle ne prouve pas à elle seule un phénomène statistiquement anormal.

SUPÉRIEUR

4. ALÉA, ENJEUX, VULNÉRABILITÉ : LA STRUCTURE D'UNE CARTOGRAPHIE DU RISQUE

Cartographier un risque naturel (incendie, inondation, mouvement de terrain) ne se réduit jamais à une seule couche statistique : la doctrine standard de gestion des risques, reprise en France par les services de prévention, décompose le risque en trois composantes distinctes, à cartographier et croiser séparément plutôt que confondre.

STRUCTURE CONCEPTUELLE DU RISQUE

$$\text{Risque} = \text{Aléa} \times \text{Enjeux} \times \text{Vulnérabilité}$$

Aléa : probabilité et intensité physique du phénomène (ex. probabilité d'éclosion et de propagation d'un feu selon le terrain, la végétation, le vent). Enjeux : ce qui est exposé (population, bâti, infrastructures présentes dans la zone). Vulnérabilité : la sensibilité de ces enjeux au phénomène (une habitation en bois est plus vulnérable au feu qu'un bâtiment en pierre à jardin dégagé). Un aléa fort sans aucun enjeu exposé ne produit aucun risque au sens opérationnel du terme — une distinction régulièrement source de confusion dans le langage courant, où « risque » et « aléa » sont souvent employés l'un pour l'autre.

COMPOSANTE	MÉTHODE STATISTIQUE SPATIALE TYPIQUE
Aléa	Gi*/LISA sur l'historique des occurrences, KDE sur les points d'ignition, indices composites (pente, vent, combustible)
Enjeux	Densité de population/bâti (statistiques de zone, module Le Compas), distance aux infrastructures
Vulnérabilité	Indices composites pondérés (type de matériau, âge du bâti, capacité d'évacuation)

REMARQUE

UNE CARTE DE RISQUE COMBINE, ELLE NE MOYENNE PAS NAÏVEMENT

Combiner ces trois couches par une simple moyenne arithmétique non pondérée traite implicitement chaque composante comme d'égale importance et d'échelle comparable, une hypothèse rarement justifiée sans une analyse multicritère explicite (voir l'analyse multicritère AHP, module Le Compas) qui documente les poids choisis et leur justification, plutôt que de les laisser implicites dans le choix arbitraire d'une formule.

SUPÉRIEUR

5. PIÈGES STATISTIQUES PROPRES AUX DONNÉES SPATIALES

- Pseudoréplication : traiter des observations spatialement dépendantes (des cellules voisines d'une même grille, des mesures répétées au même endroit) comme des observations indépendantes gonfle artificiellement la taille d'échantillon effective, et donc la confiance accordée à un résultat
- MAUP (module Le Compas) : le résultat d'une statistique de zone dépend du découpage choisi, pas seulement de la donnée sous-jacente
- Confondre corrélation spatiale et causalité : deux phénomènes peuvent covarier spatialement (Tobler) sans lien causal direct, chacun pouvant simplement répondre au même facteur sous-jacent non mesuré (le relief, par exemple, influence à la fois la végétation et l'habitat)
- Ignorer l'effet de bord (edge effect) : une entité située au bord de la zone d'étude a mécaniquement moins de voisins recensés dans l'analyse, ce qui biaise les indices locaux (LISA, G_i^* , KDE) qui y sont calculés, sauf correction explicite (zone tampon d'étude plus large que la zone d'intérêt, pondération d'edge effect)

À TOI DE JOUER

LA STRUCTURE DU RISQUE

Construis la formule en cliquant les tuiles dans l'ordre : attention aux tuiles pièges.

Exercice interactif, à faire sur la version web du site.

SUPÉRIEUR

6. OUTILS ET BIBLIOTHÈQUES

OUTIL	TYPE	POINTS FORTS
GeoDa	Logiciel libre autonome (interface graphique)	Conçu spécifiquement pour l'analyse exploratoire de données spatiales (Anselin), LISA/Gi* accessibles sans code
PySAL (Python Spatial Analysis Library)	Bibliothèque Python	Équivalent programmable de GeoDa, s'intègre avec GeoPandas (module Le Compas)
Extension QGIS « Analyse spatiale statistique »	Plugin QGIS	LISA/Gi* directement dans l'interface déjà utilisée pour le reste du projet, sans changer d'environnement
R (packages spdep, gstat)	Langage statistique dédié	Référence académique historique pour la statistique spatiale, très large littérature et documentation associées

- Bilan — à retenir : le LISA décompose Moran entité par entité (4 types : HH, LL, HL, LH) ; le Gi* teste spécifiquement points chauds/froids par un score Z ; la KDE construit une densité continue sans découpage arbitraire (MAUP) mais dépend fortement de h ; le risque = aléa × enjeux × vulnérabilité, jamais une moyenne naïve ; pseudoréplication, MAUP, corrélation/causalité et effet de bord sont les pièges statistiques les plus fréquents sur données spatiales.

VOIR AUSSI : VOIR EN PRATIQUE : LE RISQUE INCENDIE DE BOUT EN BOUT

Le module Les Secteurs applique aléa/enjeux/vulnérabilité, Gi* et KDE à un cas complet, du modèle physique à la carte de priorisation.