

DE CE QUI SE REGROUPE

Le géographe de Vermeer mesurait déjà où les choses se regroupent sur sa carte ; l'indice local et le point chaud statistique font, avec des nombres, ce que son compas faisait à l'œil.



FIG. X. JOHN SNOW (CARTOGRAPHIE : CHARLES CHEFFINS), « CARTE DU CHOLÉRA DE BROAD STREET », 1854

Indicateurs locaux d'association spatiale (LISA), points chauds (Gi*), densité par noyau, régression spatiale, cartographie du risque.

SOMMAIRE

1. RÉGRESSION SPATIALE : QUAND LES RÉSIDUS NE SONT PAS INDÉPENDANTS

2. ANALYSE DE SEMIS DE POINTS : LA FONCTION K DE RIPLEY

3. ÉTUDE DE CAS : CARTOGRAPHIER UN RISQUE À PARTIR DE TROIS COUCHES

Le module Le Compas introduit l'indice de Moran global et le krigeage : la position dans l'espace n'est pas neutre statistiquement, la première loi de la géographie de Tobler le pose clairement. Cette salle va plus loin sur trois terrains que Le Compas ne fait qu'effleurer : détecter où, précisément, une structure spatiale se manifeste (pas seulement si elle existe globalement), analyser des semis de points plutôt que des zones, et cartographier un risque en combinant plusieurs couches statistiques rigoureusement. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : INDICE DE MORAN GLOBAL, MAUP, VARIOGRAMME

Le Compas pose les bases de l'autocorrélation spatiale et du krigeage, prérequis de cette salle.

APPROFONDISSEMENT

1. RÉGRESSION SPATIALE : QUAND LES RÉSIDUS NE SONT PAS INDÉPENDANTS




PLANCHE XVIII. LA MÊME LOGIQUE QUE LE NUAGE DE MORAN, APPLIQUÉE CETTE FOIS AUX RÉSIDUS D'UN MODÈLE : UN REGROUPEMENT (HAUT-HAUT, BAS-BAS) PARMI LES RÉSIDUS SIGNALÉ UNE AUTOCORRÉLATION QUE L'OLS CLASSIQUE IGNORE.

Une régression linéaire classique (moindres carrés ordinaires, OLS) suppose que ses résidus (l'écart entre valeur observée et valeur prédite) sont indépendants les uns des autres. Sur une donnée spatiale, cette hypothèse est régulièrement violée : si le phénomène étudié a une structure spatiale (la première loi de Tobler, encore), les résidus d'un modèle qui l'ignore présentent eux-mêmes de l'autocorrélation spatiale, détectable en calculant un indice de Moran directement sur les résidus du modèle.

- Modèle à retard spatial (spatial lag model) : ajoute la valeur moyenne des voisins comme variable explicative supplémentaire, quand la valeur d'une entité dépend directement de celle de ses voisines (diffusion, contagion)
- Modèle à erreur spatiale (spatial error model) : modélise l'autocorrélation dans le terme d'erreur lui-même, quand une variable non observée mais spatialement structurée influence le phénomène (un facteur environnemental non mesuré, par exemple)
- Dans les deux cas, ignorer une autocorrélation spatiale résiduelle avérée ne rend pas les coefficients du modèle faux en moyenne, mais sous-estime systématiquement leur incertitude réelle : des intervalles de confiance trop étroits, une significativité statistique artificiellement gonflée

VOIR AUSSI : VOIR AUSSI : LIRE UNE VALEUR DE P CORRECTEMENT

Le module Méthodes (section Mémoire de recherche) détaille l'interprétation correcte d'une p-value et le risque de pseudo-réplication sur des observations non indépendantes — directement lié à l'autocor-

REMARQUE

ALLER PLUS LOIN : LA RÉGRESSION GÉOGRAPHIQUEMENT PONDÉRÉE (GWR)

Le spatial lag et le spatial error (ci-dessus) corrigent l'autocorrélation mais gardent des coefficients uniques pour toute la zone d'étude. La régression géographiquement pondérée (Geographically Weighted Regression, Fotheringham, Brunsdon & Charlton, 2002) va plus loin : elle ajuste une régression locale différente en chaque point, pondérée par la proximité (encore Tobler), produisant une carte de coefficients qui varient dans l'espace plutôt qu'un coefficient global unique — utile quand la relation entre deux variables (ex. NDVI et précipitations) n'a pas de raison d'être identique partout sur un grand territoire.

APPROFONDISSEMENT

2. ANALYSE DE SEMIS DE POINTS : LA FONCTION K DE RIPLEY

Au-delà de la simple densité (KDE, piste Licence/BUT), la fonction K de Ripley (Ripley, 1976) teste si un semis de points est plus regroupé, plus régulier, ou statistiquement indiscernable d'une répartition complètement aléatoire (CSR, Complete Spatial Randomness — un processus de Poisson spatial) à différentes échelles de distance simultanément, plutôt qu'à une seule échelle fixée d'avance.

FONCTION K DE RIPLEY (ESTIMATEUR EMPIRIQUE)

$$K(h) = (A / n^2) \cdot \sum_i \sum_{j \neq i} 1[d_{ij} \leq h]$$

A = aire de la zone d'étude, n = nombre de points, d_{ij} = distance entre les points i et j, $1[\cdot]$ = 1 si la condition est vraie, 0 sinon. $K(h)$ observé est comparé à sa valeur théorique sous CSR (πh^2) : au-dessus, regroupement à cette distance h ; en dessous, régularité (répulsion) ; proche, absence de structure détectable à cette échelle précise.

EXEMPLE

POURQUOI TESTER PLUSIEURS ÉCHELLES À LA FOIS

Un semis de points peut être regroupé à petite échelle (des feux qui démarrent près des axes routiers, à quelques centaines de mètres) tout en restant réparti de façon quasi aléatoire à grande échelle (aucune région entière plus touchée qu'une autre). La fonction K , en balayant h de façon continue, révèle ce changement d'échelle, invisible à un indice global unique comme le Moran ou une simple densité moyenne.

ATTENTION

LA FONCTION K BRUTE EST SENSIBLE AU BORD DE LA ZONE D'ÉTUDE

Comme les indicateurs locaux ($LISA$, G_i^*), l'estimateur empirique de $K(h)$ sous-compte systématiquement les paires de points proches du bord de la zone d'étude, une partie de leur voisinage réel tombant hors de la zone observée. Les logiciels dédiés (spatstat en R, PySAL en Python) appliquent une correction de bord (ex. correction de Ripley elle-même, ou de translation) avant de comparer $K(h)$ à sa valeur théorique sous CSR — une étape à vérifier, jamais à supposer automatique.

APPROFONDISSEMENT

3. ÉTUDE DE CAS : CARTOGRAPHIER UN RISQUE À PARTIR DE TROIS COUCHES

Une commune dispose de trois couches : un indice d'aléa incendie par cellule de 50 m (issu d'un modèle physique, terrain/végétation/vent), une couche de densité de bâti (enjeux), et un indice de vulnérabilité du bâti (matériaux, âge). Une démarche rigoureuse ne les combine jamais à l'aveugle : elle vérifie d'abord que chaque couche est dans le même système de coordonnées et la même résolution (module Fondements/Projections avancées), documente explicitement la pondération choisie pour les combiner, puis, si l'objectif est de prioriser une action de prévention plutôt que seulement décrire, applique un G_i^* sur le résultat final pour identifier les secteurs où le risque combiné est statistiquement concentré, pas seulement ponctuellement élevé sur une poignée de cellules isolées.

À TOI DE VOIR

À TOI DE VOIR

Sur ce même cas, un collègue propose de calculer directement un indice de Moran global sur la carte de risque combinée pour vérifier « qu'il y a bien une structure spatiale ». En quoi cette étape serait-elle insuffisante par rapport à la démarche décrite ci-dessus, compte tenu de tout ce que ce module a montré sur le local versus le global ?

- Bilan — à retenir : une régression spatiale (retard ou erreur) corrige l'autocorrélation résiduelle qu'une OLS classique ignore, au risque sinon d'une significativité artificiellement gonflée ; la fonction K de Ripley teste un semis de points à toutes les échelles de distance simultanément, pas à une seule ; une cartographie du risque rigoureuse enchaîne cohérence des systèmes de coordonnées, pondération documentée, puis test de concentration (G_i^*) sur le résultat final.

VOIR AUSSI : VOIR EN PRATIQUE : LE RISQUE INCENDIE DE BOUT EN BOUT

Le module Les Secteurs applique cette démarche complète à un cas réel, aléa/enjeux/vulnérabilité inclus.