

DE LA MACHINE QUI APPREND

Comme le cabinet de curiosités range chaque coquillage, chaque tableau, chaque médaille dans une catégorie pour le comprendre, l'algorithme range chaque pixel dans une classe pour lire le paysage.



FIG. V. FRANS FRANCKEN LE JEUNE, « KUNST-
UND RARITÄTENKAMMER », 1636

Filtres à noyau, classification, évaluation de précision, deep learning : la place de l'IA en géomatique et télédétection.

SOMMAIRE

1. LE FILTRE À NOYAU (KERNEL)

2. LE FILTRE PASSE-HAUT : DÉTECTER LES CONTOURS

3. CLASSIFICATION NON SUPERVISÉE

4. CLASSIFICATION SUPERVISÉE

5. SUR-APPRENTISSAGE, SOUS-APPRENTISSAGE ET DÉCOUPAGE DES DONNÉES

6. DU MODÈLE STATISTIQUE AU MACHINE LEARNING

7. RÉSEAUX DE NEURONES ET DEEP LEARNING

8. ARCHITECTURES SPÉCIALISÉES : SEGMENTATION ET ATTENTION

9. OÙ L'IA CHANGE DÉJÀ LA PRATIQUE

10. LIMITES ET VIGILANCE

Le module Les Couleurs s'arrête aux indices, simples ou composés, calculés pixel par pixel. Cette salle va plus loin : comment exploiter le voisinage d'un pixel plutôt que le pixel seul, et comment une machine peut apprendre à reconnaître un type de terrain plutôt que suivre une règle écrite à la main. Chaque partie indique le public auquel elle s'adresse en priorité — les parties « Approfondissement » supposent les précédentes acquises.

VOIR AUSSI : AVANT DE COMMENCER : INDICES COMPOSÉS ET COMPLEXES

Si les notions d'indice composé (Tasseled Cap, ACP) ne sont pas encore vues, elles sont présentées dans le module Les Couleurs.

LYCÉE

1. LE FILTRE À NOYAU (KERNEL)

Imagine une photo légèrement floutée exprès sur une application : chaque pixel de la nouvelle image est calculé en mélangeant le pixel d'origine avec ceux juste autour de lui, plutôt qu'en le recopiant tel quel. C'est exactement ce que fait un filtre à noyau (ou filtre de convolution) sur une image satellite : jusqu'ici, chaque pixel était traité indépendamment de ses voisins ; un filtre à noyau fait l'inverse. Il recalcule la valeur d'un pixel à partir de lui-même et de son voisinage immédiat, pondérés par une petite matrice de coefficients (le noyau), le plus souvent 3×3 .

NOYAU DE LISSAGE (MOYENNE 3×3)

$$1/9 \times \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Remplace chaque pixel par la moyenne de son voisinage 3×3 : effet de flou, utile pour atténuer le bruit d'une image avant un calcul d'indice.

SUPÉRIEUR

2. LE FILTRE PASSE-HAUT : DÉTECTER LES CONTOURS

À l'inverse d'un filtre de lissage (passe-bas), un filtre passe-haut accentue les variations brutales de valeur entre pixels voisins : les contours, les limites de parcelles, les bords de bâtiments. C'est la base de la détection de contours en traitement d'image.

NOYAU DE RENFORCEMENT DES CONTOURS (PASSE-HAUT)

$[[0, -1, 0], [-1, 5, -1], [0, -1, 0]]$

Un pixel isolé, très différent de ses voisins, ressort fortement après ce filtre ; une zone homogène reste quasiment inchangée.




PLANCHE VIII. UN NOYAU 3×3 GLISSÉ SUR LA GRILLE DE PIXELS : CHAQUE PIXEL DE SORTIE DÉPEND DE SON VOISINAGE, PAS DE LUI SEUL.

LYCÉE

3. CLASSIFICATION NON SUPERVISÉE

Classer une image, c'est attribuer une catégorie (forêt, eau, bâti, culture...) à chaque pixel plutôt qu'une simple valeur numérique — un peu comme trier des bonbons de couleurs différentes en tas, sans savoir à l'avance quel tas correspond à quelle saveur : on regroupe d'abord ce qui se ressemble, on identifie le tas après coup. La classification non supervisée fait exactement ça : elle regroupe automatiquement les pixels aux signatures spectrales proches (algorithme des k-moyennes, par exemple), sans qu'aucun exemple étiqueté ne soit fourni au préalable. L'opérateur nomme les classes après coup, en les comparant à des images ou des relevés de terrain.

PRINCIPE DES K-MOYENNES (K-MEANS)

1) placer k centres au hasard 2) assigner chaque pixel au centre le plus proche 3) recalculer chaque centre comme la moyenne de ses pixels 4) répéter 2-3 jusqu'à stabilité

k (le nombre de classes recherchées) est choisi par l'opérateur avant de lancer l'algorithme — un choix arbitraire qui influence fortement le résultat, à documenter dans toute méthode.

SUPÉRIEUR

4. CLASSIFICATION SUPERVISÉE

La classification supervisée part, à l'inverse, d'échantillons d'entraînement : des zones où la classe réelle est déjà connue (relevé de terrain, photo-interprétation). L'algorithme apprend à partir de ces exemples, puis l'applique au reste de l'image. Méthodes classiques : maximum de vraisemblance (fait l'hypothèse d'une distribution statistique par classe), forêts aléatoires (Random Forest, Breiman, 2001 — assemble de nombreux arbres de décision entraînés sur des sous-échantillons aléatoires, dont le vote majoritaire réduit le risque de surapprentissage d'un arbre isolé), machines à vecteurs de support (SVM, Cortes & Vapnik, 1995 — cherche la frontière qui sépare au mieux les classes dans un espace de caractéristiques).

ÉVALUER UNE CLASSIFICATION : LA MATRICE DE CONFUSION

Précision globale = (pixels correctement classés) / (total des pixels de référence)

Une matrice de confusion croise, ligne par ligne, la classe prédite et la classe réelle observée sur le terrain. C'est le standard décrit par Congalton (1991) pour l'évaluation de la précision thématique en télédétection.

	RÉF. FORÊT	RÉF. CULTURE	RÉF. BÂTI	TOTAL PRÉDIT
Prédit Forêt	85	5	0	90
Prédit Culture	10	70	5	85
Prédit Bâti	0	5	20	25
Total référence	95	80	25	200

LE COEFFICIENT KAPPA (COHEN, 1960)

$$\kappa = (Po - Pe) / (1 - Pe)$$

Po = précision observée (les cases diagonales de la matrice ci-dessus, ici $(85+70+20)/200 = 0.875$).
 Pe = précision attendue par pur hasard, calculée à partir des totaux marge de la matrice. Le kappa corrige la précision globale de l'accord qui surviendrait même par une classification aléatoire biaisée par la fréquence des classes : $\kappa = 1$ est un accord parfait, $\kappa = 0$ équivaut au hasard, $\kappa < 0$ est pire que le hasard.




PLANCHE IX. NON SUPERVISÉE : LES CLASSES ÉMERGENT DES DONNÉES.
 SUPERVISÉE : LES CLASSES SONT APPRISSES DEPUIS DES EXEMPLES ÉTIQUETÉS.

SUPÉRIEUR

5. SUR-APPRENTISSAGE, SOUS-APPRENTISSAGE ET DÉCOUPAGE DES DONNÉES

Un modèle qui apprend « trop bien » ses exemples d'entraînement, au point de mémoriser leurs particularités plutôt que la règle générale, est en situation de surapprentissage (overfitting) : sa précision sur les données d'entraînement est excellente, mais s'effondre sur des données nouvelles. À l'inverse, un modèle trop simple pour capturer la structure réelle des données est en sous-apprentissage (underfitting) — ses deux précisions, entraînement et test, restent médiocres.

- Jeu d'entraînement (train) : les exemples sur lesquels le modèle ajuste ses paramètres
- Jeu de validation : sert à régler les hyperparamètres (profondeur d'un arbre, nombre de couches d'un réseau) sans jamais toucher au jeu de test
- Jeu de test : n'est utilisé qu'une seule fois, à la toute fin, pour estimer la performance réelle du modèle sur des données jamais vues

- Validation croisée (k-fold) : répète l'entraînement/test sur k découpages différents des mêmes données, pour obtenir une estimation de performance moins dépendante d'un découpage particulier

ATTENTION

UNE FUITE DE DONNÉES (DATA LEAKAGE) INVALIDE TOUTE L'ÉVALUATION

Si des pixels du jeu de test proviennent de la même parcelle, voire du même pixel voisin, qu'un exemple du jeu d'entraînement, la précision mesurée est artificiellement gonflée : le modèle n'a pas appris à généraliser, il a simplement retrouvé un voisin quasi identique. En télédétection, découper spatialement (par parcelle ou par zone entière, jamais pixel par pixel au hasard) est indispensable pour une évaluation honnête.

SUPÉRIEUR

6. DU MODÈLE STATISTIQUE AU MACHINE LEARNING

Le maximum de vraisemblance et la régression logistique multinomiale (un modèle statistique classique qui prédit la probabilité d'appartenance à chacune de plusieurs classes) sont les ancêtres directs du machine learning moderne : même principe (apprendre une règle à partir de données), formalisation mathématique plus explicite, mais moins de capacité à capturer des relations complexes que les méthodes qui ont suivi.

APPROFONDISSEMENT

7. RÉSEAUX DE NEURONES ET DEEP LEARNING

Un réseau de neurones convolutif (CNN) reprend le principe du filtre à noyau de la partie 1, mais avec une différence essentielle : au lieu de fixer les coefficients du noyau à la main (moyenne, contours...), le réseau les apprend automatiquement à partir de milliers d'images d'entraînement (LeCun et al., 2015, revue de référence Nature). Empilées sur plusieurs couches, ces convolutions apprises détectent d'abord des motifs simples (contours, textures), puis des structures de plus en plus complexes (un bâtiment, une route, une parcelle agricole).

CE QUE LE RÉSEAU OPTIMISE RÉELLEMENT : LA FONCTION DE PERTE

Entropie croisée : $L = - \sum_c y_c \cdot \log(\hat{y}_c)$

$y_c = 1$ si la classe réelle du pixel est c , 0 sinon (encodage "one-hot") ; $\hat{y}_c$ = probabilité prédite par le réseau pour cette classe. L'entraînement (rétropropagation du gradient, descente de gradient stochastique) ajuste les coefficients du réseau pour minimiser cette perte sur le jeu d'entraînement — c'est cette quantité, pas la précision elle-même, que le réseau optimise directement à chaque itération ; la précision n'est qu'une mesure de suivi calculée à côté.




PLANCHE X. SCHÉMA DE PRINCIPE D'UN RÉSEAU À PLUSIEURS COUCHES : CHAQUE COUCHE RECOMBINE LES SORTIES DE LA PRÉCÉDENTE.

ATTENTION

LE DEEP LEARNING NE REMPLACE PAS LES PARTIES PRÉCÉDENTES

Un CNN entraîné sur de l'imagerie satellite reste souvent alimenté par les mêmes indices et bandes que les méthodes classiques : NDVI, NDMI, bandes brutes. Comprendre ce qu'un indice mesure physiquement reste indispensable pour interpréter, corriger ou faire confiance à ce qu'un modèle produit.

APPROFONDISSEMENT


8. ARCHITECTURES SPÉCIALISÉES : SEGMENTATION ET ATTENTION

Un CNN de classification produit une seule étiquette par image ou par petite fenêtre. Pour délimiter précisément chaque bâtiment ou chaque parcelle pixel par pixel (segmentation sémantique), l'architecture U-Net (Ronneberger et al., 2015, conçue à l'origine pour l'imagerie biomédicale, aujourd'hui un standard aussi en télédétection) combine un chemin qui réduit la résolution spatiale pour capturer le contexte large, et un chemin symétrique qui la restaure pour produire une carte de sortie à la même résolution que l'image d'entrée, avec des connexions directes entre les deux qui préservent le détail fin des contours.

ÉVALUER UNE SEGMENTATION : L'IOU (INTERSECTION OVER UNION), PAS LE KAPPA

$$\text{IoU} = \text{Aire}(\text{prédiction} \cap \text{vérité terrain}) / \text{Aire}(\text{prédiction} \cup \text{vérité terrain})$$

Le kappa et la précision globale (section 4) évaluent une classification pixel par pixel indépendamment de la géométrie ; ils sont mal adaptés à une segmentation, où ce qui compte est le recouvrement entre la forme prédite et la forme réelle d'un objet (un bâtiment). L'IoU (auss appelé indice de Jaccard) vaut 1 pour un recouvrement parfait, 0 pour aucun recouvrement — c'est la métrique standard des benchmarks de segmentation (dont U-Net lui-même a été évalué). Le F1-score (moyenne harmonique de la précision et du rappel) est l'autre métrique de référence, plus adaptée quand les classes sont très déséquilibrées (ex. peu de pixels "bâtiment" au milieu de beaucoup de pixels "fond").



$$\text{IoU} = \text{aire la plus foncée} / \text{aire totale coloriée}$$

1 = recouvrement parfait · 0 = aucun recouvrement

PLANCHE XIV. L'IOU VISUELLEMENT : LE RAPPORT ENTRE LA ZONE DE RECOUVREMENT (INTERSECTION) ET L'ENSEMBLE DES DEUX ZONES COLORÉES (UNION) .

Plus récemment, les architectures Transformer (Vaswani et al., 2017, mécanisme d'attention initialement conçu pour le traitement du langage) ont été adaptées à l'image (Vision Transformer, Dosovitskiy et al., 2021) puis spécifiquement à l'imagerie satellite multi-bandes et multi-temporelle. Des modèles fondateurs pré-entraînés sur de très larges archives Sentinel-2/Landsat (par exemple Prithvi de la NASA/IBM, ou SatMAE) commencent à être

réutilisés par transfert d'apprentissage plutôt que ré-entraînés de zéro pour chaque nouvelle tâche — une évolution encore active du domaine, à considérer comme un axe de recherche en cours plutôt qu'un standard stabilisé.

REMARQUE

LE TRANSFERT D'APPRENTISSAGE (TRANSFER LEARNING)

Ré-entraîner un réseau profond de zéro nécessite des dizaines de milliers d'exemples étiquetés, rarement disponibles pour un projet précis. Le transfert d'apprentissage part d'un modèle déjà entraîné sur une tâche large (classification générale d'images, ou un modèle fondateur satellite), puis ne ré-ajuste que ses dernières couches sur un jeu de données spécifique, beaucoup plus petit — une pratique aujourd'hui standard, qui réduit d'un facteur souvent supérieur à 10 le volume de données d'entraînement nécessaire.

SUPÉRIEUR

9. OÙ L'IA CHANGE DÉJÀ LA PRATIQUE

- Classification automatique de l'occupation du sol à l'échelle nationale, mise à jour annuelle plutôt que tous les dix ans
- Détection de changement automatisée (déforestation, urbanisation) sur de longues séries temporelles, impossible à examiner manuellement image par image
- Segmentation sémantique : délimiter automatiquement chaque bâtiment, chaque parcelle, chaque route sur une image, plutôt que de simplement les classer
- Fusion de données multi-capteurs (optique, radar, LiDAR) apprise plutôt que combinée par des règles fixes

EXEMPLE

OÙ S'ENTRAÎNER SUR DES DONNÉES RÉELLES ET UN JEU DE RÉFÉRENCE

La recherche en télédétection compare ses modèles sur des jeux de données publics de référence, plutôt que sur des données propriétaires impossibles à reproduire : BigEarthNet (590 000 patches Sentinel-1/2 annotés par occupation du sol, Sumbul et al., 2019), EuroSAT (27 000 patches Sentinel-2, 10 classes, conçu comme benchmark d'entrée simple), SEN12MS (données appariées Sentinel-1/Sentinel-2/MODIS pour

la fusion multi-capteurs). Ces jeux permettent de comparer une nouvelle méthode à l'état de l'art publié sur un pied d'égalité — la même logique qu'un jeu de test indépendant (module Travaux pratiques), mais partagé par toute une communauté de recherche plutôt que propre à un seul projet.

APPROFONDISSEMENT

10. LIMITES ET VIGILANCE

ATTENTION

CE QUE L'IA EN TÉLÉDÉTECTION NE RÉSOUT PAS AUTOMATIQUEMENT

Un modèle appris sur des données d'une région ou d'une saison se généralise mal ailleurs si le paysage ou l'éclairage diffère (biais du jeu d'entraînement, décalage de distribution ou "domain shift"). Un réseau profond reste largement une boîte noire : difficile d'expliquer pourquoi un pixel précis a été classé d'une certaine façon, ce qui pose un vrai problème dans un usage réglementaire ou juridique — un enjeu qui a donné naissance à un sous-champ actif, l'IA explicable (XAI). Enfin, aucun modèle ne remplace la vérité terrain : il faut toujours des relevés réels pour entraîner et vérifier un modèle, jamais seulement d'autres prédictions.

VOIR AUSSI : PRATIQUER : CLASSIFICATION SUPERVISÉE ET ÉVALUATION DE PRÉCISION

La séance 6 de l'Atelier applique la matrice de confusion et le kappa présentés ici sur un cas réel, avec corrigé.