

DE LA MACHINE QUI APPREND

Comme le cabinet de curiosités range chaque coquillage, chaque tableau, chaque médaille dans une catégorie pour le comprendre, l'algorithme range chaque pixel dans une classe pour lire le paysage.



FIG. XI. FRANS FRANCKEN LE JEUNE, « KUNST-UND RARITÄTENKAMMER », 1636

Filtres à noyau, classification, évaluation de précision, deep learning : la place de l'IA en géomatique et télédétection.

SOMMAIRE

1. RÉSEAUX DE NEURONES ET DEEP LEARNING

2. ARCHITECTURES SPÉCIALISÉES : SEGMENTATION ET ATTENTION

3. LIMITES ET VIGILANCE

Le module Les Couleurs s'arrête aux indices, simples ou composés, calculés pixel par pixel. Cette salle va plus loin : comment exploiter le voisinage d'un pixel plutôt que le pixel seul, et comment une machine peut apprendre à reconnaître un type de terrain plutôt que suivre une règle écrite à la main. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : INDICES COMPOSÉS ET COMPLEXES

Si les notions d'indice composé (Tasseled Cap, ACP) ne sont pas encore vues, elles sont présentées dans le module Les Couleurs.

APPROFONDISSEMENT

1. RÉSEAUX DE NEURONES ET DEEP LEARNING

BRIQUE – DEEP LEARNING : CNN

Un réseau de neurones convolutif (CNN) reprend le principe du filtre à noyau, mais avec une différence essentielle : au lieu de fixer les coefficients du noyau à la main (moyenne, contours...), le réseau les apprend automatiquement à partir de milliers d'images d'entraînement (LeCun et al., 2015, revue de référence Nature). Empilées sur plusieurs couches, ces convolutions apprises détectent d'abord des motifs simples (contours, textures), puis des structures de plus en plus complexes (un bâtiment, une route, une parcelle agricole).

CE QUE LE RÉSEAU OPTIMISE RÉELLEMENT : LA FONCTION DE PERTE

Entropie croisée : $L = - \sum_c y_c \cdot \log(\hat{y}_c)$

$y_c = 1$ si la classe réelle du pixel est c , 0 sinon (encodage "one-hot") ; $\hat{y}_c$ = probabilité prédite par le réseau pour cette classe. L'entraînement (rétropropagation du gradient, descente de gradient stochastique) ajuste les coefficients du réseau pour minimiser cette perte sur le jeu d'entraînement : c'est cette quantité, pas la précision elle-même, que le réseau optimise directement à chaque itération ; la précision n'est qu'une mesure de suivi calculée à côté.




PLANCHE X. SCHÉMA DE PRINCIPE D'UN RÉSEAU À PLUSIEURS COUCHES : CHAQUE COUCHE RECOMBINE LES SORTIES DE LA PRÉCÉDENTE.

ATTENTION

LE DEEP LEARNING NE REMPLACE PAS LES MÉTHODES CLASSIQUES

Un CNN entraîné sur de l'imagerie satellite reste souvent alimenté par les mêmes indices et bandes que les méthodes classiques : NDVI, NDMI, bandes brutes. Comprendre ce qu'un indice mesure physiquement reste indispensable pour interpréter, corriger ou faire confiance à ce qu'un modèle produit.

APPROFONDISSEMENT


2. ARCHITECTURES SPÉCIALISÉES : SEGMENTATION ET ATTENTION

Un CNN de classification produit une seule étiquette par image ou par petite fenêtre. Pour délimiter précisément chaque bâtiment ou chaque parcelle pixel par pixel (segmentation sémantique), l'architecture U-Net (Ronneberger et al., 2015, conçue à l'origine pour l'imagerie biomédicale, aujourd'hui un standard aussi en télédétection) combine un chemin qui réduit la résolution spatiale pour capturer le contexte large, et un chemin symétrique qui la restaure pour produire une carte de sortie à la même résolution que l'image d'entrée, avec des connexions directes entre les deux qui préservent le détail fin des contours.

ÉVALUER UNE SEGMENTATION : L'IOU (INTERSECTION OVER UNION), PAS LE KAPPA

$$\text{IoU} = \frac{\text{Aire}(\text{prédiction} \cap \text{vérité terrain})}{\text{Aire}(\text{prédiction} \cup \text{vérité terrain})}$$

Le kappa et la précision globale évaluent une classification pixel par pixel indépendamment de la géométrie ; ils sont mal adaptés à une segmentation, où ce qui compte est le recouvrement entre la forme prédite et la forme réelle d'un objet (un bâtiment). L'IoU (aussi appelé indice de Jaccard) vaut 1 pour un recouvrement parfait, 0 pour aucun recouvrement : c'est la métrique standard des benchmarks de segmentation (dont U-Net lui-même a été évalué). Le F1-score (moyenne harmonique de la précision et du rappel) est l'autre métrique de référence, plus adaptée quand les classes sont très déséquilibrées (ex. peu de pixels "bâtiment" au milieu de beaucoup de pixels "fond").



$$\text{IoU} = \text{aire la plus foncée} / \text{aire totale coloriée}$$

1 = recouvrement parfait · 0 = aucun recouvrement

PLANCHE XIV. L'IOU VISUELLEMENT : LE RAPPORT ENTRE LA ZONE DE RECOUVREMENT (INTERSECTION) ET L'ENSEMBLE DES DEUX ZONES COLORÉES (UNION) .

Plus récemment, les architectures Transformer (Vaswani et al., 2017, mécanisme d'attention initialement conçu pour le traitement du langage) ont été adaptées à l'image (Vision Transformer, Dosovitskiy et al., 2021) puis spécifiquement à l'imagerie satellite multi-bandes et multi-temporelle. Des modèles fondateurs pré-entraînés sur de très larges archives Sentinel-2/Landsat (par exemple Prithvi de la NASA/IBM, ou SatMAE) commencent à être réutilisés par transfert d'apprentissage plutôt que ré-entraînés de zéro pour chaque nouvelle tâche, une évolution encore active du domaine, à considérer comme un axe de recherche en cours plutôt qu'un standard stabilisé.

REMARQUE

LE TRANSFERT D'APPRENTISSAGE (TRANSFER LEARNING)

Ré-entraîner un réseau profond de zéro nécessite des dizaines de milliers d'exemples étiquetés, rarement disponibles pour un projet précis. Le transfert d'apprentissage part d'un modèle déjà entraîné sur une tâche large (classification générale d'images, ou un modèle fondateur satellite), puis ne ré-ajuste que ses dernières couches sur un jeu de données spécifique, beaucoup plus petit, une pratique aujourd'hui standard, qui réduit d'un facteur souvent supérieur à 10 le volume de données d'entraînement nécessaire.

APPROFONDISSEMENT

3. LIMITES ET VIGILANCE

ATTENTION

CE QUE L'IA EN TÉLÉDÉTECTION NE RÉSOUT PAS AUTOMATIQUEMENT

Un modèle appris sur des données d'une région ou d'une saison se généralise mal ailleurs si le paysage ou l'éclairage diffère (biais du jeu d'entraînement, décalage de distribution ou "domain shift"). Un réseau profond reste largement une boîte noire : difficile d'expliquer pourquoi un pixel précis a été classé d'une certaine façon, ce qui pose un vrai problème dans un usage réglementaire ou juridique : un enjeu qui a donné naissance à un sous-champ actif, l'IA explicable (XAI). Enfin, aucun modèle ne remplace la vérité terrain : il faut toujours des relevés réels pour entraîner et vérifier un modèle, jamais seulement d'autres prédictions.

À TOI DE VOIR

À TOI DE VOIR

Un modèle de classification d'occupation du sol entraîné exclusivement sur des images de printemps en Bretagne est appliqué tel quel à des images d'été en Provence. Identifie au moins deux raisons distinctes, parmi celles évoquées dans cette section, pour lesquelles sa précision risque de chuter — et ce qu'il faudrait changer dans le protocole d'entraînement pour l'éviter.

- Bilan — à retenir : un CNN apprend ses noyaux de convolution au lieu de les fixer à la main ; l'entropie croisée, pas la précision, est ce que le réseau minimise réellement ; U-Net segmente pixel par pixel (évalué par IoU, pas par kappa) ; les Transformers/modèles fondateurs (Prithvi, SatMAE) se réutilisent par transfert d'apprentissage ; domain shift, boîte noire et absence de vérité terrain restent des limites réelles, pas de simples détails techniques.

VOIR AUSSI : PRATIQUER : CLASSIFICATION SUPERVISÉE ET ÉVALUATION DE PRÉCISION

La séance 6 de l'Atelier applique la matrice de confusion et le kappa présentés ici sur un cas réel, avec corrigé.

