

DE LA MACHINE QUI APPREND

Comme le cabinet de curiosités range chaque coquillage, chaque tableau, chaque médaille dans une catégorie pour le comprendre, l'algorithme range chaque pixel dans une classe pour lire le paysage.



FIG. XVII. FRANS FRANCKEN LE JEUNE, « KUNST-UND RARITÄTENKAMMER », 1636

Filtres à noyau, classification, évaluation de précision, deep learning : la place de l'IA en géomatique et télédétection.

SOMMAIRE

1. FILTRES DE CONVOLUTION : LISSAGE ET DÉTECTION DE CONTOURS

2. CLASSIFICATION NON SUPERVISÉE ET SUPERVISÉE

3. ÉVALUER UNE CLASSIFICATION : MATRICE DE CONFUSION ET KAPPA

4. SUR-APPRENTISSAGE, SOUS-APPRENTISSAGE ET DÉCOUPAGE DES DONNÉES

5. DU MODÈLE STATISTIQUE AU MACHINE LEARNING

6. OÙ L'IA CHANGE DÉJÀ LA PRATIQUE

Le module Les Couleurs s'arrête aux indices, simples ou composés, calculés pixel par pixel. Cette salle va plus loin : comment exploiter le voisinage d'un pixel plutôt que le pixel seul, et comment une machine peut apprendre à reconnaître un type de terrain plutôt que suivre une règle écrite à la main. Trois pistes complètes ci-dessous (choisis la tienne dans le filtre « Afficher ») : chacune se lit seule, du début à la fin.

VOIR AUSSI : AVANT DE COMMENCER : INDICES COMPOSÉS ET COMPLEXES

Si les notions d'indice composé (Tasseled Cap, ACP) ne sont pas encore vues, elles sont présentées dans le module Les Couleurs.

1. FILTRES DE CONVOLUTION : LISSAGE ET DÉTECTION DE CONTOURS

BRIQUE – FILTRES À NOYAU (KERNEL)

Jusqu'ici, chaque pixel était traité indépendamment de ses voisins ; un filtre à noyau (ou filtre de convolution) fait l'inverse. Il recalcule la valeur d'un pixel à partir de lui-même et de son voisinage immédiat, pondérés par une petite matrice de coefficients (le noyau), le plus souvent 3×3 .

NOYAU DE LISSAGE (MOYENNE 3×3)

$$1/9 \times \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Remplace chaque pixel par la moyenne de son voisinage 3×3 : effet de flou, utile pour atténuer le bruit d'une image avant un calcul d'indice.

À l'inverse d'un filtre de lissage (passe-bas), un filtre passe-haut accentue les variations brutales de valeur entre pixels voisins : les contours, les limites de parcelles, les bords de bâtiments. C'est la base de la détection de contours en traitement d'image.

NOYAU DE RENFORCEMENT DES CONTOURS (PASSE-HAUT)

$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

Un pixel isolé, très différent de ses voisins, ressort fortement après ce filtre ; une zone homogène reste quasiment inchangée.




PLANCHE VIII. UN NOYAU 3×3 GLISSÉ SUR LA GRILLE DE PIXELS : CHAQUE PIXEL DE SORTIE DÉPEND DE SON VOISINAGE, PAS DE LUI SEUL.

SUPÉRIEUR

2. CLASSIFICATION NON SUPERVISÉE ET SUPERVISÉE

La classification non supervisée regroupe automatiquement les pixels aux signatures spectrales proches (algorithme des k-moyennes), sans qu'aucun exemple étiqueté ne soit fourni au préalable ; l'opérateur nomme les classes après coup. La classification supervisée part, à l'inverse, d'échantillons d'entraînement : des zones où la classe réelle est déjà connue (relevé de terrain, photo-interprétation). L'algorithme apprend à partir de ces exemples, puis l'applique au reste de l'image.

🔗 RAPPEL

RAPPEL : SIGNATURE SPECTRALE ET INDICES (MODULE LES COULEURS)

Le module Les Couleurs définit la signature spectrale d'un pixel comme sa réflectance sur plusieurs bandes, combinée le cas échéant en un indice comme le NDVI. C'est cette signature — pas une couleur perçue à l'œil — que la classification regroupe ou apprend à reconnaître ici, qu'elle soit non supervisée (k-moyennes) ou supervisée.

PRINCIPE DES K-MOYENNES (K-MEANS)

1) placer k centres au hasard 2) assigner chaque pixel au centre le plus proche 3) recalculer chaque centre comme la moyenne de ses pixels 4) répéter 2-3 jusqu'à stabilité

k (le nombre de classes recherchées) est choisi par l'opérateur avant de lancer l'algorithme, un choix arbitraire qui influence fortement le résultat, à documenter dans toute méthode.

Méthodes supervisées classiques : maximum de vraisemblance (fait l'hypothèse d'une distribution statistique par classe), forêts aléatoires (Random Forest, Breiman, 2001, assemblée de nombreux arbres de décision entraînés sur des sous-échantillons aléatoires, dont le vote majoritaire réduit le risque de surapprentissage d'un arbre isolé), machines à vecteurs de support (SVM, Cortes & Vapnik, 1995, cherche la frontière qui sépare au mieux les classes dans un espace de caractéristiques).




PLANCHE IX. NON SUPERVISÉE : LES CLASSES ÉMERGENT DES DONNÉES. SUPERVISÉE : LES CLASSES SONT APPRISSES DEPUIS DES EXEMPLES ÉTIQUETÉS.

SUPÉRIEUR

3. ÉVALUER UNE CLASSIFICATION : MATRICE DE CONFUSION ET KAPPA

BRIQUE – CLASSIFICATION ET MATRICE DE CONFUSION

ÉVALUER UNE CLASSIFICATION : LA MATRICE DE CONFUSION

Précision globale = (pixels correctement classés) /
(total des pixels de référence)

Une matrice de confusion croise, ligne par ligne, la classe prédite et la classe réelle observée sur le terrain. C'est le standard décrit par Congalton (1991) pour l'évaluation de la précision thématique en télédétection.

	RÉF. FORÊT	RÉF. CULTURE	RÉF. BÂTI	TOTAL PRÉDI
Prédit Forêt	85	5	0	90
Prédit Culture	10	70	5	85
Prédit Bâti	0	5	20	25
Total référence	95	80	25	200

LE COEFFICIENT KAPPA (COHEN, 1960)

$$\kappa = (Po - Pe) / (1 - Pe)$$

Po = précision observée (les cases diagonales de la matrice ci-dessus, ici $(85+70+20)/200 = 0.875$). Pe = précision attendue par pur hasard, calculée à partir des totaux marge de la matrice. Le kappa corrige la précision globale de l'accord qui surviendrait même par une classification aléatoire biaisée par la fréquence des classes : $\kappa = 1$ est un accord parfait, $\kappa = 0$ équivaut au hasard, $\kappa < 0$ est pire que le hasard.

SUPÉRIEUR

4. SUR-APPRENTISSAGE, SOUS-APPRENTISSAGE ET DÉCOUPAGE DES DONNÉES

Un modèle qui apprend « trop bien » ses exemples d'entraînement, au point de mémoriser leurs particularités plutôt que la règle générale, est en situation de surapprentissage (overfitting) : sa précision sur les données d'entraînement est excellente, mais s'effondre sur des données nouvelles. À l'inverse, un modèle trop simple pour capturer la structure réelle des données est en sous-apprentissage (underfitting) : ses deux précisions, entraînement et test, restent médiocres.

- Jeu d'entraînement (train) : les exemples sur lesquels le modèle ajuste ses paramètres
- Jeu de validation : sert à régler les hyperparamètres (profondeur d'un arbre, nombre de couches d'un réseau) sans jamais toucher au jeu de test
- Jeu de test : n'est utilisé qu'une seule fois, à la toute fin, pour estimer la performance réelle du modèle sur des données jamais vues
- Validation croisée (k-fold) : répète l'entraînement/test sur k découpages différents des mêmes données, pour obtenir une estimation de performance moins dépendante d'un découpage particulier

ATTENTION

UNE FUITE DE DONNÉES (DATA LEAKAGE) INVALIDE TOUTE L'ÉVALUATION

Si des pixels du jeu de test proviennent de la même parcelle, voire du même pixel voisin, qu'un exemple du jeu d'entraînement, la précision mesurée est artificiellement gonflée : le modèle n'a pas appris à généraliser, il a simplement retrouvé un voisin quasi identique. En télédétection, découper spatialement (par parcelle ou par zone entière, jamais pixel par pixel au hasard) est indispensable pour une évaluation honnête.

SUPÉRIEUR

5. DU MODÈLE STATISTIQUE AU MACHINE LEARNING

Le maximum de vraisemblance et la régression logistique multinomiale (un modèle statistique classique qui prédit la probabilité d'appartenance à chacune de plusieurs classes)

sont les ancêtres directs du machine learning moderne : même principe (apprendre une règle à partir de données), formalisation mathématique plus explicite, mais moins de capacité à capturer des relations complexes que les méthodes qui ont suivi.

SUPÉRIEUR

6. OÙ L'IA CHANGE DÉJÀ LA PRATIQUE

- Classification automatique de l'occupation du sol à l'échelle nationale, mise à jour annuelle plutôt que tous les dix ans
- Détection de changement automatisée (déforestation, urbanisation) sur de longues séries temporelles, impossible à examiner manuellement image par image
- Segmentation sémantique : délimiter automatiquement chaque bâtiment, chaque parcelle, chaque route sur une image, plutôt que de simplement les classer
- Fusion de données multi-capteurs (optique, radar, LiDAR) apprise plutôt que combinée par des règles fixes

EXEMPLE

OÙ S'ENTRAÎNER SUR DES DONNÉES RÉELLES ET UN JEU DE RÉFÉRENCE

La recherche en télédétection compare ses modèles sur des jeux de données publics de référence, plutôt que sur des données propriétaires impossibles à reproduire : BigEarthNet (590 000 patches Sentinel-2 annotés par occupation du sol, Sumbul et al., 2019 ; étendu à Sentinel-1 dans la variante BigEarthNet-MM), EuroSAT (27 000 patches Sentinel-2, 10 classes, conçu comme benchmark d'entrée simple), SEN12MS (données appariées Sentinel-1/Sentinel-2/MODIS pour la fusion multi-capteurs). Ces jeux permettent de comparer une nouvelle méthode à l'état de l'art publié sur un pied d'égalité : la même logique qu'un jeu de test indépendant, mais partagé par toute une communauté de recherche plutôt que propre à un seul projet.

À TOI DE JOUER

MACHINE ET VOCABULAIRE

Associer chaque terme d'apprentissage automatique à sa définition.

- Bilan — à retenir : un filtre passe-bas lisse, un filtre passe-haut accentue les contours ; classification non supervisée (sans exemples) vs supervisée (avec exemples étiquetés) ; la matrice de confusion et le kappa évaluent une classification, le kappa corrige l'accord dû au hasard ; train/validation/test évitent le sur-apprentissage, jamais de fuite de données spatiale ; des jeux publics (BigEarthNet, EuroSAT) permettent de comparer les méthodes entre équipes.

VOIR AUSSI : PRATIQUER : CLASSIFICATION SUPERVISÉE ET ÉVALUATION DE PRÉCISION

La séance 6 de l'Atelier applique la matrice de confusion et le kappa présentés ici sur un cas réel, avec corrigé.