

LE CABINET DE L'APPRENTI

Ortelius a rassemblé cartes et méthode en un atlas : le premier assemblage cohérent d'un savoir jusque-là dispersé. Ces travaux pratiques ont le même objectif.



FIG. VII. ABRAHAM ORTELIUS, « TYPUS ORBIS TERRARUM », 1570

Neuf séances pratiques complètes, chacune autonome et corrigée : géoréférencement, indices, classification, réseau de neurones, radar, krigeage, mini-projet.

SOMMAIRE

LE JEU DE DONNÉES CANONIQUE : UNE VRAIE SCÈNE
SENTINEL-2

SÉANCE 1 : CARTOGRAPHIE DE BASE SOUS QGIS

SÉANCE 2 : GÉORÉFÉRENCER UNE IMAGE PAR GRILLE

SÉANCE 3 : DE L'IMAGE GÉORÉFÉRENCÉE À L'INDICE
COMPOSÉ

SÉANCE 4 : ANALYSE SPATIALE, BUFFER ET INTERSECTION

BONUS SÉANCE 4 : LA MÊME QUESTION, SUR UNE DONNÉE
VIVANTE

SÉANCE 5 : PROGRAMMATION GÉOSPATIALE SIMPLE

SÉANCE 6 : CLASSIFICATION SUPERVISÉE ET ÉVALUATION DE
PRÉCISION

SÉANCE 7 : CLASSIFICATION PAR RÉSEAU DE NEURONES
SIMPLE

SÉANCE 8 : RADAR ET INTERPOLATION SPATIALE

SÉANCE 9 : ÉTUDE DE CAS ET MINI-PROJET FINAL

SÉANCE 10 : COMMENTER UN DOCUMENT CARTOGRAPHIQUE

SÉANCE 11 : AUDITER LA QUALITÉ D'UN JEU DE DONNÉES SIG

SÉANCE 12 : VALIDER STATISTIQUEMENT UNE CLASSIFICATION

Chaque séance ci-dessous est autonome : elle peut constituer un TP complet à elle seule, avec son objectif, ses exercices à plusieurs niveaux, ses ressources et un corrigé dépliant. Elles sont néanmoins conçues pour s'enchaîner, en particulier les séances 2 et 3, qui réutilisent directement le résultat l'une de l'autre. Utilise le module La Méthode pour la structure attendue d'un compte-rendu ou d'un rapport, et le module Références pour les sources de données et de documentation. Le corrigé de chaque séance est volontairement masqué par défaut : chercher d'abord, comparer ensuite, c'est la vérification qui consolide l'apprentissage, pas la lecture seule de la réponse.




PLANCHE VII. LE FIL DIRECTEUR DES SÉANCES : DE LA DONNÉE BRUTE GÉORÉFÉRENCÉE JUSQU'À LA CARTE DE SYNTHÈSE ET SON RAPPORT.

LE JEU DE DONNÉES CANONIQUE : UNE VRAIE SCÈNE SENTINEL-2

Plutôt que de renvoyer vers « télécharge une image quelque part », plusieurs séances ci-dessous (3, 5, 6, 7, 9) s'appuient sur un même jeu de données réel, extrait directement de l'archive Copernicus et fourni avec le site : une scène Sentinel-2 authentique, quasiment sans nuage, sur une emprise de $3,2 \times 3,3$ km à Vitrolles (Bouches-du-Rhône), qui mélange volontairement bâti dense, infrastructure aéroportuaire, végétation de garrigue et une portion de l'étang de Berre, de quoi illustrer chaque indice du module Les Couleurs sur un seul et même territoire.



COMPOSITION COULEUR NATURELLE

Scène S2B_31TFJ_20240806_0_L2A (6 août 2024, 0.008 % de nuages). Étang de Berre en haut à gauche, tissu urbain de Vitrolles à droite, piste de l'aéroport Marseille-Provence en bas à gauche.



NDVI CALCULÉ

Même image, formule du module Les Couleurs : le contraste végétation (vert) / bâti-piste-eau (blanc à marron) saute aux yeux sans interprétation nécessaire.

FICHIER	CONTENU
sentinel2_2024-08-06_vitrolles_bands.tif	6 bandes réelles en réflectance de surface (0–1) : bleu, vert, rouge, red-edge (B5), NIR, SWIR (B11), EPSG:2154, 10 m
sentinel2_2024-08-06_vitrolles_indices.tif	NDVI, NDMI, NDBI, NDRE, NDWI déjà calculés, en 5 bandes, pour vérifier un calcul plutôt que le refaire
emprise.geojson	Polygone exact de l'emprise, pour un découpage (clip) propre
grille_100m_indices.geojson	1122 cellules de 100 m avec la moyenne réelle de NDVI/NDMI/NDBI par cellule, résultat de référence pour la séance 3
stats.json	Statistiques réelles (min/max/moyenne/écart-type) de chaque indice sur toute l'emprise
classification_reference.json	Classification SCL réelle à 3 classes, découpage train/test et matrices de confusion Random Forest/MLP, référence pour la séance 6

VOIR AUSSI : TÉLÉCHARGER LES 6 FICHIERS

Page dédiée avec un lien de téléchargement direct par fichier — pas besoin de reconstituer l'URL à la main.

ACCÈS DIRECT AUX FICHIERS

`/data/sample-vitrolles-2024/<nom-du-fichier>`

Les 6 fichiers du tableau ci-dessus sont aussi servis statiquement par le site à cette adresse relative (ex. `/data/sample-vitrolles-2024/emprise.geojson`) — pratique pour les charger directement dans QGIS (Couche > Ajouter une couche) via l'URL complète du site, sans passer par un téléchargement local.

REMARQUE

ORIGINE ET LICENCE DE CETTE IMAGE

Scène S2B_31TFJ_20240806_0_L2A, extraite du catalogue public Sentinel-2 L2A hébergé sur AWS (Element84 Earth Search STAC, sentinel-cogs, accès direct sans authentification), les données sources proviennent du programme Copernicus de l'Union européenne et de l'ESA. Conformément à la politique de données

Copernicus (libre, complète et gratuite), toute réutilisation doit porter la mention « Contains modified Copernicus Sentinel data [2024] ».

EXEMPLE

VALEURS RÉELLES DE RÉFÉRENCE (CALCULÉES SUR TOUTE L'EMPRISE)

NDVI : moyenne 0.33, écart-type 0.30 (de -1.0 à 1.0 selon les pixels). NDMI : moyenne -0.09, écart-type 0.16. NDBI : moyenne +0.09 (symétrique du NDMI, comme attendu de la formule). NDRE : moyenne 0.16. NDWI : moyenne -0.47, cohérent avec un territoire majoritairement non aquatique, comportant une portion d'étang. Ces chiffres, pas des estimations, servent de repère pour vérifier un calcul personnel : un NDVI moyen très éloigné de 0.33 sur cette même emprise signale une erreur de calcul (mauvaises bandes, mauvais CRS, image non corrigée), pas une variante légitime.

LYCÉE

SÉANCE 1 : CARTOGRAPHIE DE BASE SOUS QGIS

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Manipuler dans l'ordre les quatre gestes de base de tout projet SIG : charger une donnée, vérifier son système de coordonnées, la styliser selon un attribut, la mettre en page pour la communiquer. Ce sont les gestes qui reviennent dans toutes les séances suivantes.

1. Télécharger un jeu de données vecteur public (ex. limites communales sur data.gouv.fr, format GeoJSON ou Shapefile)
2. Charger la couche dans QGIS (glisser-déposer, ou Couche > Ajouter une couche)
3. Vérifier le CRS du projet et le reprojecter en EPSG:2154 (Lambert-93) si nécessaire
4. Ouvrir la table attributaire, identifier un champ numérique pertinent (ex. population, superficie)

5. Appliquer une symbologie graduée sur ce champ (Propriétés de la couche > Symbologie > Graduée), en choisissant une variable visuelle cohérente avec la nature de la donnée (voir module La Méthode, sémiologie graphique)
6. Ajouter une légende, une échelle et une flèche du nord via la mise en page d'impression

DÉCOUVERTE

- Une seule couche, une seule classe de symbologie
- Légende et échelle suffisent pour valider la séance

APPROFONDISSEMENT

- Superposer une deuxième couche (ex. cours d'eau) avec sa propre symbologie
- Justifier par écrit le choix de la palette de couleur (voir module La Méthode, critique du document)

CORRIGÉ : SÉANCE 1

Une donnée numérique continue (population, superficie) se porte par la variable visuelle valeur (dégradé clair → foncé d'une même teinte) ou par la taille (ronds proportionnels), jamais par une palette de teintes qualitatives sans ordre, voir le module La Méthode, section sémiologie graphique. Une classification par quantiles (autant d'entités par classe) donne en général une carte plus lisible qu'une classification à intervalles égaux quand la donnée est très inégalement répartie (cas fréquent d'une population communale). Le CRS du projet doit afficher EPSG:2154 en bas à droite avant tout calcul de surface : sinon \$area renvoie une valeur en degrés carrés, inexploitable.

- Critère 1 : le CRS du projet est bien Lambert-93 (EPSG:2154), vérifié avant toute mesure
- Critère 2 : la variable visuelle choisie correspond au type de donnée (valeur/taille pour une quantité, teinte pour une catégorie)
- Critère 3 : la légende, l'échelle et l'orientation sont toutes trois présentes sur la mise en page finale

VOIR AUSSI : RESSOURCES : DATA.GOUV.FR, DOCUMENTATION QGIS

Voir le thème « Géomatique, SIG et données géographiques » dans les Références.

Le module La Méthode détaille les six variables visuelles de Bertin mobilisées pour choisir une symbologie.

DEVOIR À RENDRE : CARTE

UNE CARTE THÉMATIQUE SIMPLE, SUR UNE VRAIE DONNÉE PUBLIQUE

En reprenant exactement la méthode de la séance 1 (télécharger, vérifier le CRS, styliser, mettre en page), produis une carte de la répartition d'un indicateur au choix (population, superficie, densité...) sur les communes d'un département de ton choix, à partir d'un jeu de données réel de data.gouv.fr. La carte doit être exportée en PDF ou image, prête à être présentée telle quelle.

- Le CRS du projet est vérifié et correspond à un système projeté métrique
- La variable visuelle (taille, valeur ou teinte) correspond au type de donnée représentée
- Légende, échelle et orientation figurent toutes trois sur la mise en page finale
- La source des données (nom du jeu, date de téléchargement) est indiquée sur la carte ou en note

SUPÉRIEUR

SÉANCE 2 : GÉORÉFÉRENCER UNE IMAGE PAR GRILLE

Une image scannée ou une photo aérienne ancienne n'a, à l'origine, aucune coordonnée : ses pixels ne sont repérés que par leur ligne et leur colonne. La géoréférencer, c'est établir la correspondance entre ces pixels et de vraies coordonnées terrain, une compétence indispensable pour exploiter n'importe quelle archive cartographique ou image non géoréférencée.

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Comprendre qu'un géoréférencement n'est fiable que s'il s'appuie sur des points de contrôle (GCP) à coordonnées réelles certaines, jamais sur un calage approximatif « à l'œil » contre un fond de carte.

La méthode la plus fiable quand aucun repère topographique clair n'est disponible : utiliser une grille de coordonnées déjà imprimée sur le document (grille DFCI, grille Lambert, quadrillage kilométrique). Chaque intersection de la grille est un point de contrôle dont la coordonnée réelle se lit directement sur les codes affichés en marge.

1. Repérer sur l'image au moins 6 à 8 intersections de la grille, réparties sur toute l'étendue du document (pas seulement dans un coin)
2. Lire la coordonnée réelle de chaque intersection à partir des codes de la grille imprimée
3. Dans QGIS, ouvrir le Géoréférenceur (Raster > Géoréférencement), placer un point de contrôle sur chaque intersection repérée et saisir sa coordonnée réelle
4. Choisir une transformation adaptée (une transformation affine linéaire suffit si la grille est régulière et sans rotation notable ; une transformation polynomiale d'ordre 2 ou plus absorbe une distorsion non linéaire, au prix d'un risque de sur-ajustement si peu de points sont disponibles)
5. Lancer le géoréférencement et vérifier le résidu affiché par point : il doit rester très inférieur à l'espacement réel de la grille
6. Exporter le raster géoréférencé (GeoTIFF, EPSG:2154)

ATTENTION

VÉRIFIER, NE PAS SUPPOSER

Un géoréférencement peut sembler correct visuellement tout en étant décalé de plusieurs dizaines de mètres. Toujours comparer le résultat à une couche de référence connue et indépendante (ex. un réseau routier ou une grille administrative déjà géoréférencée) avant de considérer l'image comme fiable : c'est la même logique de contrôle indépendant que la RMSE présentée au module Le Compas.

DÉCOUVERTE

- 4 points de contrôle sur une grille bien visible et régulière
- Transformation affine simple

AVANCÉ

- Grille partiellement illisible : combiner points de grille et repères topographiques identifiables

- Comparer deux transformations (affine vs polynomiale) et justifier laquelle convient le mieux, résidu par résidu

CORRIGÉ : SÉANCE 2

Sur une grille régulière sans rotation, une transformation affine à 6 points bien répartis donne typiquement un résidu par point inférieur à 1/100e de l'espacement réel de la grille (par exemple, moins de 20 m de résidu pour une grille DFCI espacée de 2 km), un résidu du même ordre de grandeur que l'espacement de la grille signale presque toujours une erreur de lecture de coordonnée sur au moins un point, pas une limite de la méthode. Une transformation polynomiale d'ordre 2 avec seulement 4-6 points donne souvent un résidu affiché plus faible que l'affine, sans que ce soit un signe de meilleure qualité : c'est un sur-ajustement (le polynôme absorbe le bruit de pointage plutôt que la vraie distorsion), à éviter en dessous d'une dizaine de points de contrôle.

- Critère 1 : au moins 6 GCP utilisés, répartis sur toute l'étendue de l'image (pas regroupés dans un coin)
- Critère 2 : le résidu par point, une fois la transformation calculée, reste très inférieur à l'espacement réel de la grille
- Critère 3 : le résultat est comparé à une couche de référence indépendante avant d'être considéré comme fiable

DEVOIR À RENDRE : INTRODUCTION

RÉDIGER L'INTRODUCTION D'UN COMPTE-RENDU DE GÉORÉFÉRENCEMENT

Avant même d'avoir les résultats, rédige l'introduction (150 à 200 mots) du compte-rendu de la séance 2 : contexte (nature du document à géoréférencer, pourquoi il en a besoin), objectif précis (quelle exploitation ultérieure ce géoréférencement doit permettre), et méthode annoncée (grille de coordonnées, nombre de points de contrôle prévu, transformation envisagée), sans anticiper les résultats eux-mêmes, qui n'ont pas leur place ici.

- Le contexte explique la nature du document et pourquoi un géoréférencement est nécessaire, pas seulement « on va géoréférencer une image »
- L'objectif est formulé de façon précise, pas comme un simple rappel du titre de la séance

- La méthode est annoncée (grille, nombre de points, transformation) sans qu'aucun résultat ou chiffre de résidu n'apparaisse encore
- Le texte respecte la fourchette de longueur demandée (150-200 mots), signe d'un travail de synthèse réel

SUPÉRIEUR

SÉANCE 3 : DE L'IMAGE GÉORÉFÉRENCÉE À L'INDICE COMPOSÉ

Cette séance part directement du résultat de la séance 2 : une image auparavant sans coordonnées, maintenant géoréférencée. Trois étapes progressives, du calcul le plus simple au plus complexe.

1. Calculer le NDVI sur l'image nouvellement géoréférencée (calculatrice raster, voir module Le Regard/Les Couleurs pour la formule), sans géoréférencement préalable, ce calcul produirait un résultat exact en valeur mais inutilisable en position
2. Superposer une grille régulière (fishnet) sur l'emprise de l'image et calculer, pour chaque cellule, la moyenne du NDVI qu'elle contient (Vecteur > Analyse > Statistiques de zone, ou l'outil « Statistiques de zone » du menu Raster, voir module Le Compas, section algèbre raster)
3. Répéter le géoréférencement et le calcul de NDVI sur une seconde image de la même zone, prise à une date différente
4. Composer un indice complexe à partir des deux dates : $\Delta\text{NDVI} = \text{NDVI}(\text{date } 2) - \text{NDVI}(\text{date } 1)$, qui met en évidence les zones de changement plutôt que l'état à un instant donné

EXEMPLE

POURQUOI PASSER PAR LA CELLULE PLUTÔT QUE LE PIXEL SEUL

Une moyenne par cellule lisse le bruit pixel-à-pixel et rend le résultat directement comparable à une grille administrative ou réglementaire (commune, parcelle, zone de gestion), c'est la même logique que les statistiques zonales utilisées dans un vrai projet de suivi de territoire.

REMARQUE

VALIDER SA PROPRE MÉTHODE CONTRE UN RÉSULTAT DÉJÀ CONNU

Une fois l'étape 2 maîtrisée sur une image personnelle, la refaire sur sentinel2_2024-08-06_vitrolles_bands.tif (le jeu de données canonique présenté en tête de ce module) permet une vraie vérification : grille_100m_indices.geojson donne déjà, pour 1122 cellules de 100 m, la moyenne réelle de NDVI/NDMI/NDBI calculée sur les mêmes bandes. Un fishnet + statistiques de zone fait correctement sur ce fichier doit reproduire ces valeurs à peu de choses près (petits écarts possibles selon l'alignement exact de la grille), un net écart signale une erreur dans sa propre chaîne de traitement, pas une variante légitime.

INTERMÉDIAIRE

- NDVI sur l'image géoréférencée + moyenne par cellule d'une grille fournie

AVANCÉ

- Les deux dates, le Δ NDVI complet, et une carte finale classant les cellules en trois catégories (perte, stable, gain de végétation)

CORRIGÉ : SÉANCE 3

Un Δ NDVI se classe généralement en trois catégories à partir d'un seuil autour de ± 0.05 à ± 0.1 (au-delà de l'incertitude de mesure habituelle entre deux dates) : une variation plus faible que ce seuil est considérée stable, pas un vrai changement. Un Δ NDVI très négatif localisé (chute franche, au-delà de -0.3) sur une zone auparavant boisée est la signature typique d'une coupe rase ou d'un défrichement plutôt que d'un simple cycle saisonnier, qui produit rarement une chute aussi abrupte d'une date à l'autre si les deux images sont prises à la même saison.

- Critère 1 : le NDVI est calculé sur l'image géoréférencée, pas sur l'image brute (position exploitable)
- Critère 2 : les deux dates comparées sont prises à une saison comparable, sinon le Δ NDVI mélange changement réel et cycle végétatif normal

- Critère 3 : un seuil explicite (documenté) sépare perte / stable / gain, plutôt qu'un découpage arbitraire

VOIR AUSSI : REVOIR : INDICES COMPOSÉS ET COMPLEXES

Le module Les Couleurs détaille la logique des indices composés avant de les mettre en pratique ici.

DEVOIR À RENDRE : ANALYSE DE TEXTE

ANALYSER L'ARTICLE FONDATEUR D'UN INDICE QUE TU VIENS D'UTILISER

Trouve et lis le résumé (abstract) de l'article original ayant introduit le NDVI (Rouse et al., 1974, « Monitoring vegetation systems in the Great Plains with ERTS ») ou celui du SAVI (Huete, 1988, « A soil-adjusted vegetation index »), les deux sont largement documentés et cités dans la littérature de télédétection, recherchables par leur titre exact. Rédige une analyse de 300 à 400 mots qui répond à trois questions : quel problème concret l'auteur cherchait-il à résoudre ? quelle est l'idée centrale de sa solution ? en quoi la limite qu'il identifie (ou corrige) rejoint-elle ce que tu as observé toi-même en séance 3 (Δ NDVI, confusion sol nu/végétation clairsemée) ?

- La source exacte (auteur, année, titre) est citée, pas une paraphrase anonyme de « un article sur le NDVI »
- Le problème initial identifié par l'auteur est reformulé avec ses propres mots, pas recopié
- Un lien explicite est établi avec l'expérience concrète de la séance 3, pas une simple juxtaposition
- La longueur demandée (300-400 mots) est respectée : ni un résumé trop court, ni un remplissage hors sujet

À TOI DE JOUER

LE FIL DE L'ATELIER

Remettre dans l'ordre les étapes de la séance 3 : de l'image géoréférencée à l'indice composé.

Exercice interactif — à faire sur la version web du site.

SÉANCE 4 : ANALYSE SPATIALE, BUFFER ET INTERSECTION

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Répondre à une vraie question spatiale (« quelles parcelles sont concernées par telle contrainte ? ») en enchaînant deux opérations plutôt qu'en cherchant une réponse à l'œil sur la carte.

1. Charger une couche de cours d'eau et une couche de parcelles (ou bâtiments) sur une même zone
2. Créer un buffer de 200 m autour des cours d'eau (Vecteur > Outils de géotraitement > Tampon)
3. Intersecter ce buffer avec la couche de parcelles (Vecteur > Outils de géotraitement > Intersection)
4. Ouvrir la table attributaire du résultat : chaque entité correspond à une parcelle (ou portion) située dans la zone tampon
5. Calculer la surface totale concernée (Champ calculé : \$area, après vérification du CRS en mètres)

ATTENTION

ERREUR FRÉQUENTE

Un buffer de "200" appliqué sur une couche en EPSG:4326 (degrés) produira une zone tampon de 200 degrés, pas 200 mètres. Toujours vérifier que la couche est en système projeté métrique avant de créer un buffer en mètres.

CORRIGÉ : SÉANCE 4

Une parcelle qui chevauche partiellement le buffer (et non entièrement) apparaît en plusieurs entités après l'intersection : une pour la portion dans le buffer, la géométrie d'origine de la parcelle n'est pas conservée telle quelle. C'est le comportement normal de l'outil Intersection, pas une erreur : sommer \$area sur le résultat donne bien la surface réellement concernée par la contrainte, même pour les parcelles partiellement traversées.

- Critère 1 : le buffer est créé sur une couche en CRS projeté métrique (EPSG:2154), jamais en degrés
- Critère 2 : le résultat de l'intersection contient une entité par portion de parcelle réellement recoupée par le buffer, pas par parcelle entière
- Critère 3 : la surface totale est calculée par somme de \$area sur le résultat de l'intersection, pas sur la couche de parcelles d'origine

VOIR AUSSI : REVOIR : BUFFER, INTERSECTION ET OPÉRATIONS SPATIALES

Le module Le Compas détaille les opérations spatiales (buffer, intersection, union, différence) mobilisées dans cette séance, avant de les pratiquer ici.

DEVOIR À RENDRE : CARTE

CARTE D'UNE CONTRAINTE RÉGLEMENTAIRE RÉELLE, BUFFER + INTERSECTION

Choisis une contrainte réglementaire réelle basée sur une distance (bande de 200 m autour d'un cours d'eau, périmètre de protection autour d'un monument, zone tampon autour d'une ICPE...) sur un territoire de ton choix. Produis une carte qui montre la zone tampon, les parcelles ou bâtiments concernés (résultat de l'intersection), et une légende qui distingue clairement les entités entièrement incluses des entités seulement partiellement recoupées. Accompagne la carte d'un paragraphe de critique du document (module La Méthode, section 1) : quelle limite cette analyse comporte-t-elle (distance réglementaire simplifiée, données parcellaires pas toujours à jour...) ?

- Le buffer est calculé sur une couche projetée métrique, la distance correspond à une vraie contrainte nommée et sourcée
- La légende distingue visuellement les entités entièrement dans le buffer de celles seulement partiellement recoupées
- La surface totale concernée est indiquée sur la carte ou dans le texte d'accompagnement
- Le paragraphe de critique identifie au moins une limite réelle de l'analyse, pas une remarque générique

BONUS SÉANCE 4 : LA MÊME QUESTION, SUR UNE DONNÉE VIVANTE

Le jeu de données canonique (bâti, végétation, eau) est une photographie figée au 06/08/2024. OpenStreetMap couvre la même emprise exacte, mais c'est une donnée vivante (VGI, volunteered geographic information) : n'importe quel contributeur peut la corriger ou la compléter à tout moment. Le bloc ci-dessous interroge l'API Overpass en direct, au moment où tu charges cette page, pas une capture figée à l'avance.

DONNÉE INTERROGÉE EN DIRECT

Cette section interroge l'API OpenStreetMap en temps réel, consulter la version web du module pour l'exécuter et voir les nombres actuels.

Planche vivante. Mêmes bornes géographiques que l'emprise Sentinel-2 canonique, comptées en direct sur OpenStreetMap.

EXEMPLE

CONSIGNE

Note le nombre de bâtiments affiché. Recharge la page dans quelques minutes (bouton « Rafraîchir ») : le chiffre a-t-il changé ? Compare ensuite ce nombre à ta propre lecture visuelle du bâti sur l'image Sentinel-2 de la séance 1, te semble-t-il cohérent (même ordre de grandeur), ou la couverture OSM te paraît-elle nettement incomplète sur cette zone précise ?

CORRIGÉ : BONUS SÉANCE 4

Il n'y a volontairement pas de nombre "correct" à retenir ici : c'est le point de l'exercice. Deux lectures possibles, selon ce que tu observes : si le nombre de bâtiments OSM est proche de ta lecture visuelle, la zone est bien cartographiée par la communauté (fréquent en zone urbaine dense en France). S'il est nettement inférieur, tu viens de mettre en évidence une limite réelle et fréquente des données participatives (VGI) : une complétude très inégale selon les zones et les contributeurs locaux, contrairement à un jeu de données satellite qui, lui, couvre uniformément tout le territoire à chaque passage : c'est la différence entre donnée autoritative (Sentinel-2, produite et validée de façon homogène) et donnée participative (OSM, aussi bonne que ses contributeurs locaux).

VOIR AUSSI : REVOIR : OPÉRATIONS SPATIALES ET SOURCES DE DONNÉES

Le module Le Compas détaille les opérations spatiales appliquées ici à une donnée interrogée en direct plutôt qu'à un fichier statique.

SUPÉRIEUR

SÉANCE 5 : PROGRAMMATION GÉOSPATIALE SIMPLE

Quatre exercices courts, indépendants, qui couvrent les besoins les plus fréquents en géographie et télédétection : lire/transformer une donnée vecteur, mesurer, automatiser un calcul raster répétitif, et interroger une donnée en ligne de commande sans passer par une interface graphique.

EXERCICE 1 (DÉCOUVERTE) : D'UN CSV À UNE CARTE

```
gdf = gpd.GeoDataFrame(df, geometry=gpd.points_from_xy(df.lon, df.lat), crs='EPSG:4326')
```

Charger un CSV de points (colonnes lon/lat), le convertir en GeoDataFrame, le reprojeter en EPSG:2154, puis l'exporter en GeoJSON.

EXERCICE 2 (INTERMÉDIAIRE) : MESURER AVEC SHAPELY/GEOPANDAS

```
gdf['buffer_200m'] =  
gdf.to_crs(epsg=2154).geometry.buffer(200)
```

Reprendre le GeoDataFrame de l'exercice 1, créer un buffer de 200 m autour de chaque point, puis calculer l'aire cumulée de tous les buffers (attention aux chevauchements, non gérés par une simple somme, utiliser `gdf.unary_union` avant de mesurer l'aire réelle couverte).

EXERCICE 3 (AVANCÉ) : AUTOMATISER UN CALCUL NDVI PAR LOT

```
for red, nir in zip(sorted(glob('*_B04.tif')),  
sorted(glob('*_B08.tif'))):  
    ndvi = (read(nir) - read(red)) /  
    (read(nir) + read(red))
```

Avec `rasterio` : parcourir un dossier contenant plusieurs paires de bandes rouge/NIR, calculer le NDVI de chacune, et enregistrer chaque résultat sous un nom dérivé du fichier source, la base de tout traitement par lot en télédétection.

EXERCICE 4 (DÉCOUVERTE) : INSPECTER UNE DONNÉE EN LIGNE DE COMMANDE AVEC GDAL

gdalinfo -stats sentinel2_2024-08-06_vitrolles_indices.tif

GDAL/OGR (la bibliothèque sur laquelle repose la quasi-totalité des logiciels SIG, dont QGIS) fournit des utilitaires en ligne de commande pour inspecter rapidement une couche sans l'ouvrir dans une interface graphique : ogrinfo pour le vecteur (nombre d'entités, CRS, champs), gdalinfo pour le raster (dimensions, résolution, statistiques par bande). Sur le fichier réel du jeu de données canonique (bande 1 = NDVI), gdalinfo -stats doit afficher un minimum proche de -1, un maximum proche de 1 et une moyenne proche de 0.33 : les mêmes chiffres que le callout "Valeurs réelles de référence" en tête de ce module : un réflexe utile pour vérifier une donnée avant de l'intégrer à un traitement automatisé plus long, ou simplement pour confirmer qu'un fichier téléchargé n'est pas corrompu.

CORRIGÉ : SÉANCE 5

Exercice 1 : le piège le plus fréquent est d'oublier `crs='EPSG:4326'` à la construction du `GeoDataFrame` (les colonnes lon/lat n'étant que des nombres, GeoPandas ne devine jamais le CRS source), sans cette précision, la reprojection ultérieure vers `EPSG:2154` produit un résultat silencieusement faux, sans erreur levée. Exercice 2 : `gdf.to_crs(epsg=2154).geometry.buffer(200).unary_union.area` donne l'aire réellement couverte (chevauchements fusionnés) ; `gdf.buffer(200).area.sum()` surestime dès que deux buffers se recouvrent, ce qui est fréquent sur des points rapprochés. Exercice 3 : diviser par `np.where(denominateur==0, 1, denominateur)` ou utiliser un masque évite une division par zéro sur les pixels où `NIR+Rouge = 0` (bordures de l'image, valeurs nodata). Exercice 4 : `gdalinfo -stats` ajoute les statistiques (min/max/moyenne/écart-type) aux métadonnées du fichier, utile pour repérer d'un coup d'œil un NDVI hors de l'intervalle `[-1, 1]`, signe d'une erreur en amont.

VOIR AUSSI : REVOIR : PYQGIS ET GEOPANDAS

Le module Le Compas présente ces deux approches avant de les pratiquer ici.

DEVOIR À RENDRE : ÉTUDE BIBLIOGRAPHIQUE

COMPARER DEUX SOURCES SUR LE CHOIX PYQGIS VS GEOPANDAS

Trouve deux sources distinctes (documentation officielle, article de blog technique signé, présentation de conférence FOSS4G/PyData...) qui discutent, chacune à sa manière, du choix entre automatiser un traitement dans PyQGIS ou dans un pipeline

Python autonome (GeoPandas, rasterio). Rédige une synthèse de 250 mots qui ne juxtapose pas les deux sources l'une après l'autre, mais les met en dialogue : sur quel critère sont-elles d'accord, sur lequel divergent-elles, et quelle est ta propre conclusion sur ce jeu de données précis (celui de Vitrolles) ?

- Les deux sources sont identifiées précisément (auteur/organisation, titre, où les trouver), pas de « j'ai lu quelque part que »
- La synthèse compare les deux sources entre elles, pas un résumé de la première puis un résumé de la seconde
- Une conclusion personnelle et justifiée referme le texte, appliquée au cas du jeu de données Vitrolles
- La longueur (250 mots) est respectée

APPROFONDISSEMENT

SÉANCE 6 : CLASSIFICATION SUPERVISÉE ET ÉVALUATION DE PRÉCISION

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Aller jusqu'au bout d'une classification : constituer des échantillons d'entraînement représentatifs, entraîner un classifieur, puis évaluer honnêtement sa précision, l'étape la plus souvent négligée dans un premier projet de classification.

1. Charger sentinel2_2024-08-06_vitrolles_bands.tif (jeu de données canonique ci-dessus) et sa bande SCL, la Scene Classification Layer, calculée par l'algorithme officiel ESA/Sen2Cor, une vérité terrain déjà disponible sans digitalisation manuelle pour 3 classes franches : végétation, sol nu/bâti, eau
2. Réserver un tiers de l'emprise (par exemple le tiers droit) comme jeu de test, jamais montré à l'entraînement, un découpage spatial, pas un tirage aléatoire pixel par pixel (voir module L'Intelligence, mise en garde sur la fuite de données)
3. Entraîner une classification supervisée (Random Forest, scikit-learn ou SCP dans QGIS) sur les deux tiers restants uniquement, avec les 6 bandes comme variables d'entrée
4. Appliquer le classifieur à l'ensemble de l'emprise
5. Construire la matrice de confusion entre la classification obtenue et les pixels de test, puis calculer la précision globale et le coefficient kappa (formules détaillées au module

ATTENTION

NE JAMAIS ÉVALUER UN MODÈLE SUR LES DONNÉES QUI ONT SERVI À L'ENTRAÎNER

Calculer la précision d'une classification sur les mêmes pixels que ceux utilisés pour l'entraîner donne un chiffre optimiste, souvent proche de 100 %, qui ne dit rien de la performance réelle du modèle sur le reste de l'image. C'est l'erreur méthodologique la plus grave et la plus fréquente en classification supervisée, voir la mise en garde sur la fuite de données au module L'Intelligence.

CORRIGÉ : SÉANCE 6 : RÉSULTAT RÉEL, MESURÉ SUR LE JEU DE DONNÉES VITROLLES (PAS UNE ESTIMATION)

Sur ce jeu réel (113 000 pixels labellisés par la SCL, découpage spatial 2/3 gauche = entraînement / 1/3 droit = test) : un Random Forest à 200 arbres atteint 100 % de précision sur l'entraînement mais seulement 96.2 % sur le test, avec un kappa de 0.640 : l'écart net entre les deux confirme le sur-apprentissage attendu d'un Random Forest peu contraint (module L'Intelligence, section sur-apprentissage). La matrice de confusion réelle montre la quasi-totalité des erreurs sur la frontière végétation ↔ sol nu/bâti (1009 pixels de végétation classés sol nu/bâti sur 2390 pixels de végétation en test), cohérent avec la confusion bâti/sol nu déjà annoncée au module Les Couleurs.

- Critère 1 : le découpage entraînement/test est spatial (par zone), jamais un tirage aléatoire pixel par pixel
- Critère 2 : la matrice de confusion réelle est présentée avant toute interprétation, comme un vrai rapport technique (voir module La Méthode)
- Critère 3 (piège réel rencontré sur ce jeu de données) : la classe eau, présente uniquement dans l'étang de Berre en haut à gauche de l'emprise, se retrouve à 100 % du côté entraînement avec ce découpage par tiers verticaux : 0 pixel d'eau dans le jeu de test. Un score de précision qui semble bon peut donc masquer une classe jamais réellement évaluée : toujours vérifier que chaque classe a des effectifs non nuls des deux côtés du découpage avant de faire confiance au score global.

VOIR AUSSI : REVOIR : CLASSIFICATION SUPERVISÉE ET MATRICE DE CONFUSION

Le module L'Intelligence détaille les méthodes de classification et les métriques d'évaluation avant de les pratiquer ici.

DEVOIR À RENDRE : ANALYSE DE TEXTE

ANALYSER UNE SOURCE MÉTHODOLOGIQUE SUR L'ÉVALUATION D'UNE CLASSIFICATION

Cherche une source qui traite spécifiquement de l'évaluation de précision d'une classification (matrice de confusion, kappa, ou leurs limites, par exemple un article citant Congalton, 1991, référence classique du domaine, ou une documentation technique d'un organisme comme l'ESA/Copernicus). Rédige une analyse de 350 mots qui met en regard ce que dit la source et le résultat réel mesuré en séance 6 (kappa 0.640, erreurs concentrées sur la frontière végétation/sol nu, classe eau totalement absente du jeu de test) : la source permet-elle d'expliquer ou de relativiser ce résultat précis ?

- La source est identifiée précisément, pas anonyme
- L'analyse convoque explicitement les chiffres réels de la séance 6 (kappa, matrice de confusion), pas seulement des généralités
- Le texte distingue clairement ce qui vient de la source de ce qui est une interprétation personnelle
- La longueur (350 mots) est respectée

APPROFONDISSEMENT

SÉANCE 7 : CLASSIFICATION PAR RÉSEAU DE NEURONES SIMPLE

Le module L'Intelligence détaille les CNN, U-Net et Transformers, mais la séance 6 n'a mis en pratique que des classificateurs classiques (maximum de vraisemblance, forêts aléatoires). Cette séance ferme cet écart avec le plus simple des réseaux de neurones, un perceptron multicouche (MLP), sur les mêmes données qu'en séance 6, pour comparer directement sa précision à celle d'un Random Forest sur un pied d'égalité.

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Constater par la pratique qu'un réseau de neurones, même simple, s'entraîne et s'évalue exactement selon le même protocole qu'un classificateur classique

(train/validation/test, matrice de confusion, kappa), la différence est dans le modèle, pas dans la méthodologie d'évaluation.

1. Reprendre le jeu d'entraînement/test de la séance 6 (mêmes polygones, même découpage train/test, condition indispensable pour une comparaison honnête)
2. Entraîner un MLP à une couche cachée avec scikit-learn (MLPClassifier) sur les bandes brutes et/ou les indices calculés (NDVI, NDMI, NDBI) comme variables d'entrée
3. Faire varier le nombre de neurones de la couche cachée (ex. 10, 50, 200) et observer l'effet sur la précision d'entraînement vs la précision de test (voir module L'Intelligence, sur-apprentissage)
4. Comparer la matrice de confusion et le kappa obtenus à ceux du Random Forest de la séance 6, sur le même jeu de test
5. Tracer la courbe de perte (loss) au fil des itérations d'entraînement (scikit-learn expose `loss_curve_`) pour vérifier qu'elle décroît puis se stabilise, sans jamais ré-augmenter (signe de sur-apprentissage si le suivi se fait aussi sur un jeu de validation)

ENTRAÎNER UN MLP AVEC SCIKIT-LEARN

```
clf = MLPClassifier(hidden_layer_sizes=(50,), max_iter=500);  
clf.fit(X_train, y_train)
```

X_train : tableau des bandes/indices par pixel ou par polygone d'entraînement ; y_train : la classe correspondante. Contrairement à un CNN complet (module L'Intelligence), ce MLP ne voit aucun voisinage spatial : chaque pixel est classé indépendamment de ses voisins, exactement comme le Random Forest de la séance 6. La différence de précision observée, si elle existe, vient donc uniquement de la capacité du modèle à combiner les variables d'entrée, pas d'une information spatiale supplémentaire.

ATTENTION

NE PAS PRÉSUMER DU VAINQUEUR AVANT DE MESURER

L'intuition générale (un Random Forest généralise souvent mieux qu'un MLP sur peu de données, l'avantage des réseaux de neurones apparaissant surtout à grande échelle) n'est qu'une tendance, pas une loi : elle peut être contredite sur un jeu de données précis, comme le montre le résultat réel ci-dessous. La bonne pratique n'est jamais de présumer lequel gagnera, mais de toujours mesurer sur son propre jeu de test.

CORRIGÉ : SÉANCE 7 : RÉSULTAT RÉEL, MESURÉ SUR LE MÊME JEU DE DONNÉES QUE LA SÉANCE 6

Contrairement à l'intuition générale : sur ce jeu réel, le MLP à 50 neurones cachés fait légèrement MIEUX que le Random Forest de la séance 6 sur le jeu de test : kappa 0.673 contre 0.640, pour une précision test quasi identique (96.3 % contre 96.2 %). Le MLP à 200 neurones cachés (kappa 0.672, précision test 96.4 %) n'apporte rien de plus que celui à 50 neurones : la capacité supplémentaire ne sert à rien ici, le facteur limitant n'est pas la taille du réseau mais l'ambiguïté spectrale intrinsèque entre végétation et sol nu/bâti à cette résolution. Autre différence réelle mesurée : le Random Forest atteint 100 % de précision sur l'entraînement (sur-apprentissage net) quand le MLP plafonne à 97.3 % sur l'entraînement : sa frontière de décision, plus lisse, colle moins parfaitement aux données d'entraînement, ce qui explique en partie sa meilleure tenue sur le test.

- Critère 1 : le même découpage train/test que la séance 6 est réutilisé à l'identique (comparaison valide)
- Critère 2 : la courbe de perte est tracée et commentée, pas seulement le score final
- Critère 3 : un écart de précision entre MLP et Random Forest est interprété (taille du jeu de données, absence de contexte spatial), pas seulement constaté

VOIR AUSSI : REVOIR : RÉSEAUX DE NEURONES ET SUR-APPRENTISSAGE

Le module L'Intelligence détaille la fonction de perte, le sur-apprentissage et les architectures plus avancées (CNN, U-Net) que cette séance ne fait qu'effleurer avec un MLP simple.

DEVOIR À RENDRE : DISSERTATION

« LE DEEP LEARNING REND-IL OBSOLÈTES LES MÉTHODES DE CLASSIFICATION CLASSIQUES EN TÉLÉDÉTECTION ? »

Traite ce sujet en une dissertation complète (plan dialectique conseillé, voir module La Méthode), 600 mots minimum. Ta partie centrale doit s'appuyer explicitement sur le résultat réel mesuré en séances 6 et 7 (le MLP, un réseau de neurones pourtant très simple, fait légèrement mieux qu'un Random Forest sur ce jeu précis) comme exemple concret, pas seulement sur des généralités issues du module L'Intelligence.

- Le plan est explicite et démonstratif (voir module La Méthode) : introduction, problématique, parties, transitions
- Le résultat réel RF vs MLP (séances 6-7) est utilisé comme argument concret dans au moins une partie, pas relégué en simple exemple décoratif

- Une limite ou nuance est explicitement discutée (taille du jeu de données, absence de contexte spatial dans un MLP pixel-par-pixel, coût de calcul/données d'un deep learning plus complexe)
- La longueur minimale (600 mots) est respectée

APPROFONDISSEMENT

SÉANCE 8 : RADAR ET INTERPOLATION SPATIALE

Deux techniques présentées en théorie (module Le Regard pour le SAR, module Le Compas pour le krigeage) mais jamais pratiquées jusqu'ici. Cette séance les met en œuvre séparément, sur des données réelles.

1. Télécharger une scène Sentinel-1 (niveau GRD, Ground Range Detected) sur la même zone qu'une image Sentinel-2 déjà utilisée dans une séance précédente, via Copernicus Data Space Ecosystem
2. Charger la scène dans QGIS, afficher la polarisation VV en niveaux de gris, puis comparer visuellement une zone en eau libre (signal faible, sombre) à une zone urbaine (signal fort, claire), confirmer à l'œil ce que la section réflexion spéculaire/double-rebond du module Le Regard prédit
3. Sur un jeu de points de mesure ponctuels (ex. relevés de température ou de pluviométrie d'un réseau de stations, ou à défaut un sous-échantillon aléatoire de pixels NDVI comme substitut pédagogique), calculer un variogramme expérimental (plugin QGIS SAGA ou script Python avec la bibliothèque scikit-gstat)
4. Ajuster un modèle théorique (sphérique ou exponentiel) sur ce variogramme, puis interpoler par krigeage ordinaire sur toute l'emprise
5. Comparer visuellement la carte krigée à une simple interpolation IDW (Inverse Distance Weighting) sur les mêmes points, et comparer la carte de variance de krigeage à la simple distance au point le plus proche

EXEMPLE

POURQUOI COMPARER À L'IDW PLUTÔT QU'ACCEPTER LE KRIGEAGE SANS REcul

L'IDW et le krigeage donnent souvent des cartes de valeurs visuellement proches sur un jeu de points bien réparti : la vraie valeur ajoutée du krigeage n'est pas toujours flagrante sur la carte de valeurs elle-même. C'est la carte de variance de krigeage (que l'IDW ne produit pas) qui révèle l'apport réel : elle montre explicitement où

l'estimation est fiable (près des points de mesure) et où elle ne l'est pas (zones peu échantillonnées), une information absente de toute interpolation déterministe.

CORRIGÉ : SÉANCE 8

Sur la scène Sentinel-1 : une surface en eau calme apparaît nettement plus sombre en VV qu'une zone bâtie, qui ressort au contraire très brillante (effet de coin, double rebond façade/sol), un contraste souvent plus net et plus rapide à lire que sur l'image optique correspondante, en particulier si celle-ci comporte des nuages ce jour-là. Sur le variogramme : un effet de pépite élevé par rapport au palier signale un point de mesure bruité ou une variabilité à une échelle plus fine que l'espacement du réseau de points, dans ce cas, le krigeage doit être interprété avec prudence quel que soit le modèle ajusté.

- Critère 1 : le contraste eau/bâti en polarisation VV est identifié et relié à la physique de rétrodiffusion (module Le Regard), pas seulement décrit visuellement
- Critère 2 : le variogramme expérimental est ajusté avec un modèle théorique explicite (sphérique/exponentiel), pas laissé brut
- Critère 3 : la carte de variance de krigeage est produite et interprétée, pas seulement la carte de valeurs interpolées

VOIR AUSSI : REVOIR : GÉOSTATISTIQUE ET KRIGEAGE

Le module Le Compas détaille le variogramme et la théorie du krigeage avant de les pratiquer ici.

DEVOIR À RENDRE : ÉTUDE BIBLIOGRAPHIQUE

UN CAS RÉEL D'USAGE OPÉRATIONNEL DU RADAR OU DU KRIGEAGE

Recherche un cas réel et documenté d'usage opérationnel (pas académique/théorique) de l'une des deux techniques de cette séance : le service Copernicus Emergency Management Service (EMS) pour la cartographie rapide d'inondation par SAR, ou un exemple documenté de krigeage en agriculture de précision, hydrologie ou santé publique. Rédige une synthèse de 400 mots qui explique le contexte opérationnel (qui, pourquoi, avec quelle contrainte de délai), la méthode réellement employée, et compare-la à ta propre mise en œuvre de la séance 8.

- Le cas cité est réel et sourcé précisément (organisme, document, date), pas un exemple générique inventé

- Le contexte opérationnel (contrainte de délai, décideur destinataire) est explicité, pas seulement la technique
- Une comparaison explicite est faite avec la mise en œuvre personnelle de la séance 8
- La longueur (400 mots) est respectée

APPROFONDISSEMENT

SÉANCE 9 : ÉTUDE DE CAS ET MINI-PROJET FINAL

Les huit séances précédentes traitent chacune une compétence isolée. Le mini-projet les combine toutes, au service d'une vraie question : le rendu attendu ici est délibérément plus exigeant que celui de toute séance précédente : un vrai sujet, une vraie problématique, une analyse qui montre une compréhension réelle de l'outil et de la matière, pas seulement une carte techniquement correcte. Quatre familles de sujets reviennent le plus souvent :

- Risques naturels : croiser indices d'humidité/de végétation, pente et vent pour cartographier un risque incendie (voir le module Les Couleurs pour un exemple réel d'indice composite de comportement du feu)
- Agriculture de précision : suivi du NDVI d'une parcelle dans le temps pour cibler l'irrigation ou détecter un stress hydrique précoce
- Urbanisme : NDBI et séries temporelles pour mesurer l'étalement urbain d'une commune sur dix ans
- Climat et environnement : détection de changement (déforestation, recul d'un glacier) par comparaison de deux dates, comme en séance 3

EXEMPLE

TROIS SUJETS RÉELS, DÉJÀ PROBLÉMATISÉS, À CHOISIR TELS QUELS OU À ADAPTER À TON PROPRE TERRITOIRE

1. « La vulnérabilité à la surchauffe estivale d'une commune est-elle corrélée à la densité du bâti et au déficit de végétation ? » (croiser NDBI, NDVI et pente : risques naturels × urbanisme). 2. « Comment le stress hydrique d'un secteur agricole a-t-il évolué sur plusieurs années, lu à travers le NDVI en pleine saison sèche ? » (série temporelle NDVI : agriculture de précision). 3. « Le front urbain d'une commune littorale a-t-il progressé vers une zone à risque (submersion, incendie) entre deux dates ? » (détection de changement, comme en séance 3, croisée à une zone à aléa : urbanisme × risques naturels). Chacun de ces trois sujets mobilise volontairement

plus d'une compétence isolée des séances précédentes : c'est cette combinaison, pas la difficulté technique d'une seule étape, qui distingue le mini-projet d'un simple exercice supplémentaire.

REMARQUE

INTERDISCIPLINARITÉ : UN ATOUT, JAMAIS UNE OBLIGATION

Chacun des trois sujets ci-dessus admet une lecture purement physique (aléa, contrainte du milieu) ou peut être enrichi d'une dimension humaine (politique d'aménagement, inégalité d'exposition selon les quartiers, choix agricoles économiques), les deux angles, ou un seul, sont recevables. Un projet qui articule explicitement géographie physique et géographie humaine (ex. "le risque est physique, mais son exposition sociale ne l'est pas") démontre une compréhension plus large de la discipline, et cela se retrouve dans le barème ci-dessous, mais un projet mono-disciplinaire rigoureux et bien mené n'est pas pénalisé pour autant.

ATTENTION

CAHIER DES CHARGES DU MINI-PROJET

Choisir un territoire et un sujet (l'un des trois ci-dessus, ou une variante personnelle sur le même modèle). Produire une carte finale qui combine au minimum : une donnée vecteur, une donnée raster ou un indice spectral calculé, et au moins une analyse spatiale (buffer, intersection ou jointure spatiale). Le rendu attendu est une carte mise en page (légende organisée, échelle, source des données, sémiologie graphique justifiée) accompagnée d'un rapport complet structuré selon le module La Méthode (contexte, données et méthode, résultats, discussion, recommandations), pas un simple paragraphe de commentaire.

REMARQUE

DÉMARRER DIRECTEMENT SUR LE JEU DE DONNÉES CANONIQUE

Sans territoire personnel en tête, le jeu de données Vitrolles présenté en tête de ce module se prête directement au sujet 1 (NDBI déjà calculé sur du bâti réel, dont l'aéroport Marseille-Provence, contraste net avec la garrigue environnante), un point

de départ réel et déjà vérifié, plutôt qu'un jeu de données à dénicher soi-même avant de pouvoir commencer.

SECTION ÉVALUÉE	BARÈME INDICATIF
Problématique et cadrage du sujet (précision, pertinence par rapport au territoire choisi)	/3
Données et méthode (sources documentées, reproductible par un tiers)	/4
Carte de synthèse (sémiologie de Bertin, légende, lisibilité)	/5
Résultats présentés avant toute interprétation	/3
Discussion (limites, incertitude, ouverture interdisciplinaire le cas échéant)	/4
Forme du rendu (structure du rapport, présentation)	/1

DEVOIR À RENDRE : RAPPORT

RAPPORT COMPLET DU MINI-PROJET

Rédige le rapport complet (pas seulement la carte) : contexte et objectif, données et méthode documentées de façon reproductible, résultats présentés avant toute interprétation, discussion des limites, et, si le sujet choisi s'y prête, une ouverture interdisciplinaire explicite (géographie humaine et/ou physique). Ce rapport est le rendu le plus exigeant de l'Atelier : il doit démontrer une vraie compréhension de l'outil et de la matière, pas seulement l'exécution correcte d'une suite d'étapes techniques.

- Le sujet traité est l'un des trois problématisés ci-dessus, ou une variante personnelle construite sur le même modèle (pas un sujet vague du type "étudier la végétation d'une zone")
- Chaque section du barème ci-dessus est identifiable dans le rendu (problématique, données/méthode, carte, résultats, discussion)
- La discussion admet explicitement au moins une limite réelle du travail, pas une formule de politesse
- Si une dimension interdisciplinaire est choisie, elle est articulée avec le résultat physique, pas juxtaposée en paragraphe séparé sans lien

CORRIGÉ : SÉANCE 9 : GRILLE D'AUTO-ÉVALUATION DU RENDU

- La carte a un titre problématisé (pas un simple intitulé du sujet), voir module La Méthode, section croquis
- La légende est organisée en rubriques logiques, pas une liste de symboles dans l'ordre de création
- Chaque figuré cartographique respecte la sémiologie de Bertin (variable adaptée au type de donnée qu'il porte)
- Le rapport sépare nettement résultats (cartes, chiffres) et discussion (limites, incertitude), jamais mélangés dans le même paragraphe
- Les sources de données (capteur, date, résolution) sont documentées, pas seulement citées de mémoire
- Au moins une limite du résultat est explicitement discutée (résolution, incertitude, hypothèse simplificatrice)

VOIR AUSSI : STRUCTURER LE RAPPORT RENDU

Le module La Méthode détaille la structure attendue d'un rapport technique (contexte, données et méthode, résultats, discussion, recommandations) et la sémiologie graphique d'une carte de synthèse.

LYCÉE

SÉANCE 10 : COMMENTER UN DOCUMENT CARTOGRAPHIQUE

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Les séances précédentes produisent toutes un document (carte, indice, classification). Celle-ci fait l'inverse : lire et commenter par écrit un document déjà produit, l'exercice le plus fréquent en épreuve de lycée (voir module La Méthode, section 1). Un commentaire de document n'est pas une description : c'est une lecture organisée qui répond à une problématique.

1. Télécharger la composition couleur naturelle et le NDVI du jeu de données Vitrolles (voir Ressources → Jeux de données)

2. Identifier, sans aucun calcul, les grands ensembles visibles sur la composition naturelle : bâti, végétation, eau, infrastructure (voir module Le Regard, section 9, les six clés de lecture de la photo-interprétation)
3. Comparer les mêmes zones sur le NDVI : formuler une problématique du type « le contraste bâti/végétation vu à l'œil sur la composition naturelle se confirme-t-il, et se précise-t-il, une fois l'indice calculé ? »
4. Rédiger un commentaire structuré (introduction avec problématique, deux ou trois parties, conclusion) qui répond à cette problématique, appuyé uniquement sur ce que montrent les deux documents

ATTENTION

S'APPUYER SUR LE DOCUMENT, PAS SUR UNE CONNAISSANCE GÉNÉRALE PLAQUÉE DESSUS

L'erreur la plus fréquente d'un commentaire de document consiste à réciter une connaissance générale sur le NDVI ou la télédétection sans jamais revenir au document précis fourni. Chaque affirmation doit pouvoir être localisée sur l'image (« la zone nord-ouest, plus sombre sur le NDVI, correspond à la piste de l'aéroport visible sur la composition naturelle »), pas rester générale.

DÉCOUVERTE

- Décrire ce que montrent les deux documents, zone par zone
- Une problématique simple suffit (ex. "le NDVI confirme-t-il la lecture à l'œil ?")

APPROFONDISSEMENT

- Discuter un désaccord entre lecture à l'œil et NDVI, s'il en existe un (ex. végétation clairsemée visible mais NDVI faible)
- Relier ce désaccord à une limite connue de l'indice (voir module Les Couleurs, limites communes aux indices spectraux)

CORRIGÉ : SÉANCE 10

Sur ce jeu de données, la piste de l'aéroport Marseille-Provence et le tissu urbain de Vitrolles se distinguent nettement en blanc à marron sur le NDVI, cohérent avec la lecture à l'œil de la composition naturelle. L'étang de Berre, en haut à gauche, apparaît

en valeurs NDVI proches de zéro ou négatives (l'eau n'a pas de chlorophylle), une nuance qu'une lecture purement visuelle de la composition naturelle ne permet pas de chiffrer aussi précisément. Un bon commentaire relève cette complémentarité : le NDVI ne remplace pas la lecture à l'œil, il la précise et la rend mesurable.

- Critère 1 : la problématique figure explicitement en introduction, pas seulement en filigrane
- Critère 2 : chaque affirmation renvoie à un endroit précis du document (pas de généralité non localisée)
- Critère 3 : la conclusion répond réellement à la problématique posée, sans ouvrir un sujet nouveau non traité

VOIR AUSSI : REVOIR : LA PHOTO-INTERPRÉTATION

Le module Le Regard détaille les six clés de lecture classiques mobilisées ici.

DEVOIR À RENDRE : COMMENTAIRE DE DOCUMENT

COMMENTAIRE STRUCTURÉ SUR UN DOCUMENT AU CHOIX

En reprenant la méthode de cette séance, rédige un commentaire structuré (400 à 600 mots) sur la composition naturelle et le NDVI du jeu de données Vitrolles, ou sur un autre couple image/indice de ton choix issu d'un module précédent (par exemple le Δ NDVI de la séance 3). Le commentaire doit répondre à une problématique explicite, formulée en introduction.

- Une problématique explicite figure en introduction et structure tout le commentaire
- Chaque partie s'appuie sur un élément localisable du document, jamais sur une généralité seule
- La conclusion répond à la problématique posée
- La longueur demandée (400-600 mots) est respectée

SUPÉRIEUR

SÉANCE 11 : AUDITER LA QUALITÉ D'UN JEU DE DONNÉES SIG

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

Un jeu de données n'est exploitable que si sa qualité a été vérifiée au préalable, pas supposée : c'est une compétence professionnelle distincte de celle de produire une carte (voir module Le Compas, section 10, qualité des données et métadonnées), jamais encore pratiquée dans l'Atelier jusqu'ici bien qu'annoncée dès la séance 1.

1. Télécharger les 6 fichiers du jeu de données Vitrolles (voir Ressources → Jeux de données)
2. Vérifier la complétude : le nombre de cellules de grille_100m_indices.geojson correspond-il à ce qu'annonce la documentation du module Travaux pratiques (1122 cellules) ?
3. Vérifier la cohérence du CRS : emprise.geojson et grille_100m_indices.geojson déclarent-ils bien EPSG:2154, et se superposent-ils réellement une fois chargés côte à côte dans QGIS ?
4. Vérifier la plausibilité des valeurs attributaires : les NDVI/NDMI/NDBI de la grille restent-ils dans leur plage théorique (-1 à 1) ? Une valeur hors plage signale une erreur de calcul ou d'encodage
5. Rédiger une fiche de métadonnées courte (source, date, CRS, résolution, limites connues) au format du standard ISO 19115 simplifié, telle qu'un tiers pourrait la lire sans avoir jamais vu le jeu de données

EXEMPLE

UNE ANOMALIE RÉELLE À CHERCHER : LA CLASSE EAU DANS CLASSIFICATION_REFERENCE.JSON

classification_reference.json (utilisé en séance 6) recense trois classes (végétation, sol nu/bâti, eau), mais sa matrice de confusion sur le jeu de test présente une ligne "eau" entièrement à zéro pour les trois modèles fournis. Un audit de qualité doit repérer cette anomalie et formuler une hypothèse plausible (classe totalement absente du découpage spatial train/test choisi, plutôt qu'un modèle qui échouerait totalement sur l'eau) — sans vérifier cette hypothèse ici, la repérer et la documenter est déjà le geste professionnel attendu.

CORRIGÉ : SÉANCE 11

Les 5 fichiers géographiques du jeu de données sont mutuellement cohérents (même CRS EPSG:2154, même emprise), une garantie apportée par leur origine commune (même pipeline d'extraction Sentinel-2). Le point d'audit le plus instructif reste la ligne "eau" vide de classification_reference.json : elle rappelle qu'un jeu de données peut être par ailleurs parfaitement cohérent (CRS, plages de valeurs) tout en portant

une limite structurelle qu'aucune vérification de format ne révèle, seule une lecture attentive du contenu la fait apparaître.

- Critère 1 : la fiche de métadonnées mentionne explicitement le CRS, la date d'acquisition et la résolution, pas seulement le nom du fichier
- Critère 2 : au moins une vérification de plausibilité (plage de valeurs, nombre d'entités) est réellement effectuée, pas seulement annoncée
- Critère 3 : l'anomalie de la classe eau (ou toute autre anomalie réelle trouvée) est documentée avec une hypothèse, pas ignorée

VOIR AUSSI : REVOIR : QUALITÉ DES DONNÉES ET MÉTADONNÉES

Le module Le Compas détaille la norme ISO 19115 et les critères classiques de qualité d'un jeu de données géographique.

DEVOIR À RENDRE : FICHE DE MÉTADONNÉES

FICHE DE MÉTADONNÉES ET RAPPORT D'AUDIT

Produis une fiche de métadonnées complète du jeu de données Vitrolles (source, licence, CRS, résolution, emprise, date, limites connues) accompagnée d'un court rapport d'audit (une page) qui documente au moins deux vérifications de qualité réellement effectuées, avec leur résultat.

- La fiche de métadonnées couvre au moins six champs (source, licence, CRS, résolution, emprise, date)
- Au moins deux vérifications de qualité distinctes sont documentées avec leur résultat réel, pas supposé
- Toute anomalie trouvée est décrite avec une hypothèse plausible, pas seulement signalée

APPROFONDISSEMENT

SÉANCE 12 : VALIDER STATISTIQUEMENT UNE CLASSIFICATION

REMARQUE

OBJECTIF MÉTHODOLOGIQUE

La séance 6 a comparé Random Forest et un perceptron multicouche (MLP) sur le même jeu de test : le MLP obtient un kappa supérieur. Mais un écart de kappa observé sur un seul jeu de test suffit-il à conclure qu'un modèle est réellement meilleur que l'autre, ou peut-il s'expliquer par le hasard de ce découpage particulier ? C'est la question que pose toute validation statistique (voir module La Méthode, section 7, rigueur statistique d'un mémoire de recherche), rarement posée avant d'annoncer un résultat.

MODÈLE	KAPPA (TEST, N = 37170)	EXACTITUDE (TEST)
Random Forest	0.6402	0.9617
MLP (50 neurones)	0.6732	0.9632
MLP (200 neurones)	0.6720	0.9638

1. Télécharger `classification_reference.json` (voir Ressources → Jeux de données) : il contient les trois matrices de confusion complètes, pas seulement les scores agrégés du tableau ci-dessus
2. À partir des deux matrices de confusion Random Forest et MLP(50), identifier les pixels que les deux modèles classent différemment (désaccords) — c'est la donnée nécessaire à un test de McNemar, le test standard pour comparer deux classificateurs évalués sur le même jeu de test
3. Formuler l'hypothèse nulle explicitement : « les deux modèles se trompent avec la même fréquence, l'écart de kappa observé est compatible avec le hasard »
4. Discuter, sans nécessairement calculer la statistique exacte, ce qui rendrait cet écart de kappa (0.6402 contre 0.6732) plus ou moins convaincant : un grand nombre de désaccords cohérents dans un sens penche contre l'hypothèse nulle, un faible nombre de désaccords dispersés ne permet pas de trancher

ATTENTION

UN SEUL JEU DE TEST NE PROUVE JAMAIS UNE SUPÉRIORITÉ GÉNÉRALE

Même si l'écart de kappa se révèle statistiquement significatif sur ce jeu de test précis, cela ne prouve pas que le MLP est supérieur au Random Forest en général, seulement sur cette scène, ce découpage spatial train/test et ces trois classes. Une conclusion générale nécessiterait de répéter la comparaison sur plusieurs scènes et découpages

indépendants, exactement la mise en garde déjà formulée dans le quiz de cette salle (résultat mesuré, pas une règle générale à présumer).

CORRIGÉ : SÉANCE 12

Le test de McNemar ne compare pas les scores agrégés (0.9617 contre 0.9632) mais spécifiquement les pixels où les deux modèles sont en désaccord : il ignore, à raison, tous les pixels que les deux modèles classent correctement ou incorrectement de la même façon, car ces cas ne renseignent en rien sur une différence entre les deux modèles. C'est une erreur fréquente de vouloir comparer deux exactitudes globales avec un test de Student ou un simple écart en points de pourcentage : les deux échantillons ne sont pas indépendants (même jeu de test, mêmes pixels), condition que ces tests supposent et que McNemar, conçu justement pour des données appariées, respecte.

- Critère 1 : l'hypothèse nulle est formulée explicitement avant toute discussion du résultat
- Critère 2 : le raisonnement distingue clairement désaccords (pertinents pour la comparaison) et accords (non pertinents), pas une simple comparaison des deux exactitudes globales
- Critère 3 : la conclusion reste prudente sur la portée du résultat (une scène, un découpage), sans généraliser abusivement

VOIR AUSSI : REVOIR : KAPPA ET ÉVALUATION DE PRÉCISION

Le module L'Intelligence détaille le calcul du kappa et les pièges classiques de l'évaluation d'une classification.

VOIR AUSSI : APPROFONDIR : RIGUEUR STATISTIQUE D'UN MÉMOIRE

Le module La Méthode (section 7, structure IMRaD) détaille les exigences de rigueur statistique attendues dans un travail de recherche.

DEVOIR À RENDRE : NOTE D'ANALYSE

NOTE D'ANALYSE STATISTIQUE DE LA COMPARAISON RF / MLP

Rédige une note d'analyse (300 à 500 mots) qui formule l'hypothèse nulle du test de McNemar appliqué à la comparaison Random Forest / MLP(50) de la séance 6, discute qualitativement ce qui rendrait l'écart de kappa observé plus ou moins

convaincant à partir des matrices de confusion fournies, et conclut en rappelant explicitement la portée limitée du résultat (une seule scène, un seul découpage train/test).

- L'hypothèse nulle est formulée correctement (les deux modèles se trompent avec la même fréquence)
- L'argument s'appuie sur les désaccords entre modèles, pas sur la simple différence d'exactitude globale
- La conclusion rappelle explicitement que le résultat ne vaut que pour cette scène et ce découpage
- La longueur demandée (300-500 mots) est respectée